

تحويلات الشدة و الترشيح المكاني

إعداد الطالبات :

❖ هاجر الأنصاري

❖ مريم السايدي

❖ تسنيم نطوان

➤ تحت إشراف: د. محمد الله معاذ

تحويلات الكثافة والتصفية المكانية | 3

(Intensity Transformations and Spatial Filtering)

"هناك فارق كبير بين من يرى الظلام من خلال الضوء، ومن يرى السطوع من خلال الظلال"

(David Lindsay) ديفيد ليندسي —

(Preview) نظرة عامة

إلى مستوى الصورة نفسه، وتعتمد طرق معالجة الصور في هذه (spatial domain) يشير مصطلح المجال المكاني الفئة على التعامل المباشر مع البكسلات في الصورة. وهذا على النقيض من معالجة الصور في المجال التحويلي، والتي — كما سنناقش في الفصلين 4 و 6 — تتطلب أولاً تحويل الصورة إلى المجال التحويلي (transform domain) وإجراء المعالجة هناك، ثم الحصول على التحويل العكسي لإعادة النتائج إلى المجال المكاني.

والتصفية المكانية (intensity transformations) هناك فئتان رئيسيتان للمعالجة المكانية وهما: تحويلات الكثافة (spatial filtering).

(thresholding) تعمل تحويلات الكثافة على بكسلات منفردة في الصورة لأغراض مثل تعديل التباين وتحديد العتبة للصورة.

الخاص بكل بكسل في الصورة. ومن الأمثلة على (neighborhood) بينما تجري التصفية المكانية عمليات على الجوار (sharpening) وزيادة حدتها (smoothing) التصفية المكانية: تنعيم الصورة.

في الأقسام التالية، سنناقش عدداً من التقنيات "التقليدية" لتحويلات الكثافة والتصفية المكانية.

(Upon completion of this chapter, readers should:) عند الإنتهاء من هذا الفصل، ينبغي على القارئ أن يكون قادراً على

فهم معنى المعالجة في المجال المكاني، وكيف تختلف عن المعالجة في المجال التحويلي.

التعرف على التقنيات الرئيسية المستخدمة لتحويلات الكثافة.

وكيفية التلاعب به لتحسين الصورة (Histograms) فهم المعنى الفيزيائي للرسم البياني التكراري للصورة.

فهم آلية عمل التصفية المكانية، وكيفية تشكيل المرشحات المكانية.

(correlation) والارتباط (spatial convolution) فهم مبادئ التلافيف المكاني.

التعرف على الأنواع الرئيسية للمرشحات المكانية، وكيفية تطبيقها.

(lowpass filters) إدراك العلاقات بين المرشحات المكانية، والدور الأساسي لمرشحات التمرير المنخفض.

فهم كيفية استخدام مزيج من طرق التحسين في الحالات التي يكون فيها النهج الواحد غير كافٍ.

3.1 الخلفية (3.1 BACKGROUND)

جميع تقنيات معالجة الصور المناقشة في هذا الفصل يُتم تطبيقها في المجال المكاني (spatial domain)، والذي نعلم من مناقشة القسم 2.4 أنه المستوى الذي يحتوي على بكسلات الصورة. تعمل تقنيات المجال المكاني مباشرة على بكسلات الصورة، وذلك بخلاف مجال التردد (موضوع الفصل الرابع) الذي تُجرى فيه العمليات على تحويل فورييه للصورة بدلاً من الصورة نفسها. وكما سنتعلم خلال التقدم في هذا الكتاب، فإن بعض مهام معالجة الصور تكون أسهل أو أكثر معنى عند تطبيقها في المجال المكاني، بينما يناسب بعضها الآخر النهج الثاني.

أساسيات تحويلات الكثافة والتصفية المكانية

THE BASICS OF INTENSITY TRANSFORMATIONS AND SPATIAL (FILTERING)

تعتمد عمليات المجال المكاني التي نناقشها في هذا الفصل على التعبير الرياضي التالي:

$$g(x, y) = T[f(x, y)] \quad \text{حيث:}$$

$f(x, y)$ هي صورة الدخل (Input image).

$g(x, y)$ هي صورة الخرج (Output image).


(x, y) النقطة (neighborhood) ومُعَرَّف فوق جوار f مطبق على (Operator) هو مؤثر T .

يمكن تطبيق المؤثر على بكسلات صورة واحدة (وهو تركيزنا الرئيسي في هذا الفصل)، أو على بكسلات مجموعة من الصور مثل إجراء الجمع العنصري لسلسلة من الصور لتقليل الضوضاء كما نوقش في القسم 2.6.

توضح الشكل 3.1 التنفيذ الأساسي للمعادلة (3-1) على صورة واحدة. النقطة (x_0, y_0) الموضحة هي موقع اختياري في الصورة، والمنطقة الصغيرة الموضحة هي جوار (neighborhood) النقطة (x_0, y_0) . عادةً ما يكون الجوار مستطيلاً، ومركزه عند (x_0, y_0) ، وحجمه أصغر بكثير من حجم الصورة.

تتكون العملية التي يوضحها الشكل 3.1 من تحريك مركز الجوار من بكسل إلى آخر، وتطبيق المؤثر T على البكسلات الواقعة داخل الجوار للحصول على قيمة الخرج في ذلك الموقع. وبالتالي، لأي موقع محدد (x_0, y_0) :

الشكل 3.1 (FIGURE 3.1):



جوار بمقدار 3×3 times حول نقطة (x_0, y_0) في الصورة. يتم تحريك الجوار من بكسل إلى آخر في الصورة لتوليد صورة الخرج. تذكر من الفصل الثاني أن قيمة البكسل عند الموقع (x_0, y_0) هي $f(x_0, y_0)$ ، وهي قيمة الصورة عند ذلك الموقع.

تكون قيمة صورة الخرج g عند تلك الإحداثيات مساوية لنتيجة تطبيق المؤثر T على الجوار الذي مبدؤه/مركزه عند (x_0, y_0) في f .

على سبيل المثال، لنفترض أن الجوار عبارة عن مربع بحجم 3×3 times وأن المؤثر T مُعَرَّف كـ "حساب متوسط كثافة البكسلات في الجوار". افترض موقعاً اختيارياً في الصورة وليكن $(150, 100)$. النتيجة عند ذلك الموقع في صورة الخرج، أي $g(100, 150)$ ، هي مجموع $f(100, 150)$ ومجاوراتها الثمانية (neighbors-8) مقسوماً على 9. ثم يتم تحريك مركز الجوار إلى الموقع المجاور التالي وتكرار الإجراء لتوليد القيمة التالية لصورة الخرج g .

عادةً، تبدأ العملية من الزاوية العليا اليسرى لصورة الدخل وتتقدم بكسلاً بكسل في مسح أفقياً (أو رأسياً)، صفّاً واحداً (أو عموداً واحداً) في كل مرة.

تحويل الكثافة / النقطي (Point Processing)

أصغر جوار ممكن هو بحجم 1×1 . في هذه الحالة، تعتمد g فقط على قيمة f عند نقطة واحدة (x, y) ، وتتحول T في المعادلة (1-3) إلى دالة تحويل الكثافة (intensity transformation function) (وتسمى أيضاً مستوى الرمادي gray-level أو التعيين mapping) وتأخذ الشكل:

$$s = T(r)$$

حيث نستخدم s و r للتبسيط للتعبير عن كثافة g و f عند أي نقطة (x, y) بالترتيب.

توسع التباين (Contrast Stretching): إذا كانت $T(r)$ تأخذ الشكل الموضح في الشكل 3.2(a)، فإن نتيجة تطبيق التحويل على كل بكسل في f ستكون إنتاج صورة ذات تباين أعلى من الأصلية، عن طريق تقليل مستويات الكثافة تحت القيمة k وزيادة سطوع المستويات التي فوق k . تُعرف هذه التقنية أحياناً بتوسع التباين؛ القيم الأقل من k تقل (تغطي) الكثافة نحو الأسود، بينما القيم الأعلى من k ترتفع الكثافة نحو الأبيض.

دالة التحديد / العتبة (Thresholding Function): في الحالة الحدية الموضحة في الشكل 3.2(b)، تنتج $T(r)$ صورة ثنائية المستوى (صورة ثنائية binary image). تُسمى دالة التعيين من هذا الشكل بدالة العتبة (thresholding function).

يمكن صياغة أساليب معالجة بسيطة جداً ولكنها قوية باستخدام دوال تحويل الكثافة لغرض تحسين الصورة (image enhancement). وفي الفصل العاشر، سنستخدمها لتجزئة الصور (image segmentation).

الأساليب التي تعتمد نتائجها فقط على الكثافة عند نقطة ما تُسمى أحياناً تقنيات المعالجة النقطية (point processing techniques)، وذلك تمييزاً لها عن تقنيات المعالجة بالجوار (neighborhood processing techniques).

ملاحظة هامشية (Margin Note):

اعتماداً على حجم الجوار وموقعه بالقرب من حدود الصورة، قد تقع بعض البكسلات خارج حدود الصورة. هناك حلان لهذه المشكلة:

إهمال القيم التي تقع خارج الصورة.


حشو الصورة (pad the image) بالحواف (وهو الخيار الأفضل).

الشكل 3.2 (FIGURE 3.2):

دوال تحويل الكثافة:

(a) دالة توسيع التباين (Contrast stretching function).

(b) دالة العتبة (Thresholding function).



(ABOUT THE EXAMPLES IN THIS CHAPTER) حول الأمثلة في هذا الفصل

على الرغم من أن طرق تحويل الكثافة والتصفية المكانية تغطي نطاقاً واسعاً من التطبيقات، إلا أن معظم الأمثلة في التحسين هو عملية معالجة الصورة لتصبح (image enhancement). هذا الفصل هي تطبيقات على تحسين الصور مهمة، لأنها تؤكد من البداية على (specific) النتيجة أكثر ملاءمة من الصورة الأصلية لتطبيق معين. وتعتبر كلمة معين (problem-oriented). أن تقنيات التحسين هي تقنيات موجهة نحو المشكلة

الطرق لتحسين صور Best قد لا تكون (X-ray) على سبيل المثال، الطرق المفيدة جداً لتحسين صور الأشعة السينية، لا توجد "نظرية" عامة لتحسين الصور؛ فعندما تعالج الصورة للتقييم البصري (infrared) الأشعة تحت الحمراء يكون المشاهد هو الحكم النهائي على مدى كفاءة طريقة معينة


فإن التحسين يكون أسهل في القياس الكمي. على سبيل (machine perception) أما عند التعامل مع الإدراك الآلي فإن طريقة (automated character-recognition system) المثال، في نظام التعرف الآلي على الحروف التحسين الأكثر ملاءمة هي التي تؤدي إلى أعلى معدل للتعرف، بغض النظر عن الاعتبارات الأخرى مثل المتطلبات الحسابية

بغض النظر عن التطبيق أو الطريقة المستخدمة، فإن تحسين الصور يُعد من أكثر مجالات معالجة الصور جاذبية بصرياً. يجد المبتدئون في معالجة الصور عادةً أن تطبيقات التحسين ممتعة وسهلة الفهم نسبياً. لذلك، فإن استخدام أمثلة من تحسين الصور لتوضيح طرق المعالجة المكانية المطورة في هذا الفصل لا يوفر فقط الحاجة إلى فصل إضافي يتعامل مع التحسين، ولكن الأكثر أهمية هو أنه نهج فعال لتقديم مفاهيم معالجة الصور في المجال المكاني للقادمين الجدد

ومع تقدمك في بقية الكتاب، ستجد أن المادة المطورة في هذا الفصل لها نطاق أوسع بكثير من مجرد تحسين الصور

بعض دوال تحويل الكثافة الأساسية 3.2

(3.2 SOME BASIC INTENSITY TRANSFORMATION FUNCTIONS)



تُعد تحويلات الكثافة من بين أسهل جميع تقنيات معالجة الصور. كما ذكرنا في القسم السابق، نرسم لقيم البكسلات، كما هو موضح في المعادلة (2-3)، T ، على التوالي. ترتبط هذه القيم عن طريق تحويل r و s قبل المعالجة وبعدها بـ s إلى قيمة بكسل جديدة r والذي يعين قيمة البكسل

إلى r نظرًا لأننا نتعامل مع كميات رقمية، فإن قيم دالة تحويل الكثافة تُخزن عادةً في جدول، وتُنفذ عمليات التعيين من يحتوي جدول البحث، (8-bit image) بالنسبة لصورة ذات 8 بتات (lookups tables) عبر جداول البحث s على 256 إدخالاً T الخاص بـ

كمقدمة لتحويلات الكثافة، ننظر إلى الشكل 3.3، الذي يوضح ثلاثة أنواع أساسية من الدوال المستخدمة بشكل تكراري في معالجة الصور

(identity) والمطابقة (negative) تحويلات السالب (Linear): خطية

تحويلات اللوغاريتم واللوغاريتم العكسي (Logarithmic): لوغاريتمية

n والجزر n تحويلات القوة (Power-law): قانون القوة

الحالة البديهية التي تكون فيها كثافة الخرج مطابقة لكثافة الدخل (Identity function) تُعد دالة المطابقة

(IMAGE NEGATIVES) سالب الصورة

باستخدام دالة التحويل $[0, L-1]$ يتم الحصول على سالب الصورة التي تقع مستويات الكثافة فيها ضمن المجال السلبية الموضحة في الشكل 3.3، والتي تأخذ الشكل التالي


$$s = L - 1 - r$$

(FIGURE 3.3) الشكل 3.3:

بعض دوال تحويل الكثافة الأساسية. تم تغيير مقياس كل منحنى بشكل مستقل حتى تتناسب جميع المنحنيات في نفس الرسم البياني. اهتمامنا هنا ينصب على أشكال المنحنيات وليس على قيمها النسبية.

إن عكس مستويات الكثافة لصورة رقمية بهذه الطريقة ينتج عنه ما يعادل السالب الفوتوغرافي (photographic negative). يُستخدم هذا النوع من المعالجة، على سبيل المثال، في تحسين التفاصيل البيضاء أو الرمادية المغمورة في المناطق الداكنة من الصورة، خاصة عندما تكون المناطق السوداء هي السائدة في الحجم.

يعرض الشكل 3.4 مثالاً على ذلك؛ فالصورة الأصلية عبارة عن صورة شعاعية رقمية للثدي (digital mammogram) تُظهر وريماً صغيراً. على الرغم من أن المحتوى البصري هو نفسه في كلتا الصورتين، إلا أن بعض المشاهدين يجدون أنه من الأسهل تحليل التفاصيل الدقيقة للأنسجة باستخدام الصورة السالبة (Negative image).



الشكل 3.4 (FIGURE 3.4):

(a) صورة شعاعية رقمية للثدي (Digital mammogram).

(b) الصورة السالبة الناتجة باستخدام المعادلة (3-3).

(الصورة (a) بإذن من شركة (General Electric Medical Systems).

تحويلات اللوغاريتم (LOG TRANSFORMATIONS)

الشكل العام لتحويل اللوغاريتم في الشكل 3.3 هو:

$$s = c \log(1 + r) \quad \text{where}$$

حيث c هو ثابت، ويفترض أن $r \geq 0$. يوضح شكل منحنى اللوغاريتم في الشكل 3.3 أن هذا التحويل يعين نطاقاً ضيقاً من قيم الكثافة المنخفضة في الدخول إلى نطاق أوسع من مستويات الخرج. على سبيل المثال، لاحظ كيف يتم تعيين مستويات دخل الكثافة في النطاق $[0, L/4]$ إلى مستويات خرج في النطاق $[0, 4/3L]$. وعلى العكس من ذلك، يتم تعيين القيم الأعلى لمستويات الدخل إلى نطاق أضيق في الخرج.

نستخدم تحويلاً من هذا النوع لتوسيع قيم البكسلات الداكنة في الصورة، مع ضغط قيم المستويات الأعلى. والعكس صحيح بالنسبة لتحويل اللوغاريتم العكسي (الدالة الأسية exponential).

أي منحنى يملك الشكل العام لدالة اللوغاريتم الموضحة في الشكل 3.3 يمكنه تحقيق هذا التوسيع/الضغط لمستويات الكثافة في الصورة، لكن تحويلات قانون القوة (power-law transformations) المناقشة في القسم التالي أكثر مرونة لهذا الغرض.

تتميز دالة اللوغاريتم بخاصية مهمة وهي أنها تضغط المدى الديناميكي (dynamic range) لقيم البكسل. ومن الأمثلة التي تملك فيها قيم البكسل مدى ديناميكياً واسعاً: طيف فورييه (Fourier spectrum)، والذي سنناقشه في الفصل الرابع. ليس من الغريب مواجهة قيم طيف تتراوح من 0 إلى 10^6 أو أعلى. معالجة أرقام مثل هذه لا تمثل مشكلة للحاسوب، لكن أجهزة عرض الصور لا يمكنها إعادة إنتاج مثل هذا المدى الواسع من القيم بأمانة. والنتيجة الصافية هي أن التفاصيل ذات الكثافة العالية قد تضع عند عرض طيف فورييه النموذجي.

الشكل 3.5(a) يوضح طيف فورييه بقيم تتراوح في المدى من 0 إلى 1.5×10^6 . عندما يتم تغيير مقياس هذه القيم خطياً للعرض في نظام 8 بتات، فإن البكسلات الأكثر سطوعاً تسيطر على العرض، على حساب القيم الأدنى (والتي لا تقل أهمية) في الطيف. يتم توضيح تأثير هذه السيطرة بوضوح من خلال المساحة الصغيرة نسبياً في الصورة في الشكل 3.5(a) والتي لا تظهر باللون الأسود.

إذا قمنا بدلاً من عرض القيم بهذه الطريقة بتطبيق المعادلة (3-4) أولاً (مع $c = 1$ في هذه الحالة) على قيم الطيف، فإن مدى قيم النتيجة يصبح من 0 إلى 15.2. إن تحويل القيم بهذه الطريقة يتيح عرض مدى أكبر من الكثافات على الشاشة. يوضح الشكل 3.5(b) نتيجة تغيير مقياس مدى الكثافة خطياً إلى المدى $[0, 255]$ وعرض الطيف في نفس نظام العرض ذي الـ 8 بتات. مستوى التفاصيل الدقيقة الظاهرة في هذه الصورة مقارنة بالعرض غير المعدل للطيف واضح جداً من هاتين الصورتين. معظم أطراف فورييه في منشورات معالجة الصور، بما في ذلك هذا الكتاب، تم تغيير مقياسها بهذه الطريقة.

الشكل 3.5 (FIGURE 3.5):

(a) طيف فورييه معروض كصورة ذات تدرج رمادي.

(b) نتيجة تطبيق التحويل اللوغاريتمي في المعادلة (3-4) مع $c = 1$. تم تغيير مقياس كلا الصورتين إلى المدى $[0, 255]$.

(تابع الصفحة 125)

تحويلات قانون القوة (جاما) (POWER-LAW (GAMMA) TRANSFORMATIONS)

تأخذ تحويلات قانون القوة الشكل التالي:

$$s = c \cdot r^\gamma \quad \text{where}$$


حيث c و γ ثابتان موجبة. تُكتب المعادلة (5-3) أحياناً على الشكل $s = c(r + \epsilon)^\gamma$ للحساب من أجل الإزاحات (أي إنتاج خرج حتى عندما يكون الدخل صفراً). ومع ذلك، فإن الإزاحات تكون عادةً مسألة معايرة لجهاز العرض، ونتيجة لذلك يتم تجاهلها عادةً في المعادلة (5-3).

يوضح الشكل 3.6 رسومات بيانية لـ s كدالة في r لقيم مختلفة من γ . كما هو الحال مع تحويلات اللوغاريتم، فإن منحنيات قانون القوة ذات القيم الكسرية لـ γ تقوم بتعيين نطاق ضيق من قيم الدخل الداكنة إلى نطاق أوسع من قيم الخرج، والعكس صحيح بالنسبة للقيم الأعلى لمستويات الدخل. لاحظ أيضاً في الشكل 3.6 أنه يمكن الحصول على عائلة كاملة من التحويلات ببساطة عن طريق تغيير γ . المنحنيات الناتجة بقيم $\gamma > 1$ لها عكس التأثير تماماً مقارنة بتلك الناتجة بقيم $\gamma < 1$. وعندما يكون $\gamma = 1$ ، $c = 1$ ، تخفض المعادلة (5-3) إلى تحويل المطابقة (identity transformation).

يخضع استجابة العديد من الأجهزة المستخدمة لالتقاط الصور وعرضها وطباعتها لقانون القوة. جرت العادة على تسمية الأس في معادلة قانون القوة بـ جاما (γ) [ومن هنا جاء استخدام هذا الرمز في المعادلة (5-3)]. يُطلق على العملية المستخدمة لتصحيح ظاهرة استجابة قانون القوة هذه اسم تصحيح جاما (gamma correction) أو ترميز جاما (gamma encoding).


على سبيل المثال، تمتلك أجهزة أنبوب أشعة الكاثود (CRT) استجابة كثافة إلى جهد تخضع لدالة القوة، بأسس تتراوح من حوالي 1.8 إلى 2.5. كما يظهر المنحنى الخاص بـ $\gamma = 2.5$ في الشكل 3.6، فإن أنظمة العرض هذه تميل إلى إنتاج...

FIGURE 3.6
Plots of the gamma equation $s = cr^\gamma$ for various values of γ ($c = 1$ in all cases). Each curve was scaled independently so that all curves would fit in the same graph. Our interest here is on the shapes of the curves, not on their relative values.



الشكل 3.6 (FIGURE 3.6):

رسومات معادلة جاما $s = c r^\gamma$ لقيم مختلفة من γ (مع $c = 1$ في جميع الحالات). تم تغيير مقياس كل منحنى بشكل مستقل بحيث تتناسب جميع المنحنيات في نفس الرسم البياني. اهتمامنا هنا ينصب على أشكال المنحنيات وليس على قيمها النسبية.



صورة أغمق مما هو مقصود. يوضح الشكل 3.7 هذا التأثير؛ فالشكل 3.7(a) عبارة عن صورة متدرجة الكثافة (intensity ramp image). الشكل 3.7(b) يُظهر الصورة كما تُعرض على شاشة بمقياس جاما يساوي 2.5. وكما هو متوقع، يظهر خرج الشاشة أغمق من صورة الدخل.

في هذه الحالة، يتكون تصحيح جاما (gamma correction) من استخدام التحويل $s = r^{1/2.5} = r^{0.4}$ لمعالجة الصورة مسبقاً قبل إدخالها إلى الشاشة. النتيجة موضحة في الشكل 3.7(c). وعند إدخال هذه الصورة المصححة إلى نفس الشاشة، فإنها تنتج خروجاً قريباً جداً في المظهر من الصورة الأصلية، كما يظهر في الشكل 3.7(d). ينطبق تحليل مماثل لما سبق على أجهزة التصوير الأخرى مثل الماسحات الضوئية والطابعات، مع الفارق في قيمة جاما التي تعتمد على الجهاز نفسه (Poynton [1996]).

ملاحظة هامشية (Margin Note):

أحياناً تجعل قيمة جاما العالية الصورة المعروضة تبدو أفضل للمشاهد لأنها تزيد من التباين. ومع ذلك، فإن الهدف من تصحيح جاما هو إنتاج عرض دقيق لصورة الدخل.

الشكل 3.7 (FIGURE 3.7):

(a) صورة متدرجة الكثافة (Intensity ramp image).

(b) الصورة كما تُعرض على شاشة محاكاة بقيمة جاما 2.5.

(c) الصورة بعد تصحيح جاما.


(d) الصورة المصححة كما تُعرض على نفس الشاشة. قارن بين (d) و (a).

مثال 3.1: تحسين التباين باستخدام تحويلات قانون القوة للكثافة

(EXAMPLE 3.1: Contrast enhancement using power-law intensity transformations)

بالإضافة إلى تصحيح جاما، تُعد تحويلات قانون القوة مفيدة لمعالجة التباين للأغراض العامة. يظهر الشكل 3.8(a) صورة رنين مغناطيسي (MRI) للجزء العلوي من العمود الفقري الصدري لإنسان مصاب بخلع كسري (fracture dislocation). الكسر واضح في المنطقة المحددة بالدائرة. نظرًا لأن الصورة داكنة في الغالب، فإن توسيع مستويات الكثافة يُعد أمراً مرغوباً فيه. يمكن تحقيق ذلك باستخدام تحويل قانون القوة بأس كسري.

الصور الأخرى الموضحة في الشكل تم الحصول عليها عن طريق معالجة الشكل 3.8(a) باستخدام دالة تحويل قانون القوة في المعادلة (3-5).



الشكل 3.8 (FIGURE 3.8):

(a) صورة رنين مغناطيسي (MRI) لكسر في العمود الفقري الصدري للإنسان (منطقة الكسر محاطة بدائرة).
 (b)–(d) نتائج تطبيق التحويل في المعادلة (3-5) مع $c = 1$ وقيم γ تساوي 0.3 و 0.4 و 0.6 على التوالي.
 الصورة الأصلية بإذن من الدكتور David R. Pickens، قسم الأشعة والعلوم الإشعاعية، المركز الطبي بجامعة فاندربيلت).

قيم جاما المناظرة للصور من (b) إلى (d) هي 0.3 و 0.4 و 0.6 على التوالي (مع $c = 1$ في جميع الحالات). لاحظ أنه مع انخفاض قيمة جاما من 0.6 إلى 0.4، أصبحت المزيد من التفاصيل واضحة. أدى انخفاض آخر لقيمة جاما إلى 0.3 إلى تحسين بعض التفاصيل الدقيقة في الخلفية، ولكنه بدأ في تقليل التباين إلى النقطة التي بدأت فيها الصورة تأخذ مظهراً "باهتاً" (washed-out)، خاصة في الخلفية. تم الحصول على أفضل تحسين من حيث التباين والتفاصيل الواضحة مع $\gamma = 0.4$. وتُعد القيمة $\gamma = 0.3$ حداً تقريبياً ينخفض تحته التباين في هذه الصورة المحددة إلى مستوى غير مقبول.

مثال 3.2: توضيح آخر لتحويلات قانون القوة

(EXAMPLE 3.2: Another illustration of power-law transformations)

يعرض الشكل 3.9 (a) المشكلة المعاكسة لتلك الموضحة في الشكل 3.8 (a). الصورة المراد معالجتها...

(Page 128) تابع: مثال على تحويلات قانون القوة



مما يشير إلى أن ضغط مستويات الكثافة يُعد أمراً مرغوباً فيه. يمكن، (washed-out) "تظهر الآن بمظهر "باهت... أكبر من 1 gamma \ تحقيق ذلك باستخدام المعادلة (3-5) بـ 5-3 (بقيم ل

على التوالي (d) إلى (b) تساوي 3.0 و 4.0 و 5.0 في الأشكال 3.9 gamma \ بـ (a) تظهر نتائج معالجة الشكل 3.9. تم الحصول على نتائج مناسبة باستخدام قيم جاما 3.0 و 4.0. النتيجة الأخيرة تتمتع بمظهر أكثر جاذبية قليلاً لأنها ؛ فعلى سبيل المثال، تظهر مدرجات 5.0 gamma \ ذات تباين أعلى. وهذا ينطبق أيضاً على النتيجة المحصلة مع مقارنة بأي من الصور الثلاث الأخرى (d) المطار القريبة من منتصف الصورة أكثر وضوحاً في الشكل 3.9.

(FIGURE 3.9) الشكل 3.9:

صورة جوية (a)

في جميع (c = 1) تساوي 3.0 و 4.0 و 5.0 على التوالي gamma \ نتائج تطبيق التحويل في المعادلة (3-5) مع (b)–(d) (الحالات).

(NASA الصورة الأصلية بإذن من وكالة ناسا).

دوال التحويل الخطية القطعية

(PIECEWISE LINEAR TRANSFORMATION FUNCTIONS)

(piecewise linear functions) النهج المكمل للطرق المناقشة في الأقسام الثلاثة السابقة هو استخدام دوال خطية قطعية الميزة الرئيسية لهذه الدوال مقارنة بالدوال المناقشة حتى الآن هي أن شكل الدوال الخطية القطعية. (piecewise linear functions) يمكن أن يكون معقداً بدرجة اختيارية. في الواقع، وكما ستلاحظ قريباً، فإن التنفيذ العملي لبعض التحويلات الهامة يمكن صياغته فقط كدوال خطية قطعية. العيب الرئيسي لهذه الدوال هو أن تحديدها يتطلب مدخلات شاسعة من (user input) المستخدم.

(Page 129) بعض دوال تحويل الكثافة الأساسية 3.2

(Contrast Stretching) توسيع التباين

قد تنتج الصور ذات التباين المنخفض عن سوء الإضاءة، أو نقص المدى الديناميكي في مستشعر التصوير، أو حتى على توسيع مدى (Contrast stretching) الضبط الخاطئ لفتحة العدسة أثناء التقاط الصورة. يعمل توسيع التباين مستويات الكثافة في الصورة بحيث يغطي المدى الكامل المتاح في وسط التسجيل أو جهاز العرض.

في (r_1, s_1) و (r_2, s_2) تحويلاً نموذجياً يُستخدم لتوسيع التباين. تتحكم مواقع النقاط (a) يوضح الشكل 3.10: شكل دالة التحويل

فإن التحويل يكون دالة خطية لا تنتج أي تغيير في الكثافة، $r_1 = s_1$ و $r_2 = s_2$ إذا كان

تنتج (thresholding function) فإن التحويل يتحول إلى دالة عتبة، $s_1 = 0$ و $s_2 = L-1$ و $r_1 = r_2$ إذا كان [(b) انظر الشكل 3.2] صورة ثنائية

تنتج درجات مختلفة من التوسع في مستويات كثافة صورة الخرج، مما (r_1, s_1) و (r_2, s_2) القيم المتوسطة ل يؤثر بالتالي على تباينها

وتزايدية (single valued) لكي تكون الدالة أحادية القيمة $s_1 \leq s_2$ و $r_1 \leq r_2$ بشكل عام، يُفترض أن هذا يحافظ على ترتيب مستويات الكثافة، مما يمنع ظهور عيوب صناعية. (monotonically increasing) بانتظام في الكثافة (artifacts)

نتيجة توسيع (c) يوضح صورة المجهر الإلكتروني المنخفضة التباين بـ 8 بتات. يوضح الشكل 3.10 (b) الشكل 3.10 حيث $(r_1, s_1) = (r_{\min}, 0)$ و $(r_2, s_2) = (r_{\max}, L-1)$ التباين المحصلة عن طريق ضبط يمثلان أدنى وأعلى مستويات الكثافة في صورة الدخل $r_{\min}$ و $r_{\max}$

(FIGURE 3.10): الشكل 3.10


دالة تحويل خطية قطعية لتوسيع التباين (a)

صورة بالمجهر الإلكتروني لحبوب اللقاح منخفضة التباين، مكبرة 700 مرة (b)

نتيجة توسيع التباين (c)

نتيجة تطبيق دالة العتبة (d)

المعهد البيولوجي للبحث العلمي، الجامعة الوطنية الأسترالية، Roger Heady الصورة الأصلية بإذن من الدكتور كانبرا، أستراليا




دوال تحويل الكثافة الأساسية

تكلمة الفقرة السابقة (Page 130)

على التوالي. قامت دالة التحويل بتوسيع مستويات الكثافة خطياً لكي تغطي كامل نطاق الكثافة $[0, L-1]$.

أخيراً، يوضح الشكل



3.10(d) نتيجة استخدام دالة العتبة (Thresholding function) مع ضبط:

$$(r_1, s_1) = (m, 0)$$

$$(r_2, s_2) = (m, L-1)$$

حيث يمثل m متوسط مستوى الكثافة في الصورة.

تقطيع مستوى الكثافة

(Intensity-Level Slicing)

هناك تطبيقات في معالجة الصور يكون الهدف منها تسليط الضوء على نطاق معين ومحدد من الكثافات.

من أمثلة هذه التطبيقات:

تحسين المظاهر والأشكال في صور الأقمار الصناعية (مثل الكتل المائية).

تحسين إبراز العيوب والشقوق في صور الأشعة السينية (X-ray).

يمكن تنفيذ تقنية تقطيع مستوى الكثافة بعدة طرق، لكنها تدور حول أسلوبين رئيسيين:

الأسلوب الأول: عرض جميع القيم الواقعة في النطاق المطلوب بقيمة واحدة (مثلاً اللون الأبيض)، وعرض باقي الكثافات الخارجة عن النطاق بقيمة أخرى (مثلاً اللون الأسود). هذا التحويل الموضح في الشكل 3.11(a) ينتج صورة ثنائية (Binary image).

الأسلوب الثاني: زيادة سطوع (أو تغميق) النطاق المطلوب من الكثافات، مع ترك جميع مستويات الكثافة الأخرى في الصورة دون أي تغيير، كما يظهر في الشكل 3.11(b).

وصف الشكل 3.11 (FIGURE 3.11):

(a) دالة تحويل تسلط الضوء على النطاق $[A, B]$ وتقلل باقي الكثافات إلى مستوى أدنى.

(b) دالة تحويل تسلط الضوء على النطاق $[A, B]$ وتترك الكثافات الأخرى دون تغيير.

مثال 3.3: تقطيع مستوى الكثافة

(EXAMPLE 3.3: Intensity-Level Slicing)

الشكل 3.12(a) يمثل صورة شريانية للشريان الأورطي بالقرب من منطقة الكلية (Aortic angiogram). الهدف من هذا المثال هو استخدام تقطيع مستوى الكثافة لتحسين إبراز الأوعية الدموية الرئيسية التي تظهر أسطح من الخلفية نتيجة إحقان مادة تباين (Contrast medium).

عند استخدام التحويل الموضح في الشكل 3.11(a):

النطاق المحدد كان بالقرب من الجزء العلوي لمقياس الكثافة. النتيجة الصافية الموضحة في الشكل 3.12(b) هي أن الأوعية الدموية وأجزاء من الكليتين تظهر باللون الأبيض، بينما تظهر جميع الكثافات الأخرى باللون الأسود. هذا التحسين ينتج صورة ثنائية، وهو مفيد لدراسة الخصائص الشكلية لتدفق مادة التباين (لكشف الانسدادات مثلاً).

عند استخدام التحويل الموضح في الشكل 3.11(b):



إذا كان الاهتمام ينصب على قيم الكثافة الفعلية لمنطقة الاهتمام، نستخدم الشكل 3.11(b). الشكل 3.12(c) يوضح النتيجة؛ حيث تم ضبط نطاق الكثافات حول متوسط الكثافة ليتحول للأسود، بينما تركت الكثافات الأخرى دون تغيير. هنا نلاحظ أن الدرجات الرمادية للأوعية الدموية والكلية ظلت محفوظة.

وصف الشكل 3.12 (FIGURE 3.12):

(a) صورة شريانية للشريان الأورطي (Aortic angiogram).

(b) نتيجة استخدام تحويل التقطيع من النوع 3.11(a).

(c) نتيجة استخدام تحويل التقطيع من النوع 3.11(b).

تقطيع مستويات البت

(Bit-Plane Slicing)

قيم البكسلات هي أعداد صحيحة مكونة من بتات (Bits). على سبيل المثال، القيم في صورة ذات تدرج رمادي بمستوى 256 تتكون من 8 بتات (أي بكسل واحد = 1 بايت).

بدلاً من تسليط الضوء على نطاقات الكثافة، يمكننا تسليط الضوء على المساهمة التي يقدمها كل بت محدد في المظهر الكلي للصورة.

كما يوضح الشكل 3.13، يمكن اعتبار الصورة ذات الـ 8 بتات مكونة من 8 مستويات (كل مستوى بسمك 1 بت):

المستوى 1 (Plane 1): يحتوي على البت الأدنى قيمة (Lowest-order bit / LSB) لجميع البكسلات.

المستوى 8 (Plane 8): يحتوي على البت الأعلى قيمة (Highest-order bit / MSB) لجميع البكسلات.

وصف الشكل 3.13 (FIGURE 3.13):

مستويات البت (Bit-planes) لصورة ذات 8 بتات.

Bit plane 1: البت الأدنى أهمية (Least significant).

Bit plane 8: البت الأعلى أهمية (Most significant).

تحليل المستويات (Page 131)


الشكل 3.14(a) يوضح صورة رمادية بـ 8 بتات. يلاحظ أن:

المستويات الأربعة العليا (Higher-order bit planes): وخاصة المستوى الأول والثاني منها، تحتوي على كمية كبيرة ومهمة من البيانات المرئية للصورة.

المستويات السفلى

(Lower-order bit planes): تساهم في التفاصيل الدقيقة جداً للكثافة في الصورة.


FIGURE 3.13
Bit-planes of an
8-bit image.



دوال تحويل الكثافة الأساسية (تابع)

وصف الشكل 3.14 (FIGURE 3.14):

(a) صورة رمادية ذات 8 بتات بحجم 1192\ 550 times بكسل.



(b) إلى (i) مستويات البت من 8 إلى 1، حيث يمثل المستوى 1 البت الأدنى أهمية (LSB).

كل مستوى بت هو عبارة عن صورة ثنائية (Binary image).

آلية تمثيل البتات في الصورة (Page 132)

...المستويات سوداء (0)، بينما البعض الآخر أبيض (1).

لمعرفة السبب، اعتبر بكسلاً في منتصف الحد السفلي للصورة في الشكل 3.14(a):

البكسلات المناظرة لها في مستويات البت (بدءاً من المستوى الأعلى) تمتلك القيم: 0 1 0 0 0 1 1.

هذا التمثيل الثنائي يقابل الرقم العشري 194.

يمكن إعادة بناء قيمة أي بكسل في الصورة الأصلية من البكسلات الثنائية المقابلة لها في مستويات البت عن طريق تحويل السلسلة الثنائية مكونة من 8 بتات إلى رقم عشري.

توليد مستويات البت واضغط الصور

يمكن الحصول على الصورة الثنائية لمستوى البت الثامن (Bit plane 8) لصورة ذات 8 بتات عن طريق تطبيق دالة العتبة (Thresholding):

تحويل قيم الكثافة بين 0 و 127 إلى القيمة 0.

تحويل قيم الكثافة بين 128 و 255 إلى القيمة 1.

فائدة تفكيك الصورة إلى مستويات البت:


تحليل الأهمية النسبية لكل بت: يحدد مدى كفاية عدد البتات المستخدمة لتكميم (Quantize) الصورة. ضغط الصور (Image Compression): (موضوع الفصل الثامن)، حيث يُستخدم عدد أقل من المستويات لإعادة بناء الصورة.

مثال على إعادة البناء:

يظهر الشكل 3.15 (a) صورة تم إعادة بنائها باستخدام مستويي البت 8 و 7 فقط: تتم عملية إعادة البناء بضرب بكسلات المستوى رقم n في الثابت 2^{n-1} لتحويل البت الثنائي إلى عشري. يُضرب كل مستوى بت في الثابت المناظر له، وتُجمع النتائج للحصول على الصورة الرمادية. للحصول على الشكل 3.15 (a)، ضربنا مستوى البت 8 في 128، ومستوى البت 7 في 64، ثم جمعنا المستويين. النتيجة أظهرت استعادة الملامح الرئيسية للصورة الأصلية، ولكن الصورة وتبدو مسطحة (Flat) خاصة في الخلفية. (تابع الصفحة 133)

وصف الشكل 3.15 (FIGURE 3.15):

صور تمت إعادة بنائها من مستويات البت



:

(a) باستخدام المستويين 8 و 7.

(b) باستخدام المستويات 8 و 7 و 6.

(c) باستخدام المستويات 8 و 7 و 6 و 5.

هذا ليس مستغرباً لأن مستويين فقط يمكنهما إنتاج 4 مستويات كثافة متميزة فقط ($4 = 2^2$).

إضافة المستوى 6 إلى إعادة البناء ساعدت في تحسين الوضع كما يظهر في الشكل 3.15 (b).

إضافة المستوى 5 حسنت الخلفية بشكل ملحوظ وقللت من التدرج الظاهر (Contouring) كما يوضح الشكل 3.15 (c).

الخلاصة:

تخزين أعلى 4 مستويات بت فقط يسمح بإعادة بناء الصورة الأصلية بتفاصيل مقبولة جداً، مع توفير 50% من المساحة التخزينية مقارنة بالصورة الأصلية.

3.3 معالجة الرسم البياني التكراري

(HISTOGRAM PROCESSING 3.3)

لتكن r_k (حيث $k = 0, 1, 2, \dots, L-1$) تمثل مستويات الكثافة لصورة رقمية $f(x, y)$ ذات L مستوى.

يُعرّف الرسم البياني التكراري غير المعايير (Unnormalized histogram) للصورة f بالمعادلة:

$$h(r_k) = n_k \quad \text{for } k = 0, 1, 2, \dots, L-1$$

حيث:

n_k : هو عدد البكسلات في الصورة التي تمتلك مستوى الكثافة r_k .

التقسيمات الفرعية لمقياس الكثافة تُسمى خانات التكرار (Histogram bins).

الرسم البياني التكراري المعياري (Normalized Histogram)

يُعرّف الرسم البياني التكراري المعياري بالمعادلة:

$$p(r_k) = \frac{h(r_k)}{MN} = \frac{n_k}{MN} \quad \text{حيث:}$$

M و N : هما عدد صفوف أعمدة الصورة بالترتيب (إجمالي عدد البكسلات MN).

غالباً ما نتعامل مع الهستوجرام المعياري. مجموع $p(r_k)$ لجميع قيم k يساوي دائماً 1.

تُمثل مكونات $p(r_k)$ تقديراً لـ احتمالية (Probability) حدوث مستوى الكثافة r_k في الصورة.

أهمية التلاعب بهستوجرام

تعد معالجة الهستوجرام أداة أساسية في معالجة الصور لأنها:

سهلة وبسيطة الحساب حسابياً.

مناسبة للتنفيذ البرمجي والمادي السريع (Hardware implementation)، مما يجعلها شهيرة في المعالجة الآلية وفي الوقت الفعلي (Real-time image processing).

العلاقة بظهور الصورة:

شكل الهستوجرام يرتبط مباشرة بمظهر الصورة:


الصورة الداكنة (Dark image): تتجمع معظم خانات الهستوجرام عند الطرف الأدنى (الداكن) لمقياس الكثافة.

الصورة الساطعة (Light image): تتناثر خانات الهستوجرام نحو الطرف الأعلى الساطع.

الصورة منخفضة التباين (Low contrast): تمتلك هستوجرام ضيقاً ومتركزاً في أجزاء محددة.

معالجة الرسم البياني التكراري (تابع 3.3)

وصف الشكل 3.16 (FIGURE 3.16):



أربعة أنواع من الصور مع الرسوم البيانية التكرارية (الهستوجرام) المناظرة لها:

(a) صورة داكنة (Dark).

(b) صورة ساطعة (Light).

(c) صورة منخفضة التباين (Low contrast).

(d) صورة عالية التباين (High contrast).

المحور الأفقي للهستوجرام يمثل قيم r_k (الكثافة)، والمحور الرأسي يمثل قيم $p(r_k)$ (الاحتمالية).

تحليل أنواع الصور والتباين (Page 134)

...يكون الهستوجرام عادةً متمركزاً نحو منتصف مقياس الكثافة، كما يوضح الشكل 3.16(c). بالنسبة لصورة أحادية اللون (Monochrome)، يمنح هذا المظهر لوناً رمادياً باهتاً ومملاً (Washed-out gray look).

أخيراً، نلاحظ أن مكونات الهستوجرام في الصورة عالية التباين تغطي نطاقاً واسعاً من مقياس الكثافة:

توزيع البكسلات ليس بعيداً عن التوزيع المنتظم (Uniform distribution).

عدد قليل فقط من الخانات (Bins) يكون أعلى بكثير من الخانات الأخرى.

النتيجة البديهية:

الصورة التي تميل بكسلاتها إلى شغل كامل نطاق مستويات الكثافة المتاحة، وتتوزع بشكل منتظم تقريباً، ستنمط بمظهر عالي التباين وتظهر تنوعاً كبيراً في درجات اللون الرمادي.

النتيجة الصافية هي صورة تظهر قدراً كبيراً من تفاصيل التدرج الرمادي وتمتلك مدى ديناميكياً عالياً (High dynamic range). وكما ستلاحظين قريباً، من الممكن تطوير دالة تحويل لتحقيق هذا التأثير تلقائياً باستخدام هستوجرام الصورة المدخلة فقط.

مساواة الهستوجرام

(HISTOGRAM EQUALIZATION)

بافتراض أن قيم الكثافة مستمرة أولاً، لتمثل المتغير r كثافة الصورة المراد معالجتها.

كما هو معتاد، نفترض أن r تقع في النطاق $[0, L-1]$:

حيث $r = 0$ يمثل اللون الأسود.

و $r = L-1$ يمثل اللون الأبيض.

بالنسبة للشروط التي تلبي r ، نركز اهتمامنا على التحويلات (رسم الخرائط للكثافة) التي تكون على الصورة:


$$s = T(r) \quad 0 \leq r \leq L-1$$

(تابع الصفحة 135)

وصف الشكل 3.17 (FIGURE 3.17):

(a) دالة متزايدة بانتظام (Monotonic increasing)، توضح كيف يمكن رسم قيم متعددة إلى قيمة واحدة.

FIGURE 3.17
(a) Monotonic increasing function, showing how multiple values can map to a single value. (b) Strictly monotonic increasing function. This is a one-to-one mapping, both ways.



(b) دالة متزايدة بانتظام بصرامة (Strictly monotonic increasing)، وتوفر رسم خطي تناظري (One-to-one mapping) في كلا الاتجاهين.

تنتج هذه الدالة قيمة كثافة للخرج s مقابل قيمة كثافة معينة r في صورة الدخل. نفترض الشروط التالية:

الشرط (a): الدالة $T(r)$ هي دالة متزايدة بانتظام (Monotonic increasing) في الفترة $0 \leq r \leq L-1$.

الشرط (b): القيمة $0 \leq T(r) \leq L-1$ بالنسبة لـ $0 \leq r \leq L-1$.

في بعض الصياغات، نستخدم التحويل العكسي (Inverse transformation):

$$r = T^{-1}(s) \quad 0 \leq s \leq L-1$$

وفي هذه الحالة نغير الشرط (a) إلى:

الشرط (a'): الدالة $T(r)$ هي دالة متزايدة بانتظام بصرامة (Strictly monotonic increasing) في الفترة $0 \leq r \leq L-1$.

أهمية الشروط:

الشرط (a): يضمن عدم انخفاض قيم كثافة الخرج عن قيم الدخل المناظرة، مما يمنع ظهور عيوب ناتجة عن انعكاس الكثافة. (Reversals of intensity).

الشرط (b): يضمن أن مدى كثافات الخرج هو نفس مدى كثافات الدخل.

الشرط (a'): يضمن أن التحويل من s عودة إلى r سيكون تناظرياً (One-to-one)، مما يمنع الغموض (Ambiguities).

توضيح الشكل 3.17:

في الشكل 3.17(a): تحقق الدالة الشرطين (a) و (b). نرى أنه من الممكن لقيم دخل متعددة أن ترتبط بقيمة خرج واحدة. هذه الدالة تنفذ عملية تناظر من r إلى s فقط، لكنها تطرح مشكلة إذا أردنا استعادة قيم r بشكل فريد من قيم s (الربط العكسي).

تعكس الأسهم في الشكل 3.17(a) هذه المشكلة؛ حيث أن التناظر العكسي لـ s_k يعطي نطاقاً من القيم، مما يمنع استعادة قيمة r الأصلية بدقة.

في الشكل 3.17(b): تظهر دالة متزايدة بصرامة تحقق الشرط (a')، حيث كل قيمة لـ s ترتبط بقيمة واحدة فريدة لـ r والعكس صحيح.

معالجة الرسم البياني التكراري (تابع 3.3)

الشرط الترتيب والتمثيل الرقمي (Page 136)

...في s_k . كما يوضح الشكل 3.17(b)، فإن اشتراط أن تكون $T(r)$ متزايدة بانتظام بصرامة (strictly monotonic) يضمن أن التحويلات العكسية ستكون أحادية القيمة (single valued) (أي أن التناظر أحادي لربط الطرفين بشكل دقيق).

هذا مطلب نظري يتيح لنا اشتقاق بعض تقنيات معالجة الهستوجرام المهمة لاحقاً في هذا الفصل. ولأن الصور يتم تخزينها باستخدام قيم كثافة صحيحة (integers)، فنحن مضطرون لتقريب جميع النتائج إلى أقرب قيم صحيحة مجاورة.

غالباً ما يؤدي ذلك إلى عدم تحقق شرط التزايد المنتظم بصرامة، مما يعني وجود تحويلات عكسية قد لا تكون فريدة. لحسن الحظ، ليس من الصعب التعامل مع هذه المشكلة في الحالة المنفصلة (discrete case)، كما يوضح المثال 3.7 في هذا القسم.

الاشتراطات الإحصائية والدالة الكثافية الاحتمالية (PDF)

يمكن النظر إلى كثافة الصورة على أنها متغير عشوائي (random variable) في الفترة $[0, L-1]$.

لتكن $p_r(r)$ و $p_s(s)$ تمثلاً لدالتى الكثافة الاحتمالية (PDFs) لقيم الكثافة r و s في صورتين مختلفتين:

ترمز الرموز السفلية على p إلى أن p_r و p_s هما دالتان مختلفتان.

إحدى النتائج الأساسية في نظرية الاحتمالات هي أنه إذا كانت $p_r(r)$ و $T(r)$ معروفين، وكانت $T(r)$ مستمرة ومستقرة على نطاق القيم المهتم بها، فإن دالة الكثافة الاحتمالية للمتغير المحول s يمكن الحصول عليها بالمعادلة:

$$p_s(s) = p_r(r) \left| \frac{dr}{ds} \right| \quad \text{quad}$$

وهكذا نرى أن دالة الكثافة الاحتمالية لكثافة الخرج s تتحدد من خلال دالة الكثافة الاحتمالية لدخل الكثافات ودالة التحويل المستخدمة (مع التذكير بأن r و s ترتبطان بـ $T(r)$).

دالة التوزيع التراكمي (CDF)

دالة تحويل ذات أهمية خاصة في معالجة الصور هي:

$$s = T(r) = (L-1) \int_0^r p_r(w) \, dw \quad \text{quad}$$

حيث:

(dummy variable of integration) متغير وهمي للتكامل w :

التكامل في الطرف الأيمن هو دالة التوزيع التراكمي (CDF) للمتغير العشوائي r .

خصائص هذه الدالة:

بما أن دالة الكثافة الاحتمالية $p_r(w)$ موجبة دائماً، والتكامل يمثل المساحة تحت الدالة، فإن دالة التحويل في المعادلة (11-3) تلبى الشرط (a)؛ لأن المساحة تحت دالة موجبة لا يمكن أن تنقص مع زيادة r .

عندما يكون الحد الأعلى للتكامل هو $r = L-1$ ، فإن قيمة التكامل تساوي 1 (كما يجب بالنسبة لـ PDF). وبالتالي تكون القيمة القصوى لـ s هي $L-1$ ، ويتحقق الشرط (b) أيضاً.

معالجة الرسم البياني التكراري (تابع)

إثبات التوزيع المنتظم (Page 138)

افترضنا أننا شكلنا صورة جديدة بكثافات s تم الحصول عليها باستخدام هذا التحويل؛ أي أن قيم s تتشكل بطرب تربيع قيم الكثافة المناظرة لصورة الدخل، ثم قسمتها على $(L-1)$.

يمكننا التحقق من أن دالة الكثافة الاحتمالية للكثافات في الصورة الجديدة $p_s(s)$ هي منتظمة عن طريق تعويض $p_r(r)$ في المعادلة (13-3)، واستخدام حقيقة أن:

$$s = r^2 / (L-1)$$

خطوات الاشتقاق الرياضي:

$$| p_s(s) = p_r(r) * | dr / ds$$

$$| p_r(r) * | 1 / (ds / dr) =$$

$$[d/dr (r^2 / (L - 1))]^{-1} * [(L - 1)^{2/2r}] =$$

$$[(L - 1) / (2r)] * [(L - 1)^{2/2r}] =$$

$$(L - 1) / 1 =$$

الخطوة الأخيرة تتحقق لأن r غير سالبة و L أكبر من 1. وكما هو متوقع، فإن النتيجة هي دالة كثافة احتمالية (PDF) منتظمة.

المعالجة في الحالة المنفصلة (Discrete Values)

بالنسبة للقيم المنفصلة، نعمل مع الاحتمالات والمجاميع بدلاً من دوال الكثافة الاحتمالية والتكاملات (لكن شرط التزايد المنتظم المذكور سابقاً يظل سارياً).

تذكر أن احتمال ظهور مستوى الكثافة r_k في الصورة الرقمية يُقرب بالمعادلة:

$$p_r(r_k) = n_k / MN \quad \text{--- (المعادلة 14-3)}$$

حيث:

MN : هو إجمالي عدد البكسلات في الصورة.

n_k : هو عدد البكسلات التي تمتلك مستوى الكثافة r_k .

$p_r(r_k)$ مع r_k تنتمي إلى الفترة $[0, L - 1]$ يُشار إليها باسم الرسم البياني التكراري المعايير للصورة.

الشكل المنفصل لدالة التحويل (المعادلة 11-3) هو:

$$s_k = T(r_k) = (L - 1) * \sum_{j=0}^k p_r(r_j) \quad \text{for } k = 0, 1, 2, \dots, L - 1 \quad \text{--- (المعادلة 3-15)}$$

(ملاحظة: Sum تعني مجموع العناصر من $j=0$ إلى k).

حيث L هو عدد مستويات الكثافة المحتملة في الصورة (مثلاً 256 لصورة 8-بت). وبالتالي يتم الحصول على الصورة المعالجة بنقل كل بكسل في صورة الدخل ذي الكثافة r_k إلى بكسل مناظر بقيمة s_k في صورة الخرج.

يسمى هذا بـ مساواة الهستوجرام (Histogram equalization) أو تحويل خطية الهستوجرام (Histogram linearization transformation).

مثال 3.5: توضيح آلية عمل مساواة الهستوجرام

(EXAMPLE 3.5: Illustration of the mechanics of histogram equalization)

سيكون من المفيد تطبيق مثال بسيط. افترض أن لدينا صورة 3-بت (أي $L = 8$) وبحجم 64×64 بكسل (إجمالي البكسلات $MN = 4096$) تمتلك توزيع الكثافة الموضح في الجدول 3.1.

مستويات الكثافة هي أعداد صحيحة في النطاق $[0, 7] = [L - 1, 0]$.

تتم معالجة القيم باستخدام المعادلة (3-15)، على سبيل المثال:

$$s_0 = T(r_0) = 7 * p_r(r_0) = 7 * 0.19 = 1.33$$

(تابع الصفحة 139)

الجدول 3.1: توزيع الكثافة وقيم الهستوجرام لصورة رقمية 3-بت بحجم 64×64

r_k	n_k	$p_r(r_k) = n_k / MN$
$r_0 = 0$	790	0.19
$r_1 = 1$	1023	0.25
$r_2 = 2$	850	0.21
$r_3 = 3$	656	0.16
$r_4 = 4$	329	0.08
$r_5 = 5$	245	0.06
$r_6 = 6$	122	0.03
$r_7 = 7$	81	0.02

الحسابات والتقريب لأقرب عدد صحيح:

وبالمثل، نحسب بقية القيم:

$$s_1 = T(r_1) = 3.08$$

$$s_2 = 4.55$$

$$s_3 = 5.67$$

$$s_4 = 6.23$$

$$s_5 = 6.65$$

$$s_6 = 6.86$$

$$s_7 = 7.00$$

تأخذ دالة التحويل هذه شكل الدرجات (Staircase shape) الموضح في الشكل 3.19(b).

عند هذه النقطة، تكون قيم s كسورية لأنها ناتجة عن جمع قيم الاحتمالات، لذلك نقوم بتقريبها إلى أقرب عدد صحيح في النطاق $[7, 0]$:

$$s_0 = 1.33 \rightarrow \text{تقرب إلى 1}$$

$$s_1 = 3.08 \rightarrow \text{تقرب إلى 3}$$

$$s_2 = 4.55 \rightarrow \text{تقرب إلى 5}$$

$$s_3 = 5.67 \rightarrow \text{تقرب إلى 6}$$

$$s_4 = 6.23 \rightarrow \text{تقرب إلى 6}$$

$$s_5 = 6.65 \rightarrow \text{تقرب إلى 7}$$

$$s_6 = 6.86 \rightarrow \text{تقرب إلى 7}$$

$$s_7 = 7.00 \rightarrow \text{تقرب إلى 7}$$

تحليل النتائج:

هذه هي قيم الهستوجرام المعادل. نلاحظ أن التحويل نتج عنه خمسة مستويات كثافة متميزة فقط:

القيمة $r_0 = 0$ ارتبطت بالقيم $s_0 = 1$ ، فهناك 790 بكسل تمتلك هذه القيمة.

هناك 1023 بكسل بقيمة $s_1 = 3$.

هناك 850 بكسل بقيمة $s_2 = 5$.

كل من r_3 و r_4 ارتبطا بنفس القيمة (6)، لذا يوجد (656 + 329 = 985 بكسل) بقيمة 6.

وبالمثل، r_5 و r_6 و r_7 ارتبطت القيمة (7)، فيوجد (245 + 122 + 81 = 448 بكسل) بقيمة 7.


قسمة هذه الأرقام على $MN = 4096$ يعطي الهستوجرام المعادل الموضح في الشكل 3.19(c).

وصف الشكل 3.19 (FIGURE 3.19):

(a) الهستوجرام الأصلي للصورة.

(b) دالة التحويل (المساواة).

(c) الهستوجرام المعادل الناتج.



خصائص مساواة الهستوجرام (Page 140)

... هذا القسم يقدم نهجاً لإزالة هذا القيد. ومع ذلك، وكما ستلاحظين قريباً، فإن استخدام المعادلة (3-15) يمتلك ميلاً عاماً لنشر رسم الصورة البياني التكراري بحيث تغطي مستويات كثافة الصورة المعادلة نطاقاً أوسع من مقياس الكثافة. والنتيجة الصافية هي تحسين التباين (Contrast enhancement).

ناقشنا سابقاً مزايا وجود قيم كثافة تمتد عبر كامل المقياس الرمادي. الطريقة المشتقة للتو تنتج كثافات تمتلك هذا الميل، كما أنها تتميز بكونها تلقائية بالكامل (Fully automatic).

بمعنى آخر، تتكون عملية مساواة الهستوجرام من تنفيذ المعادلة (3-15) المستندة إلى معلومات يمكن استخراجها مباشرة من الصورة المعطاة، دون الحاجة إلى مواصفات أو معاملات إضافية من المستخدم. هذه الخاصية التلقائية واللايدوية مهمة جداً.

التحويل العكسي

يُرمز للتحويل العكسي من s عودة إلى r بالمعادلة:

$$r_k = T^{-1}(s_k) \quad \text{--- (المعادلة 3-16)}$$

يمكن إثبات أن هذا التحويل العكسي يلبي الشرطين (a') و (b) المذكورين سابقاً فقط إذا كانت جميع مستويات الكثافة موجودة في صورة الدخل.

وهذا يضمن عدم وجود أي خانة فارغة في هستوجرام الصورة. وعلى الرغم من أن التحويل العكسي لا يُستخدم في مساواة الهستوجرام نفسها، إلا أنه يلعب دوراً محورياً في مخطط مطابقة الهستوجرام (Histogram matching) المطور لاحقاً.

مثال 3.6: مساواة الهستوجرام

(EXAMPLE 3.6: Histogram equalization)

العمود الأيسر في الشكل 3.20: يعرض الصور الأربع من الشكل 3.16.

العمود الأوسط: يعرض نتيجة تطبيق مساواة الهستوجرام على كل صورة من هذه الصور.

أظهرت النتائج الثلاث الأولى من الأعلى إلى الأسفل تحسناً كبيراً. وكما هو متوقع، لم يكن لمساواة الهستوجرام تأثير كبير على الصورة الرابعة لأن كثافتها تغطي بالفعل النطاق الكامل تقريباً.

يعرض الشكل 3.21 دوال التحويل المستخدمة لتوليد الصور المعادلة في الشكل 3.20 (تم توليدها باستخدام المعادلة 3-15). نلاحظ أن التحويل (4) خطي تقريباً، مما يشير إلى أن مدخلاته تم رسمها لقيم خروج مساوية لها تقريباً.

تحليل النتائج:

يظهر الرسم التوضيحي ربط قيمة الدخل r_k بقيمة الخرج المناظرة s_k .

في الصورة 1 (أعلى اليسار في الشكل 3.21)، تم نقل قيمة داكنة إلى قيمة أسطع بكثير، مما ساهم في زيادة سطوع الصورة الناتجة.

العمود الثالث في الشكل 3.20:

يعرض الرسوم البيانية التكرارية للصور المعادلة. في حين أن جميع الهستوجرامات الأصلية كانت مختلفة، فإن الهستوجرامات المعادلة أصبحت متشابهة جداً بانياً.

هذا ليس غير متوقع؛ لأن الاختلاف الأساسي بين الصور في العمود الأيسر هو التباين وليس المحتوى. ولأن الصور لها نفس المحتوى، كانت الزيادة في التباين الناتجة عن مساواة الهستوجرام كافية لجعل أي اختلافات في الكثافة بين الصور المعادلة غير مميزة بصرياً.

يوضح هذا المثال قوة مساواة الهستوجرام كأداة تكيفية وتلقائية لتحسين التباين.

مطابقة الهستوجرام (تحديد الهستوجرام)

(HISTOGRAM MATCHING - SPECIFICATION)

كما تم التوضيح في القسم السابق، تنتج مساواة الهستوجرام دالة تحويل تسعى لتوليد صورة خرج ذات هستوجرام منتظم. عندما يكون التحسين التلقائي مطلوباً، يعد هذا نهجاً ممتازاً لأن...

(تابع الصفحة 141)

وصف الشكل 3.20 (FIGURE 3.20):





FIGURE 3.20 Left column: Images from Fig. 3.16. Center column: Corresponding histogram-equalized images. Right column: histograms of the images in the center column (compare with the histograms in Fig. 3.16).

العمود الأيسر: الصور من الشكل 3.16.

العمود الأوسط: الصور المناظرة بعد تطبيق مساواة الهستوجرام.

العمود الأيمن: الرسوم البيانية التكرارية (الهستوجرام) للصور في العمود الأوسط (قارنوها مع الهستوجرامات في الشكل 3.16).



وصف الشكل 3.21 (FIGURE 3.21):

دوال التحويل الخاصة بمساواة الهستوجرام.

التحويلات من (1) إلى (4) تم الحصول عليها باستخدام المعادلة (3-15) وهستوجرامات الصور في العمود الأيسر للشكل 3.20.

يظهر في الرسم توضيح لربط قيمة كثافة دخل معينة r_k في الصورة 1 بقيمة s_k المناظرة لها.

الداعي لمطابقة الهستوجرام (Page 142)

...النتائج من هذه التقنية يمكن التنبؤ بها، والطريقة بسيطة التنفيذ.

ومع ذلك، هناك تطبيقات لا تكون فيها مساواة الهستوجرام مناسبة. بشكل خاص، يكون من المفيد أحياناً التمكن من تحديد شكل الهستوجرام الذي نرغب أن تتمتع به الصورة المعالجة. الطريقة المستخدمة لتوليد صور تمتلك هستوجراماً محدداً تُسمى مطابقة الهستوجرام (Histogram matching) أو تحديد الهستوجرام (Histogram specification).

لنفرض للحظة وجود كثافات مستمرة r و z ، وكما في السابق، نتعامل معها كمتغيرات عشوائية بذات دالة كثافة احتمالية $p_r(r)$ و $p_z(z)$ على التوالي:

هنا نرمز r و z إلى مستويات الكثافة لصورتَي الدخل والخرج (المعالجة) على التوالي.

يمكننا تقدير $p_r(r)$ من صورة الدخل المعطاة.

$p_z(z)$ هي دالة الكثافة الاحتمالية المحددة (المطلوبة) التي نرغب أن تتمتع بها صورة الخرج.

المعادلات الأساسية لمطابقة الهستوجرام

ليكن s متغيراً عشوائياً يمتلك الخاصية:

$$s = T(r) = (L - 1) * \int_0^r p_r(w) dw \quad \text{--- (المعادلة 3-17)}$$

حيث w هو متغير وهمي للتكامل (وهي نفس المعادلة 3-11 ونكررها هنا للتسهيل).

نعرف دالة G على المتغير z بالخاصية:

$$G(z) = (L - 1) * \int_0^z p_z(v) dv = s \quad \text{--- (المعادلة 3-18)}$$

حيث v هو متغير وهمي للتكامل.

يستنتج من المعادلتين السابقين أن $G(z) = s = T(r)$ ، وبالتالي يجب أن يحقق z الشرط:

$$z = G^{-1}(s) = G^{-1}[T(r)] \quad \text{--- (المعادلة 19-3)}$$

خطوات تطبيق مطابقة الهستوجرام (Page 143)

يمكن الحصول على دالة التحويل $T(r)$ باستخدام المعادلة (17-3) بعد تقدير $p_r(r)$ باستخدام صورة الدخل. وبالمثل، يمكن الحصول على الدالة $G(z)$ من المعادلة (18-3) لأن $p_z(z)$ تكون معطاة ومحددة.

تقتضي المعادلات من (17-3) إلى (19-3) أنه يمكن الحصول على صورة تقع مستويات كثافتها ضمن دالة كثافة احتمالية محددة $p_z(z)$ باتباع الإجراء التالي:

الخطوة 1: الحصول على $p_r(r)$ من صورة الدخل لاستخدامها في المعادلة (17-3).

الخطوة 2: استخدام دالة الكثافة الاحتمالية المحددة $p_z(z)$ في المعادلة (18-3) للحصول على الدالة $G(z)$.

الخطوة 3: حساب التحويل العكسي $z = G^{-1}(s)$ ؛ وهو ربط من s إلى z ، حيث تمثل الأخيرة القيم التي تمتلك PDF المحدد.

الخطوة 4: الحصول على صورة الخرج عن طريق مساواة صورة الدخل أولاً باستخدام المعادلة (17-3)؛ قيم البكسلات في هذه الصورة هي قيم s . ولكل بكسل بقيمة s في الصورة المعادلة، نطبق التحويل العكسي $z = G^{-1}(s)$ للحصول على البكسل المناظر في صورة الخرج. وعند معالجة جميع البكسلات بهذا التحويل، ستكون دالة الكثافة الاحتمالية لصورة الخرج $p_z(z)$ مساوية للـ PDF المحدد.

الصياغة المنفصلة (Discrete Formulation)

بما أن z ترتبط بـ r عن طريق $T(r)$ ، فمن الممكن للتعبير الذي ينتج z من r أن يكتب مباشرة بدلالة r . لكن بشكل عام، إيجاد تعبيرات تحليلية لـ G^{-1} ليس مهمة بسيطة. ولحسن الحظ، لا تمثل هذه مشكلة عند التعامل مع الكميات المنفصلة.

كما في السابق، يجب تحويل النتيجة المستمرة المشتقة للتو إلى صياغة منفصلة:

هذا يعني أننا نعمل مع الرسوم البيانية التكرارية بدلاً من دوال الكثافة الاحتمالية.

نفقد في التحويل القدرة على ضمان نتيجة تمتلك الهستوجرام المحدد بالضبط، ولكن على الرغم من ذلك، يمكن الحصول على نتائج مفيدة جداً حتى مع التقريبات.

الصياغة المنفصلة للمعادلة (17-3):

هي تحويل مساواة الهستوجرام المتمثل في المعادلة (15-3)، ونكرره هنا للتسهيل:

$$s_k = T(r_k) = (L - 1) * \sum_{j=0}^{k} p_r(r_j) \quad \text{for } k = 0, 1, 2, \dots, L - 1 \quad \text{--- (المعادلة 20)}$$

حيث مكونات هذه المعادلة كما تم تعريفها سابقاً.

وبالمثل، عند إعطاء قيمة محددة لـ s_q ، تتضمن الصياغة المنفصلة للمعادلة (18-3) حساب دالة التحويل:

$$G(z_q) = (L - 1) * \sum_{i=0}^{q} p_z(z_i) \quad \text{--- (المعادلة 21-3)}$$

لقيمة z_q بحيث يكون:

$$G(z_q) = s_k \quad \text{--- (المعادلة 22-3)}$$

حيث $p_z(z_i)$ هي القيمة رقم i للهستوجرام المحدد. وأخيراً، نحصل على قيمة z_q المطلوبة من التحويل العكسي.

$$z_q = G^{-1}(s_k) \text{ --- (المعادلة 23-3)}$$

عند تطبيق هذه العملية على جميع البكسلات، يكون ذلك بمثابة تحويل من قيم s في الصورة المعادلة بالهستوجرام إلى قيم z المناظرة لها في صورة الخرج.

في التطبيق العملي، لا توجد حاجة لحساب المعكوس الفعلي للدالة G :

بما أننا نتعامل مع مستويات كثافة عبارة عن أعداد صحيحة، فمن السهل حساب جميع القيم المحتملة للدالة G باستخدام المعادلة (21-3) لجميع القيم $q = 0, 1, 2, \dots, L - 1$.

يتم تقريب هذه القيم إلى أقرب عدد صحيح يقع في النطاق $[0, L - 1]$ وتُخزن في جدول بحث (Lookup table).

بعد ذلك، ولأي قيمة معطاة لـ s_k ، نبحث عن أقرب مطابقة لها في الجدول.

مثال للتوضيح:

إذا كانت الخانة رقم 27 في الجدول هي القيمة الأقرب لـ s_k ، فإن $q = 26$ (مع التذكير ببدء التعداد من 0)، وتكون z_26 هي أفضل حل للمعادلة (23-3).

وبالتالي، فإن القيمة s_k ترتبط بالقيمة z_26 . وبما أن قيم z هي أعداد صحيحة في النطاق $[0, L - 1]$ ، فيستتبع ذلك أن $z_0 = 0$ و $z_{(L-1)} = L - 1$ وبشكل عام $z_q = q$. لذلك ستكون z_26 مساوية لقيمة الكثافة 26.

نكرر هذه الإجراءات لإيجاد الربط بين كل قيمة لـ s_k وقيمة z_q التي تمثل أقرب مطابقة لها في الجدول. هذه الربطات تمثل الحل لمشكلة تحديد/مطابقة الهستوجرام.

خوارزمية تحديد الهستوجرام المنفصل (Summary of Steps)

عند إعطاء صورة دخل، وهستوجرام محدد $p_z(z_i)$ لـ $i = 0, 1, 2, \dots, L - 1$ ، ومع التذكير بأن s_k هي القيم الناتجة عن المعادلة (20-3)، يمكننا تلخيص خطوات العملية كالتالي:

الخطوة 1: حساب الهستوجرام $p_r(r)$ لصورة الدخل، واستخدامه في المعادلة (20-3) لربط الكثافات في صورة الدخل بالكثافات في الصورة المعادلة بالهستوجرام. تقريب النتائج s_k إلى نطاق الأعداد الصحيحة $[0, L - 1]$.

الخطوة 2: حساب جميع قيم الدالة $G(z_q)$ باستخدام المعادلة (21-3) لـ $q = 0, 1, 2, \dots, L - 1$ ، حيث $p_z(z_i)$ هي قيم الهستوجرام المحدد. تقريب قيم G للأعداد الصحيحة في النطاق $[0, L - 1]$ وتخزين هذه القيم في جدول بحث (Lookup table).

الخطوة 3: لكل قيمة لـ s_k (حيث $k = 0, 1, 2, \dots, L - 1$)، استخدام القيم المخزنة لـ G من الخطوة 2 لإيجاد القيمة المناظرة لـ z_q بحيث تكون $G(z_q)$ هي الأقرب إلى s_k . تخزين هذه الربطات من s إلى z . وعندما تعطي أكثر من قيمة لـ z_q نفس المطابقة (أي أن الربط غير فريد)، يتم اختيار القيمة الأصغر اتفاقاً.

الخطوة 4: تشكيل الصورة المحددة بالهستوجرام عن طريق ربط كل بكسل معادل بقيمة s_k بالبكسل المناظر ذي القيمة z_q في الصورة الناتجة، باستخدام الربطات المكتشفة في الخطوة 3.

ملاحظة حول الشروط

كما في حالة الكثافات المستمرة، تُعد الخطوة المتوسطة لمساواة صورة الدخل مفهوماً نظرياً فقط؛ حيث يمكن تجاوزها عن طريق دمج دالتي التحويل T و G^{-1} معاً.

ذكرنا في بداية مناقشة مساواة الهستوجرام أنه بالإضافة إلى الشرط (b)، يجب أن تكون الدوال العكسية G^{-1} متزايدة بانتظام بصرامة لتلبية الشرط (a'). وبدلالة المعادلة (21-3)، هذا يعني أنه لا يمكن لأي قيمة $p_z(z_i)$ في الهستوجرام المحدد أن تكون صفراً. وعند عدم تحقق هذا الشرط، نلجأ للحل البديل المطبق في الخطوة 3.

مثال 3.7: توضيح آلية عمل تحديد الهستوجرام (Page 145)

(EXAMPLE 3.7: Illustration of the mechanics of histogram specification)

افتراضي وجود صورة افتراضية بحجم 64×64 بكسل من المثال 3.5، والتي يُعاد هستوجرامها في الشكل 3.22(a). المطلوب هو تحويل هذا الهستوجرام بحيث يمتلك القيم المحددة في العمود الثاني من الجدول 3.2. يوضح الشكل 3.22(b) هذا الهستوجرام المحدد.

الخطوة الأولى:

الحصول على قيم مساواة الهستوجرام (s_k)، والتي سبق حسابها في المثال 3.5:

$$s_0 = 1$$

$$s_1 = 3$$

$$s_2 = 5$$

$$s_3 = 6$$

$$s_4 = 6$$

$$s_5 = 7$$

$$s_6 = 7$$

$$s_7 = 7$$

الخطوة الثانية:

حساب قيم $G(z_q)$ باستخدام قيم $p_z(z_q)$ وتطبيق المعادلة (3-21):

$$G(z_0) = 0.00$$

$$G(z_1) = 0.00$$

$$G(z_2) = 1.05$$

$$G(z_3) = 2.45$$

$$G(z_4) = 4.55$$

$$G(z_5) = 5.95$$

$$G(z_6) = 7.00$$

$$G(z_7) = 7.00$$

التقريب لأقرب عدد صحيح في النطاق $[0, 7]$:

$$G(z_0) = 0.00 \text{ --- } \text{تقرب إلى } 0$$

$$G(z_1) = 0.00 \text{ --- } \text{تقرب إلى } 0$$

$$G(z_2) = 1.05 \text{ --- } \text{تقرب إلى } 1$$

$$G(z_3) = 2.45 \text{ --- } \text{تقرب إلى } 2$$

$$G(z_4) = 4.55 \text{ --- } \text{تقرب إلى } 5$$

$$G(z_5) = 5.95 \text{ --- } \text{تقرب إلى } 6$$

$$G(z_6) = 7.00 \text{ --- } \text{تقرب إلى } 7$$

$$G(z_7) = 7.00 \text{ --- } \text{تقرب إلى } 7$$

تُلخص هذه النتائج في الجدول 3.3. دالة التحويل $G(z_q)$ موضحة في الشكل 3.23(c).

نظراً لأن قيمها الثلاث الأولى متساوية، فإن G ليست متزايدة بانتظام بصرامة، وبالتالي يتم انتهاك الشرط (a'). نستخدم النهج الموضح في الخطوة 3 لإيجاد أصغر قيمة لـ z_q تجعل $G(z_q)$ الأقرب لـ s_k .


وصف الشكل 3.22 (FIGURE 3.22):

(a) الهستوجرام لصورة 3-بت.

(b) الهستوجرام المحدد (المطلوب).

(c) دالة التحويل المحصلة من الهستوجرام المحدد.

(d) نتيجة تطبيق تحديد الهستوجرام (قارني بين b و d).



الجدول 3.2: الهستوجرامات المحددة والحديثة الفعلية

(TABLE 3.2: Specified and actual histograms)

TABLE 3.2
Specified and
actual histograms
(the values in
the third column
are computed in
Example 3.7).

z_q	Specified $p_s(z_q)$	Actual $p_z(z_q)$
$z_0 = 0$	0.00	0.00
$z_1 = 1$	0.00	0.00
$z_2 = 2$	0.00	0.00
$z_3 = 3$	0.15	0.19
$z_4 = 4$	0.20	0.25
$z_5 = 5$	0.30	0.21
$z_6 = 6$	0.20	0.24
$z_7 = 7$	0.15	0.11

عملية الربط بين s و z (Page 146)

...قيمة s_k لتشكيل الربط المطلوب من s إلى z .

على سبيل المثال، $s_0 = 1$ ، ونرى أن $G(z_2) = 1$ ، وهي مطابقة تامة في هذه الحالة، وبالتالي نحصل على التوافق $s_0 \rightarrow z_2$.

كل بكسل قيمته 1 في الصورة المعادلة بهستوجرام سيتغير إلى بكسل قيمته 3 في الصورة المحددة بهستوجرام. وبمواصلة العمل بهذه الطريقة، نصل إلى الربط المدرجة في الجدول 3.4.

في الخطوة الأخيرة من الإجراء، نستخدم الربطات الموجودة في الجدول 3.4 لنقل كل بكسل في الصورة المعادلة بهستوجرام إلى بكسل مناظر في الصورة المحددة بالهستوجرام المنشأة حديثاً. تحليل نتائج الهستوجرام الناتج:

قيم الهستوجرام الناتج مدرجة في العمود الثالث من الجدول 3.2، والهستوجرام موضح في الشكل 3.22(d).

تم الحصول على قيم $p_z(z_q)$ باستخدام نفس الإجراء المتبع في المثال 3.5.

كمثال، نرى في الجدول 3.4 أن $r_0 = 1$ ترتبط بـ $z_0 = 3$ ، وهناك 700 بكسل في الصورة المعادلة بالهستوجرام بقيمة 1. بالتالي، فإن $p_z(z_3) = 790 / 4096 = 0.19$.

على الرغم من أن النتيجة النهائية في الشكل 3.22(d) لا تطابق الهستوجرام المحدد تماماً، إلا أن الاتجاه العام لنقل الكثافات نحو الطرف العالي من مقياس الكثافة قد تحقق بالتأكيد. وكما ذكرنا سابقاً، فإن الحصول على الصورة المعادلة بالهستوجرام كخطوة متوسطة يكون مفيداً...

الجدول 3.3: القيم المقربة لدالة التحويل $G(z_q)$

(TABLE 3.3: Rounded values of the transformation function $G(z_q)$)

histogram equalized image would map to a pixel valued 3 in the histogram-specified image. Continuin in this manner, we arrive at the mappings in Table 3.4.

In the final step of the procedure, we use the mappings in Table 3.4 to map every pixel in the histogram equalized image into a corresponding pixel in the newly created histogram-specified image. The values of the resulting histogram are listed in the third column of Table 3.2, and the histogram shown in Fig. 3.22(d). The values of $p_z(z_q)$ were obtained using the same procedure as in Example 3. For instance, we see in Table 3.4 that $s_4 = 1$ maps to $z_q = 3$, and there are 790 pixels in the histogram equalized image with a value of 1. Therefore, $p_z(z_3) = 790/4096 = 0.19$.

Although the final result in Fig. 3.22(d) does not match the specified histogram exactly, the general trend of moving the intensities toward the high end of the intensity scale definitely was achieved. As mentioned earlier, obtaining the histogram-equalized image as an intermediate step is useful for

TABLE 3.3
Rounded values
of the
transformation
function $G(z_q)$.

z_q	$G(z_q)$
$z_0 = 0$	0
$z_1 = 1$	0
$z_2 = 2$	0
$z_3 = 3$	1
$z_4 = 4$	2
$z_5 = 5$	5
$z_6 = 6$	6
$z_7 = 7$	7

شرح الإجراء، لكن هذا ليس ضرورياً دائماً. بدلاً من ذلك، يمكننا إدراج الربطات المباشرة من قيم r إلى s ومن s إلى z في جدول مكون من ثلاثة أعمدة. ثم نستخدم تلك الربطات لنقل بكسلات الصورة الأصلية مباشرة إلى بكسلات الصورة المحددة بالهستوجرام.

مثال 3.8: المقارنة بين مساواة الهستوجرام ومطابقة الهستوجرام

EXAMPLE 3.8: Comparison between histogram equalization and histogram (specification)

الشكل 3.23(a): يعرض صورة لقمر المريخ "فوبوس" (Phobos) المأخوذة بواسطة مسبار المريخ العالمي (NASA's Mars Global Surveyor).

الشكل 3.23(b): يعرض الهستوجرام الخاص بالشكل 3.23(a).

تتميز الصورة بوجود مناطق مظلمة كبيرة، مما يترتب عليه هستوجرام يتسم بتركيز كبير للبكسلات في الطرف المظلم من المقياس الرمادي.

للهولة الأولى، قد يستنتج المرء أن مساواة الهستوجرام ستكون نهجاً جيداً لتحسين هذه الصورة، بحيث تصبح التفاصيل في المناطق المظلمة أكثر وضوحاً. إلا أن المناقشة التالية توضح أن الأمر ليس كذلك.


الشكل 3.24(a): يعرض تحويل مساواة الهستوجرام [المعادلة (3-20)] المحصل عليه باستخدام الهستوجرام في الشكل 3.23(b).

الصفة الأكثر أهمية لدالة التحويل هذه هي سرعة ارتفاعها من مستوى الكثافة 0 إلى مستوى قريب من 190. السبب في ذلك هو التركيز الكبير للبكسلات في دخل الصورة التي تحتوي على مستويات قريبة من 0. وعند تطبيق هذا التحويل على مستويات صورة الدخل للحصول على نتيجة معادلة الهستوجرام، يكون التأثير الصافي هو ربط نطاق ضيق جداً من البكسلات المظلمة إلى...


وصف الشكل 3.23 (FIGURE 3.23):

(a) صورة قمر المريخ.

(b) الهستوجرام الخاص بالصورة z.



وصف الشكل 3.24 (FIGURE 3.24):



(a) تحويل مساواة الهستوجرام المكتسب باستخدام الهستوجرام في الشكل 3.23(b).

(b) الصورة المعادلة بالهستوجرام.

(c) الهستوجرام الخاص بالصورة المعادلة.

تحليل نتائج مساواة الهستوجرام (Page 148)

...الطرف العالي من المقياس الرمادي لصورة الخرج. ولأن العديد من البكسلات في صورة الدخل تمتلك مستويات تقع بدقة في هذا النطاق، نتوقع أن تكون النتيجة صورة ذات مظهر فاتح وباهت (washed-out).

كما يوضح الشكل 3.24(b)، فإن هذا هو ما حدث بالفعل. الهستوجرام الخاص بهذه الصورة موضح في الشكل 3.24(c). لاحظي كيف انحازت جميع مستويات الكثافة نحو النصف الأعلى من المقياس الرمادي.


بما أن المشكلة مع دالة التحويل في الشكل 3.24(a) كانت بسبب التركيز الكبير للبكسلات في الصورة الأصلية عند مستويات قريبة من 0، فإن النهج المعقول هو تعديل هستوجرام تلك الصورة بحيث لا يمتلك هذه الخاصية.

يوضح الشكل 3.25(a) دالة محددة يدوياً تحافظ على الشكل العام للهستوجرام الأصلي، ولكنها تمتلك انتقالات أكثر سلاسة لمستويات الكثافة في المنطقة المظلمة من المقياس الرمادي.

أنتج العينات المنفصلة لهذه الدالة عند 256 قيمة متساوية البعد الهستوجرام المحدد المطلوب.

تحليل دوال التحويل والمعكوس:

دالة التحويل $G(z_q)$ المحصل عليها من هذا الهستوجرام باستخدام المعادلة (3-21) مُشار إليها بـ التحويل (1) في الشكل 3.25(b).



وبالمثل، التحويل العكسي $G^{-1}(s_k)$ من المعادلة (3-23) (باستخدام الخطوات المتسلسلة المذكورة سابقاً) مُشار إليه بـ التحويل (2) في الشكل 3.25(b).

تم الحصول على الصورة المحسنة في الشكل 3.25(c) بتطبيق التحويل (2) على بكسلات الصورة المعادلة بالهستوجرام الموضحة في الشكل 3.24(b).

تحسن الصورة المحددة بالهستوجرام مقارنة بالنتيجة المحصل عليها بمساواة الهستوجرام يظهر بوضوح عند المقارنة بين هاتين الصورتين. ومن المثير للاهتمام ملاحظة أن تغييراً بسيطاً في الهستوجرام الأصلي كان كل ما يلزم للحصول على تحسن كبير في المظهر.

يعرض الشكل 3.25(d) الهستوجرام الخاص بالشكل 3.25(c). الميزة الأكثر تميزاً لهذا الهستوجرام هي كيفية انزياح طرفه الأدنى نحو المنطقة الأسطع من المقياس الرمادي (ولكن ليس بشكل مفرط)، تماماً كما هو مطلوب.

(تابع الصفحة 149)

وصف الشكل 3.25 (FIGURE 3.25):

(a) الهستوجرام المحدد.

(b) دالة التحويل $G(z_q)$ المشار إليها بـ (1)، والتحويل العكسي $G^{-1}(s_k)$ المشار إليه بـ (2).

(c) نتيجة تحديد الهستوجرام.

(d) الهستوجرام الخاص بالصورة (c).

معالجة الهستوجرام المحلية (LOCAL HISTOGRAM PROCESSING)

طرق معالجة الهستوجرام المناقشة حتى الآن هي طرق عالمية/شاملة (Global)، بمعنى أن البكسلات تُعدل بواسطة دالة تحويل تعتمد على توزيع الكثافة للصورة بأكملها.

هذا النهج العالمي مناسب للتحسين العام، ولكنه يفشل عموماً عندما يكون الهدف هو تحسين التفاصيل عبر مناطق صغيرة في الصورة. السبب في ذلك هو أن عدد البكسلات في المناطق الصغيرة يكون له تأثير مهم على حساب التحويلات العالمية.

الحل هو ابتكار دوال تحويل تعتمد على توزيع الكثافة في مجاورات البكسل (Pixel neighborhoods).

يمكن تكييف تقنيات معالجة الهستوجرام الموصوفة سابقاً مع التحسين المحلي. الإجراء يتلخص في تحديد مجاورة وتحريك مركزها من

معالجة الهستوجرام المحلية (Page 150)

...بكسل إلى بكسل في اتجاه أفقية أو رأسية.

عند كل موقع، يُحسب الهستوجرام للنقاط الواقعة في المجاورة، وتُشتق منها دالة تحويل مساواة الهستوجرام أو دالة تحويل تحديد الهستوجرام. تُستخدم هذه الدالة لربط كثافة البكسل المتمركز في المجاورة.

بعد ذلك، يُنقل مركز المجاورة إلى موقع بكسل مجاور وتُكرر العملية.

وبما أن صفّاً واحداً أو عموداً واحداً فقط من المجاورة يتغير في الانتقال بمقدار بكسل واحد، فمن الممكن تحديث الهستوجرام المحصل عليه في الموقع السابق مع البيانات الجديدة المضافة في كل خطوة حركة (انظري المشكلة 3.14).

هذا النهج له مزايا واضحة مقارنة بحساب هستوجرام جميع البكسلات في منطقة المجاورة بشكل مكرر في كل مرة تتحرك فيها المنطقة موقع بكسل واحد.

نهج آخر يُستخدم أحياناً لتقليل الحسابات هو استخدام مناطق غير متداخلة (Nonoverlapping regions)، ولكن هذه الطريقة تنتج عادةً تأثيراً كتلويّاً (blocky effect) غير مرغوب فيه.

مثال 3.9: مساواة الهستوجرام المحلية

(EXAMPLE 3.9: Local histogram equalization)


الشكل 3.26(a): عبارة عن صورة 8-بت بحجم 512×512 بكسل تتكون من خمسة مربعات سوداء على خلفية رمادية فاتحة. الصورة بها ضوضاء خفيفة، لكن الضوضاء غير ملحوظة. هناك كائنات مدمجة داخل المربعات السوداء، لكنها غير مرئية لجميع الأغراض العملية.

الشكل 3.26(b): هو نتيجة تطبيق مساواة الهستوجرام الشاملة/العالمية (Global histogram equalization). أظهرت الصورة تحسناً كبيراً في الضوضاء، ولكن بخلاف الضوضاء، لا يكشف الشكل 3.26(b) عن أي تفاصيل جديدة مهمة من الصورة الأصلية.

الشكل 3.26(c): تم الحصول عليه باستخدام مساواة الهستوجرام المحلية (Local histogram equalization) للشكل 3.26(a) مع مجاورة بحجم 3×3 . هنا نرى تفاصيل مهمة داخل جميع المربعات السوداء.

قيم الكثافة لهذه الكائنات قريبة جداً من كثافة المربعات السوداء، وأحجامها صغيرة جداً بحيث لا تؤثر على مساواة الهستوجرام الشاملة بشكل كافٍ لإظهار هذا المستوى من تفاصيل الكثافة.

وصف الشكل 3.26 (FIGURE 3.26):



(a) الصورة الأصلية.

(b) نتيجة تطبيق مساواة الهستوجرام الشاملة.

(c) نتيجة تطبيق مساواة الهستوجرام المحلية.

استخدام إحصائيات الهستوجرام لتحسين الصور

(USING HISTOGRAM STATISTICS FOR IMAGE ENHANCEMENT)

يمكن استخدام الإحصائيات المكتسبة مباشرة من هستوجرام الصورة لتحسين الصورة.

لتكن r ترمز إلى متغير عشوائي منفصل يمثل قيم الكثافة في النطاق $[0, L - 1]$ ، ولتكن $p(r_i)$ ترمز إلى مكون الهستوجرام المعايير المناظر لقيمة الكثافة r_i . وكما أشرنا سابقاً، يمكننا النظر إلى $p(r_i)$ كتقدير لاحتمالية ظهور الكثافة r_i في الصورة التي تم الحصول على الهستوجرام منها.

(تابع الصفحة 151)

العزوم الرياضية والمعدل والتباين (Moments, Mean, and Variance)

لصورة ذات مستويات كثافة في النطاق $[0, L - 1]$ ، يُعرف العزم رقم n للمتغير r حول أوسطه m بالمعادلة:

$$\mu_n(r) = \sum_{i=0}^{L-1} (r_i - m)^n * p(r_i) \quad \text{--- (المعادلة 24-3)}$$

حيث m (المتوسط الحسابي / الوسط) يُعطى بالمعادلة:

$$m = \sum_{i=0}^{L-1} r_i * p(r_i) \quad \text{--- (المعادلة 25-3)}$$

المتوسط m هو مقياس لمتوسط الكثافة (Average intensity)، بينما التباين (Variance) - أو الانحراف المعياري σ - يُعطى بالمعادلة:

$$\sigma^2 = \mu_2(r) = \sum_{i=0}^{L-1} (r_i - m)^2 * p(r_i) \quad \text{--- (المعادلة 26-3)}$$

وهو مقياس لتباين الصورة (Image contrast).

الاستخدام المحلي مقابل الاستخدام الشامل للإحصائيات

نأخذ في الاعتبار استخدامين للمتوسط والتباين لأغراض التحسين:

المتوسط والتباين الشاملان (Global mean and variance): تحسب المعادلتان (25-3) و (26-3) عبر الصورة بأكملها وتكونان مفيدتين للتعديلات الكلية في الكثافة والتباين الشاملين.

المتوسط والتباين المحليان (Local mean and variance): استخدام أكثر قوة لهذه المعاملات يكون في التحسين المحلي، حيث يُستخدم المتوسط والتباين المحليان كأساس لإجراء تغييرات تعتمد على خصائص الصورة في مجاورة حول كل بكسل.

لتكن (x, y) ترمز إلى إحداثيات أي بكسل في صورة معطاة، ولتكن S_{xy} ترمز إلى مجاورة ذات حجم محدد، متمركزة عند (x, y) .

المتوسط المحلي لبكسلات المجاورة يُعطى بالمعادلة:

$$m_{Sxy} = \sum_{i=0}^{L-1} r_i * p_{Sxy}(r_i) \quad \text{--- (المعادلة 27-3)}$$

حيث p_{Sxy} هو هستوجرام البكسلات في المنطقة S_{xy} . يحتوي هذا الهستوجرام على L خانة (bins) ترمز إلى L من قيم الكثافة المحتملة في صورة الدخل. ومع ذلك، فإن العديد من الخانات ستكون قيمتها 0 اعتماداً على حجم S_{xy} :

على سبيل المثال، إذا كانت المجاورة بحجم 3×3 وكانت $L = 256$ ، فإن من 1 إلى 9 خانات فقط من أصل 256 خانة ستكون غير صفيرية (الحد الأقصى لعدد الكثافات المختلفة المحتملة في منطقة 3×3 هو 9، والحد الأدنى هو 1).

هذه القيم غير الصفيرية ستتناظر مع عدد الكثافات المختلفة في المنطقة S_{xy} .

تباين البكسلات في المجاورة يُعطى بشكل مشابه بالمعادلة:

$$\sigma^2_{Sxy} = \sum_{i=0}^{L-1} (r_i - m_{Sxy})^2 * p_{Sxy}(r_i) \quad \text{--- (المعادلة 28-3)}$$

كما في السابق، فإن المتوسط المحلي m_{Sxy} هو مقياس لمتوسط الكثافة في المجاورة S_{xy} ، والتباين المحلي σ^2_{Sxy} (أو الانحراف المعياري المحلي) هو مقياس لتباين الكثافة في تلك المجاورة....

أساسيات التصفية المكانية (Spatial Filtering)

في هذا القسم، نناقش استخدام المرشحات المكانية في معالجة الصور. تُستخدم التصفية المكانية في مجموعة واسعة من تطبيقات معالجة الصور، لذلك فإن الفهم الجيد لمبادئ التصفية يُعد أمراً مهماً. وكما ذكر في بداية هذا الفصل، فإن أمثلة التصفية الواردة في هذا القسم تتعلق في الغالب بتحسين الصور. أما التطبيقات الأخرى للتصفية المكانية فسيتم تناولها في الفصول اللاحقة.

تم استعارة مصطلح المرشح (Filter) من المعالجة في المجال الترددي (Frequency Domain)، والتي سيتم تناولها في الفصل الرابع. ففي هذا المجال، تشير عملية «التصفية» إلى تمرير أو تعديل أو رفض مكونات ترددية محددة في الصورة. على سبيل المثال، يُطلق على المرشح الذي يسمح بمرور الترددات المنخفضة اسم مرشح التمرير المنخفض (Lowpass Filter). ويؤدي استخدام هذا المرشح إلى تنعيم الصورة من خلال جعلها أكثر ضبابية. ويمكن تحقيق تأثير تنعيم مشابه مباشرةً على الصورة نفسها باستخدام المرشحات المكانية.

تعمل التصفية المكانية على تعديل الصورة من خلال استبدال قيمة كل بكسل بدالة تعتمد على قيمة ذلك البكسل وقيم البكسلات المجاورة له. وإذا كانت العملية المطبقة على بكسلات الصورة عملية خطية (Linear)، فإن المرشح يُسمى مرشحاً مكانياً خطياً (Linear Spatial Filter). أما إذا لم تكن العملية خطية، فيُسمى مرشحاً مكانياً غير خطي (Nonlinear Spatial Filter).

سنركز أولاً على دراسة المرشحات الخطية، ثم سنتعرف على بعض المرشحات غير الخطية الأساسية. ويحتوي القسم 5.3 على قائمة أكثر شمولاً بالمرشحات غير الخطية وتطبيقاتها.

آلية عمل التصفية المكانية الخطية

The Mechanics of Linear Spatial Filtering

يقوم المرشح المكاني الخطي (Linear Spatial Filter) بتنفيذ عملية تسمى مجموع النواتج (Sum-of-Products) بين الصورة f ونواة المرشح w .

النواة (Kernel) هي مصفوفة يحدد حجمها حجم المنطقة المجاورة التي ستجرى عليها العملية، بينما تحدد معاملاتها أو قيمها طبيعة المرشح وتأثيره على الصورة.

توجد مصطلحات أخرى تُستخدم للإشارة إلى نواة المرشح المكاني، مثل:

• Mask = قناع

• Template = قالب

• Window = نافذة

لكننا سنستخدم مصطلح Filter Kernel أو اختصاراً Kernel.

كيفية عمل المرشح الخطي

يوضح الشكل 3.28 آلية التصفية المكانية الخطية باستخدام نواة بحجم:

$$3 \times 3$$

عند أي نقطة (x, y) في الصورة، تكون قيمة الاستجابة الناتجة للمرشح، والتي نرمز لها بـ:

$$g(x, y)$$

مساوية لمجموع حاصل ضرب معاملات النواة في قيم البكسلات التي تغطيها النواة.

أي بشكل مبسط:

$$g(x, y) = \sum (\text{قيمة البكسل المقابل} \times \text{قيمة النواة})$$

تتحرك النواة فوق الصورة من بكسل إلى آخر، وفي كل موقع يتم حساب قيمة جديدة. ومع تغيير الإحداثيات x و y ، ينتقل مركز النواة عبر جميع بكسلات الصورة، مما يؤدي في النهاية إلى إنشاء الصورة المرشحة:

$$g$$

لاحظ أن المعامل الموجود في مركز النواة:

$$w(0, 0)$$

يتطابق مع البكسل الموجود عند الموقع:

$$(x, y)$$

حجم النواة

إذا كان حجم النواة:

$$m \times n$$

فنفترض أن:

$$m = 2a + 1$$

و:

$$n = 2b + 1$$

حيث إن a و b أعداد صحيحة غير سالبة.

وهذا يعني أن التركيز هنا يكون على النوى ذات الأحجام الفردية في كلا الاتجاهين، مثل:

$$3 \times 3, 5 \times 5, 7 \times 7$$

استخدام الأحجام الفردية يجعل تحديد مركز النواة أسهل، لأن المركز يقع على بكسل محدد.

وبشكل عام، تُعطى عملية التصفية المكانية الخطية للصورة بواسطة المعادلة:

$$g(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x + sy + t)$$

حيث تتحرك النواة بحيث يمر مركزها على كل بكسل في الصورة f مرة واحدة.

الارتباط المكاني والالتفاف المكاني

Spatial Correlation and Convolution

يوجد مفهومان مهمان في التصفية المكانية:

1. الارتباط المكاني (Spatial Correlation).

يتضمن الارتباط المكاني تحريك مركز النواة فوق الصورة، وحساب مجموع النواتج في كل موقع.

أي أن النواة تتحرك فوق الصورة كما هي، دون تغيير ترتيب قيمها.

2. الالتفاف المكاني (Spatial Convolution)

آلية الالتفاف المكاني تشبه الارتباط المكاني، لكن يوجد اختلاف مهم:

قبل تطبيق النواة، يتم تدويرها بمقدار 180° .

بعد تدوير النواة، يتم تحريكها فوق الصورة وحساب مجموع النواتج بالطريقة نفسها.

لذلك، إذا كانت قيم النواة متماثلة حول مركزها، فإن:

$$\text{Correlation} = \text{Convolution}$$

أي أن الارتباط والالتفاف سيعطيان النتيجة نفسها.

التفسير باستخدام البعد الواحد

في حالة الإشارة أحادية البعد (1-D)، تصبح معادلة التصفية:


$$g(x) = \sum_{s=-a}^a w(s)f(x+s)$$

وهي تمثل الفكرة نفسها: يتم ضرب قيم النواة في قيم العناصر أو اليكسلات المجاورة، ثم يتم جمع النتائج للحصول على القيمة الجديدة عند الموقع x .

ملاحظة: عادةً لا يتم استبدال قيم البكسلات مباشرة داخل الصورة الأصلية أثناء عملية التصفية،

الشكل 3.28

آلية عمل التصفية
المكانية الخطية باستخدام
نواة بحجم 3×3 .
تُعرض البكسلات على
شكل مربعات لتبسيط
الرسم البياني. لاحظ أن
أصل الصورة في الزاوية
العلوية اليسرى، بينما
أصل النواة في مركزها.
إن وضع الأصل في
مركز النواة ذات التناظر
المكاني يبسط كتابة
التعابير الرياضية للتصفية
الخطية.




الشكل 3.29 (أ) يوضح دالة أحادية البعد f ونواة w . حجم النواة في هذه الحالة هو 1×5 ، لذلك $b = 0$ و $a = 2$. الشكل 3.29 (ب) يوضح موضع البداية المستخدم لأداء الارتباط، حيث توضع w بحيث يتطابق معاملها المركزي مع أصل f .

أول ما نلاحظه هو أن جزءاً من يقع خارج f وبالتالي يكون المجموع غير معرف في تلك المنطقة. ولحل هذه المشكلة يجب إضافة أصفار إلى الدالة بعدد كافٍ من الأصفار على كل جانب. بشكل عام، إذا كانت النواة ذات حجم $m \times 1$ ، فنحتاج إلى إضافة $(m-1)/2$ صفراً على كل جانب من f للتعامل مع تكوينات البداية والنهاية لد w بالنسبة إلى الشكل 3.29 (ج) يوضح دالة مملوءة بالأصفار بشكل صحيح. في هذا التكوين الابتدائي تكون جميع معاملات النواة متداخلة مع قيم صالحة.

بل يتم تخزين النتائج في صورة جديدة؛ لأن تغيير الصورة الأصلية أثناء المعالجة قد يؤثر في نتائج البكسلات التالية.

الحشو بالأصفار ليس
الخيار الوحيد، وسنناقش
خيارات أخرى بالتفصيل
لاحقاً في هذا الفصل.

تحويلات الشدة والترشيح المكاني (Intensity Transformations and Spatial Filtering)



الشكل 3.29

توضيح للارتباط (correlation) والالتفاف (convolution) أحادي الأبعاد لنواة w مع دالة f تتكون من نبضة وحدة منفصلة (discrete unit impulse). لاحظ أن الارتباط والالتفاف هما دالتان للمتغير x ، والذي يعمل على إزاحة إحدى الدالتين بالنسبة للأخرى. بالنسبة لنتائج الارتباط والالتفاف الممتدة، فإن التكوين الابتدائي يضع العنصر الأقصى يميناً للنواة متطابقاً مع نقطة الأصل للدالة f . يجب استخدام حشو إضافي (padding).

قسم الارتباط (Correlation) والالتفاف (Convolution)

الارتباط (Correlation)

- (a) الأصل f : 0 0 0 1 0 0 0 | w : 8 2 4 2 1
- (b) محاذاة موضع البداية: w تحت الأصل.
- (c) حشو بالأصفار (Zero padding): 0 0 0 0 0 1 0 0 0 0 0 | موضع البداية: 2 1
8 2 4
- (d) الموضع بعد إزاحة واحدة (shift 1).
- (e) الموضع بعد 3 إزاحات (shifts 3).
- (f) الموضع النهائي (Final position).
- (g) نتيجة الارتباط (Correlation result):
0 0 1 2 4 2 8 0
- (h) نتيجة الارتباط الممتدة (المكتملة) (Extended (full) correlation result):
0 0 0 0 1 2 4 2 8 0 0 0

الالتفاف (Convolution)

- (i) الأصل f : 0 0 0 1 0 0 0 | w مدوّرة بمقدار 180 درجة
(w rotated 180°): 8
1 2 4 2
- (j) محاذاة موضع البداية.
- (k) حشو بالأصفار (Zero padding): 0 0 0 0 0 1 0 0 0 0 0 | موضع البداية:
1 2 4 2 8
- (l) الموضع بعد إزاحة واحدة (shift 1).
- (m) الموضع بعد 3 إزاحات (shifts 3).
- (n) الموضع النهائي (Final position).
- (o) نتيجة الالتفاف (Convolution result):
0 0 8 2 4 2 1 0

• (p) نتيجة الالتفاف الممتدة (المكتملة) Extended (full) convolution)

:(result

0 0 0 0 8 2 4 2 1 0 0 0

أول قيمة للارتباط هي مجموع حاصل الضرب في هذا الموضع الابتدائي، ويتم حسابها باستخدام المعادلة (32-3) عند $x = 0$:

$$g(0) = \sum_{s=-2}^2 w(s)f(s+0) = 0$$

هذه القيمة تقع في الموضع الأقصى يساراً لنتيجة الارتباط في الشكل 3.29(g).

للحصول على القيمة الثانية للارتباط، نقوم بإزاحة المواضع النسبية لـ w و f بمقدار موقع بكسل واحد إلى اليمين [أي نضع $x = 1$ في المعادلة (32-3)] ونحسب مجموع حاصل الضرب مرة أخرى. النتيجة هي $g(1) = 8$ ، كما هو موضح في الموقع غير الصفري الأقصى يساراً في الشكل 3.29(g). عندما يكون $x = 2$ ، نحصل على $g(2) = 2$. وعندما يكون $x = 3$ ، نحصل على $g(3) = 4$ [انظر الشكل 3.29(e)].

بالاستمرار بهذه الطريقة من خلال تغيير x بإزاحة واحدة في كل مرة، نصل إلى "بناء" نتيجة الارتباط في الشكل 3.29(g). لاحظ أنه استلزم الأمر 8 قيم لـ x (أي $x = 0, 1, 2, \dots, 7$) لإزاحة w بالكامل عبر f بحيث يعبر معامل المركز في w كل بكسل في f . في بعض الأحيان، يكون من المفيد جعل كل عنصر من عناصر w يعبر كل بكسل في f . لهذا الغرض، يتعين علينا البدء...

تبدأ بالعنصر الأيمن لـ w المتطابق مع نقطة الأصل لـ f ، وتنتهي بأن يكون العنصر الأيسر لـ w متطابقاً مع العنصر الأخير لـ f (ستكون هناك حاجة إلى حشوة إضافية). يبين الشكل 3.29 (h) نتيجة هذا الارتباط الممتد أو الكامل. كما يبين الشكل 3.29 (g)، يمكننا الحصول على الارتباط "القياسي" من خلال اقتصاص الارتباط الكامل في الشكل 3.29 (h).

هناك نقطتان مهمتان تجدر الإشارة إليهما من المناقشة السابقة. أولاً، الارتباط هو دالة إزاحة نواة المشرح بالنسبة للصورة. بعبارة أخرى، تتوافق القيمة الأولى للارتباط مع إزاحة صفرية للنواة، وتتوافق القيمة الثانية مع إزاحة وحدة واحدة، وهكذا. النقطة الثانية التي تجدر ملاحظتها هي أن ربط نواة w بدالة تحتوي على جميع الأصفار وصفر واحد يعطي نسخة من

w ، ولكنها مدورة بـ 180 درجة. تسمى الدالة التي تحتوي على 1 واحد وبقية الأصفار دافعاً منفصلاً. إن ربط نواة بدافع منفصل يعطي نسخة مدورة من النواة عند موقع الدافع.

يبين الجانب الأيمن من الشكل 3.29 سلسلة من الخطوات لإجراء الالتفاف (سنقدم معادلة الالتفاف قريباً). الفرق الوحيد هنا هو أن النواة يتم تدويرها مسبقاً بـ 180 درجة قبل إجراء عمليات الإزاحة/مجموع المنتجات. كما يبين التفاف الشكل 3.29 (o) ، فإن نتيجة تدوير النواة مسبقاً هي أن لدينا الآن نسخة طبق الأصل من النواة عند موقع دافع الوحدة. في الواقع ، يعد أساس نظرية النظم الخطية هو أن التفاف دالة مع دافع يعطي نسخة من الدالة عند موقع الدافع. سنستخدم هذه الخاصية بشكل مكثف في الفصل 4.

تمتد مفاهيم D-1 التي تم مناقشتها للتو بسهولة لتشمل الصور ، كما يبين الشكل 3.30. بالنسبة لنواة بحجم $m \times n$ ، نقوم بحشو الصورة بحد أدنى (م - 1) صفوف من الأصفار في الأعلى والأسفل و(ن - 1) أعمدة من الأصفار على اليسار واليمين. في هذه الحالة ، m و n متساويان لـ 3 ، لذلك نقوم بحشو f بصف واحد من الأصفار فوق وتحت وعمود واحد من الأصفار إلى اليسار واليمين ، كما يبين الشكل 3.30 (b). يبين الشكل 3.30 (c) الموضع الأولي للنواة لإجراء الارتباط ، ويبين الشكل 3.30 (d) النتيجة النهائية بعد أن يزور مركز w كل بكسل في f ، وحساب مجموع المنتجات في كل موقع. كما في السابق ، النتيجة هي نسخة من النواة ، مدورة بـ 180 درجة. سنناقش نتيجة الارتباط الممتد قريباً.

بالنسبة للالتفاف ، نقوم بتدوير النواة مسبقاً كما في السابق ونكرر مجموع الانزلاق للمنتجات الذي تم شرحه للتو. تبين الأشكال 3.30 (f) من خلال (h) النتيجة. ترى مرة أخرى أن التفاف دالة مع دافع ينسخ الدالة إلى موقع الدافع. كما لوحظ سابقاً ، يعطي الارتباط والالتفاف نفس النتيجة إذا كانت قيم النواة متماثلة حول المركز.

يعتبر مفهوم الدافع أساسياً في نظرية النظم الخطية ، ويستخدم في العديد من الأماكن في جميع أنحاء الكتاب. يُعرّف الدافع المنفصل للقوة (السعة) A الموجود في الإحداثيات (x_0, y_0) على أنه

$$\delta(x - x_0, y - y_0) = \begin{cases} A & \text{if } x = x_0 \text{ and } y = y_0 \\ 0 & \text{otherwise} \end{cases}$$


+ في الواقع ، نقوم بإزاحة f إلى يسار w في كل مرة نزيد فيها x في المعادلة (3-32). ومع ذلك ، فمن الأكثر بديهية التفكير في أن النواة الأصغر تتحرك يميناً فوق المصفوفة الأكبر f . حركة الاثنين نسبية ، لذا فإن أي من الطريقتين للنظر في الحركة مقبولة. السبب في أننا نزيد f وليس w هو أن فهرسة المعادلات للارتباط والالتفاف أسهل بكثير (وأوضح) بهذه الطريقة ، خاصة عند العمل مع المصفوفات D-2.

تدوير نواة D-1 بمقدار 180 درجة يعادل قلب النواة حول محورها.

في D-2 ، التدوير بمقدار 180 درجة يعادل قلب النواة حول محور واحد ثم الآخر.

الشكل 3.30

الارتباط (الوسط)
والالتفاف (الصف الأخير)
نواة ثنائية الأبعاد تحتوي
على نبضة حدة وحدة
مع مع صورة تتكون من
نبضة وحدة منفصلة.
تُعرض الأصفار باللون
الرمادي لتبسيط التصري.
لاحظ أن الارتباط
والالتفاف دالتان في x
ومع تغيير هذه المتغيرات،
تحل كل دالة محل
الأخرى. راجع الملاحظة
المناقشة في المعادلتين
(3-36) و(3-37) فيما يتعلق
بالارتباط الكامل.
والالتفاف.



تذكر أن $A = 1$
لنبضة وحدة.

على سبيل المثال، النبضة الوحدة في الشكل 3.29(a) تُعطى بـ $\delta(x-3)$ في النسخة أحادية البعد من المعادلة السابقة. وبالمثل، النبضة في الشكل 3.30(a) تُعطى بـ $\delta(x-2, y-2)$ [تذكر أن الأصل هو عند $(0,0)$].

ولتلخيص المناقشة السابقة بصيغة معادلة، فإن الارتباط لنواة w ذات حجم $m \times n$ مع صورة $f(x, y)$ يرمز له بـ $(w * f)(x, y)$ ، يُعطى بواسطة المعادلة (3-31)، والتي تكررنا هنا للراحة:

$$(w * f)(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x+s, y+t) \quad (3-34)$$

ولأن نواتنا لا تعتمد على (x, y) ، فسنقوم أحياناً بتوضيح هذه الحقيقة بكتابة الجانب الأيسر من المعادلة السابقة على صورة $w * f(x, y)$. تُقيم المعادلة (3-34)، لكل قيم متغيري الإزاحة x و y بحيث يمر مركز النواة w على كل يكسل في f مرة واحدة، مع افتراض أننا قمنا بتطبيق f بطريقة مناسبة[†].

[†] كما ذكرنا سابقاً، الحد الأدنى لعدد عناصر التيطين المطلوبة للارتباط ثنائي الأبعاد هو $(m-1)/2$ صفوفًا أعلى وأسفل من f ، من f و $(n-1)/2$ أعمدة على اليمين وعلى اليسار. مع هذا التيطين، وافترض أن حجمه $M \times N$ ، فإن القيم لـ y المطلوبة للارتباط كاملاً تكون $x = 0, 1, 2, \dots, M-1$ و $y = 0, 1, 2, \dots, N-1$. وهذا يفترض أن عملية البدء بحيث يخبئة لجيث يتطابق مركز النواة مع أصل الصورة، كما عرفناه في الشكل يسار (انظر الشكل 2.19).

كما أوضحنا سابقًا، فإن:

$$a = \frac{m-1}{2}, b = \frac{n-1}{2}$$

ونفترض أن n و m عدنان صحيحان فرديان.

وبطريقة مماثلة، يُعرّف الالتفاف (Convolution) لنواة w ذات الحجم $m \times n$ مع صورة $f(x, y)$ ، والذي نرمز له بـ $(w * f)(x, y)$ ، كما يلي:

$$(w * f)(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x - sy - t) \quad (3-35)$$

حيث تعمل إشارات الطرح على محاذاة إحداثيات w و f عندما يتم تدوير إحدى الدالتين بزاوية 180° (انظر المسألة 3.17). وتُنفذ هذه المعادلة عملية مجموع النواتج التي نشير إليها في جميع أنحاء الكتاب باسم التصفية المكانية الخطية (Linear Spatial Filtering) أي أن التصفية المكانية الخطية والالتفاف المكاني هما مصطلحان مترادفان.

نظرًا لأن عملية الالتفاف تبادلية (Commutative) (انظر الجدول 3.5)، فلا يهم ما إذا تم تدوير w أو f ، ولكن تدوير النواة هو الأسلوب المتعارف عليه. لا تعتمد نوانا على (x, y) ، وهي حقيقة نوضحها أحيانًا بكتابة الطرف الأيسر من المعادلة (35-3) بالشكل:

$$w * f(x, y)$$

وعندما يكون المعنى واضحًا، نترك اعتماد المعادلتين السابقتين على x و y مفهومًا ضمنيًا، ونستخدم الترميز المبسط:

$$w * f$$

وبالمثل، كما هو الحال في الارتباط (Correlation)، تُقِيم المعادلة (35-3) لجميع قيم متغيري الإزاحة x و y ، بحيث يمر مركز w على كل بكسل في f ، والتي نفترض أنها قد تم حشوها (Padded) مسبقًا.

قيم x و y اللازمة للحصول على الالتفاف الكامل (Full Convolution) هي:

$$x = 0, 1, 2, \dots, M - 1$$

و:

$$y = 0, 1, 2, \dots, N - 1$$

ويكون حجم النتيجة:

$$M \times N$$

الارتباط والالتفاف الكاملان

يمكننا تعريف الارتباط والالتفاف بحيث يمر كل عنصر من عناصر w — وليس مركزها فقط — على كل بكسل في f .

ويتطلب ذلك أن يكون التكوين الابتدائي بحيث يتطابق الركن السفلي الأيمن للنواة مع أصل الصورة.

وبالمثل، يكون التكوين النهائي بحيث يتطابق الركن العلوي الأيسر للنواة مع الركن السفلي الأيمن للصورة.

إذا كان حجم النواة والصورة على التوالي:

$$m \times n$$

و:

$$M \times N$$

فإن عملية الحشو يجب أن تزيد إلى $m - 1$ من عناصر الحشو أعلى الصورة وأسفلها، و $n - 1$ من عناصر الحشو إلى يسار الصورة ويمينها. **

في ظل هذه الشروط، سيكون حجم مصفوفة الارتباط الكامل أو الالتفاف الكامل الناتجة:

$$S_v \times S_h$$

حيث) انظر الشكلين 3.30 (e) و 3.30 (h)، والمسألة 3.19:

$$S_v = M + m - 1 \quad (3-36)$$

و:

$$S_h = N + n - 1 \quad (3-37)$$

خوارزميات التصفية المكانية

غالبًا ما تعتمد خوارزميات التصفية المكانية على الارتباط، وبالتالي تنفذ المعادلة (3-34)

لاستخدام الخوارزمية لإجراء الارتباط، ندخل إليها النواة w كما هي.

أما لإجراء الالتفاف، فنُدخل النواة w بعد تدويرها بزاوية 180° .

والعكس صحيح بالنسبة إلى الخوارزمية التي تنفذ المعادلة (3-35)

وبالتالي، يمكن جعل أي من المعادلتين:

$$(3 - 34)$$

أو:

$$(3 - 35)$$

تنفذ وظيفة الأخرى من خلال تدوير نواة المرشح.

لكن يجب الانتباه إلى أن ترتيب الدوال المُدخلة إلى خوارزمية الارتباط يُحدث فرقاً؛ لأن الارتباط ليس تبادلياً ولا تجميعياً (Associative) انظر الجدول 3.5.

الجدول 3.5
بعض الخصائص الأساسية للارتباط والارتباط. تعني الشرطة (–) أن الخاصية غير متحققة.

الارتباط (Correlation)	الالتفاف (Convolution)	الخاصية
–	$f * g = g * f$	التبادلية
–	$f * (g * h) = (f * g) * h$	التجميعية
$f * (g + h) = (f * g) + (f * h)$	$f * (g + h) = (f * g) + (f * h)$	التوزيعية

القيم في هذه النوى متناظرة حول المركز، لذا لا يتطلب الأمر أي تدوير قبل الالتفاف.

يوضح الشكل 3.31 نواتين تُستخدمان في تنعيم شدة الإضاءة في صورة. ولتصفية صورة باستخدام إحدى هذه النوى، نقوم بعملية الالتفاف للنواة مع الصورة بالطريقة التي وصفت سابقاً. وعند الحديث عن الترشيح والنوى، ستواجه غالباً المصطلحات التالية للدلالة على نوى المرشحات من النوع الذي ناقشناه: مرشح الالتفاف، قناع الالتفاف، نواة الالتفاف. وتُستخدم هذه المصطلحات عادةً في الأدبيات للدلالة على نواة مرشح مكاني، ولا يلزم أن تكون النواة مستخدمة للالتفاف تحديداً. وبالمثل، يُستخدم مصطلح «تطبيق نواة على صورة» غالباً للدلالة على عملية الانزلاق (مجموع حاصل ضربيات المتحرك) التي شرحناها، ولا يفرق بالضرورة بين الارتباط والالتفاف. بل يُستخدم عادةً للدلالة على أيٍّ من العمليتين. وهذا المصطلح غير الدقيق هو مصدر شائع للالتباس. في هذا الكتاب، عندما نستخدم مصطلح الترشيح المكاني الخطي، فإننا نعني الالتفاف لنواة مع صورة.

أحياناً تُصَفَى الصورة (أي تُجرى عليها عملية الالتفاف) تسلسلياً، على مراحل، باستخدام نواة مختلفة في كل مرحلة. فمثلاً، إذا صُفِّيت صورة f أولاً بنواة w_1 ، ثم صُفِّيت النتيجة بنواة w_2 ، ثم صُفِّيت النتيجة بنواة ثالثة وهكذا، ولمجموع Q مراحل. وبسبب الخاصية التبادلية للالتفاف، يمكن إنجاز هذا الترشيح متعدد المراحل بعملية ترشيح واحدة باستخدام نواة مكافئة هي حاصل التفاف هذه النوى معاً، أي:

$$w = w_1 * w_2 * w_3 * \dots * w_Q \quad (3-38)$$

لا يمكننا كتابة معادلة مشابهة للارتباط؛ لأن الارتباط ليس تبادلياً.

يُستخرج حجم w من أحجام النوى الفردية من خلال تطبيقات متتالية للمعادلتين (3-36) و(3-37). إذا كانت جميع النوى الفردية من الحجم $m \times n$ ، فإن حجم w سيكون:

$$W_v = Q \times (m - 1) + m \quad (3-39)$$

و

$$W_h = Q \times (n - 1) + n \quad (3-40)$$

تفترض هاتان المعادلتان أن كل قيمة من النواة تمر على كل قيمة من المصفوفة الناتجة من الالتفاف في الخطوة السابقة. أي إن التشكيلات (التهيئات) الابتدائية والنهائية هي كما وصفتها المعادلتان (3-36) و(3-37).

a b

الشكل 3.31

أمثلة لنوى التنعيم الناتجة:

(أ) نواة صندوقية (Box kernel).

(ب) نواة غاوسية إيسية (Gaussian).

$$\frac{1}{9} \times \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad \frac{1}{4.8976} \times \begin{bmatrix} 0.3679 & 0.6065 & 0.3679 \\ 0.6065 & 1.0000 & 0.6065 \\ 0.3679 & 0.6065 & 0.3679 \end{bmatrix}$$

نوى المرشحات القابلة للفصل (Separable Filter Kernels)

كما أُشير في القسم 2.6، تُسمى الدالة ثنائية الأبعاد $G(x, y)$ قابلة للفصل (separable) إذا أمكن كتابتها على شكل حاصل ضرب دالتين أحاديتي الأبعاد، $G_1(x)$ و $G_2(y)$ ، أي:

$$G(x, y) = G_1(x)G_2(y)$$

ونواة المرشح المكاني هي مصفوفة، بينما النواة القابلة للفصل هي مصفوفة يمكن التعبير عنها على أنها حاصل ضرب خارجي (outer product) لمتجهين.

على سبيل المثال، النواة ذات الحجم 2×3 :

$$w = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

هي نواة قابلة للفصل؛ لأنه يمكن التعبير عنها على أنها حاصل ضرب خارجي للمتجهين:

$$c = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, r = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

أي:

$$w = cr^T = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

يمكن التعبير عن نواة قابلة للفصل ذات الحجم $m \times n$ على أنها حاصل ضرب خارجي لمتجهين w و v :

$$w = vw^T \quad (3-41)$$

حيث إن w و v متجهان حجمهما $m \times 1$ و $n \times 1$ ، على التوالي.

أما بالنسبة إلى نواة مربعة حجمها $m \times m$ ، فنكتب:

$$w = vv^T \quad (3-42)$$

ومن المثير للاهتمام أن حاصل ضرب متجه عمودي في متجه صفّي يعادل عملية الالتفاف ثنائي الأبعاد (2-D convolution) للمتجهين (انظر المسألة 3.24).

تكمّن أهمية النوى القابلة للفصل في المزايا الحسابية الناتجة عن الخاصية التجميعية لعملية الالتفاف. فإذا كانت لدينا نواة w يمكن تحليلها إلى نواتين أبسط، بحيث:

$$w = w_1 \otimes w_2$$

فعدنّذ، وبلاستناد إلى الخاصيتين التبادلية والتجميعية الموضحتين في الجدول 3.5، نحصل على:

$$w \otimes f = (w_1 \otimes w_2) \otimes f = (w_2 \otimes w_1) \otimes f = w_2 \otimes (w_1 \otimes f) = (w_1 \otimes f) \otimes w_2 \quad (3-43)$$

وتعني هذه المعادلة أن إجراء التفاف لنواة قابلة للفصل مع صورة يعادل أولاً إجراء الالتفاف للنواة w_1 مع الصورة f ، ثم إجراء الالتفاف للناتج مع النواة w_2 .

بالنسبة إلى صورة حجمها $M \times N$ ونواة حجمها $m \times n$ ، فإن تنفيذ المعادلة (3-35) يتطلب في حدود:

$$MNmn$$

من عمليات الضرب والجمع. ويرجع ذلك مباشرة إلى تلك المعادلة، إذ إن كل بكسل في الصورة الناتجة (المُرشحة) يعتمد على جميع معاملات نواة المرشح.

ولكن إذا كانت النواة قابلة للفصل واستخدمنا المعادلة (3-43)، فإن عملية الالتفاف الأولى:

$$w_1 \otimes f$$

تتطلب في حدود:

$$MNm$$

من عمليات الضرب والجمع، لأن w_1 حجمه $m \times 1$. ويكون الناتج بحجم $M \times N$ ، ولذلك فإن إجراء الالتفاف للنواة w_2 مع الناتج يتطلب في حدود:

$$MNn$$

من هذه العمليات، ليصبح إجمالي عدد عمليات الضرب والجمع:

$$MN(m + n)$$

وبالتالي، فإن الميزة الحسابية لإجراء الالتفاف باستخدام نواة قابلة للفصل، مقارنةً بنواة غير قابلة للفصل، تُحدّد بواسطة:

$$\frac{MNmn}{MN(m + n)} = \frac{mn}{m + n}$$

ملاحظة حول الترميز

لكي نكون متسقين تمامًا في الترميز، ينبغي أن نستخدم رموزًا كبيرة وعريضة (**Bold**) للنوى عندما نشير إليها بوصفها مصفوفات. ومع ذلك، تُعامل النوى في معظم أجزاء الكتاب على أنها دوال ثنائية الأبعاد، ونرمز إليها بالخط المائل (*Italic*).

ولتجنب الالتباس، سنستمر في استخدام **الخط المائل للنوى** في هذا القسم القصير، مع افتراض أن الترميزين مقصود بهما أن يكونا متكافئين في هذه الحالة.

ملاحظة أخرى

نفترض أن قيمتي M و N تتضمنان أي حشو (**padding**) تمت إضافته إلى الصورة فقبل إجراء عملية الالتفاف. **عمليات الضرب والجمع**، لأن w_1 حجمه $m \times 1$. وتكون النتيجة بحجم $M \times N$ ، ولذلك فإن إجراء التفاف w_2 مع النتيجة يتطلب MNn عملية من هذا النوع، ليصبح المجموع الكلي:

$$MN(m + n)$$

من عمليات الضرب والجمع. وبالتالي، فإن الميزة الحسابية لإجراء الالتفاف باستخدام نواة قابلة للفصل (**Separable Kernel**)، مقارنةً بنواة غير قابلة للفصل، تُعرّف كما يلي:

$$C = \frac{MNmn}{MN(m + n)} = \frac{mn}{m + n} \quad (3-44)$$

بالنسبة إلى نواة ذات حجم متوسط، لنفترض أنها 11×11 ، فإن الميزة الحسابية — وبالتالي ميزة زمن التنفيذ — تبلغ قيمة جيدة قدرها 5.2. أما بالنسبة إلى النوى التي تحتوي على مئات العناصر، فيمكن تقليل أزمنة التنفيذ بمعامل يبلغ مئة أو أكثر، وهو أمر ذو أهمية كبيرة. وسنوضح استخدام مثل هذه النوى الكبيرة في المثال 3.16.

نعلم من **نظرية المصفوفات** أن المصفوفة الناتجة عن حاصل ضرب متجه عمودي في متجه صفّي يكون لها دائمًا رتبة تساوي 1. وبالتعريف، تتكوّن النواة القابلة للفصل من حاصل ضرب من هذا النوع. ولذلك، لتحديد ما إذا كانت نواة ما قابلة للفصل، فإن كل ما علينا فعله هو تحديد ما إذا كانت رتبتهما تساوي 1.

عادةً، نحدد رتبة المصفوفة باستخدام دالة مبرمجة مسبقًا في لغة البرمجة المستخدمة. فعلى سبيل المثال، إذا كنت تستخدم **MATLAB**، فإن الدالة **rank** تقوم بهذه المهمة.

بعد أن تحدد أن رتبة مصفوفة النواة تساوي 1، يصبح من السهل إيجاد متجهين w و v بحيث يكون حاصل الضرب الخارجي لهما، vw^T ، مساويًا للنواة.

وتتكون الطريقة من ثلاث خطوات فقط:

1. ابحث عن أي عنصر غير صفري في النواة، ولتكن قيمته E .
2. كوّن المتجهين w و v ، بحيث يكونان على التوالي العمود والصف في النواة اللذين يحتويان على العنصر الذي تم العثور عليه في الخطوة الأولى.
3. بالرجوع إلى المعادلة (3-41)، اجعل:

$$v = c$$

و

$$w^T = \frac{r}{E}$$

والسبب في نجاح هذه الطريقة البسيطة المكونة من ثلاث خطوات هو أن صفوف وأعمدة المصفوفة التي رتبناها تساوي **1 تكون معتمدة خطيًا**. أي أن الصفوف تختلف فقط بمعامل ثابت، وينطبق الأمر نفسه على الأعمدة.

ومن المفيد فهم آلية هذه العملية عمليًا من خلال تطبيقها على نواة صغيرة (انظر المسألتين 3.20 و 3.22).

كما أوضحنا أعلاه، فإن الهدف هو إيجاد نواتين أحاديتي البعد w_1 و w_2 ، وذلك من أجل تنفيذ الالتفاف أحادي البعد. ووفقًا للترميز السابق:

$$w_1 = c = v$$

و

$$w_2 = \frac{r}{E} = w^T$$

بالنسبة إلى النوى ذات التماثل الدائري، فإن العمود المار عبر مركز النواة يصف النواة بأكملها؛ أي:

$$w = v v^T c$$

حيث c هي قيمة معامل المركز. ومن ثم، تكون المكونات أحادية البعد:

$$w_1 = v$$

و

$$w_2 = \frac{v^T}{c}$$

بعض المقارنات المهمة بين التصفية في المجال المكاني ومجال التردد

على الرغم من أن التصفية في مجال التردد هي موضوع الفصل الرابع، فإننا نقدم في هذه المرحلة بعض المفاهيم المهمة من مجال التردد التي ستساعدك على إتقان المادة التي تلي ذلك.

إن الرابط بين المعالجة في المجال المكاني والمعالجة في مجال التردد هو تحويل فورييه (Fourier Transform).

نستخدم تحويل فورييه للانتقال من المجال المكاني إلى مجال التردد.


وكما سنناقش لاحقًا في هذا الفصل، فإن النوى الوحيدة التي تكون قابلة للفصل وتكون قيمها متماثلة دائريًا حول المركز هي النوى الغاوسية (Gaussian Kernels)، والتي يكون لها معامل مركزي غير صفري، أي:

$$c > 0$$

بالنسبة إلى هذه النوى.

الشكل 3.32

أ) دالة نقل مرشح تمرير منخفض مثالي أحادي البعد (1-D) في مجال التردد.
ب) نواة المرشح المقابلة في المجال المكاني.



العودة إلى المجال المكاني، نستخدم تحويل فورييه العكسي (Inverse Fourier Transform).

بالنقصيل في الفصل الرابع. وينصب التركيز هنا على خاصيتين أساسيتين تربطان بين المجالين المكاني ومجال التردد:

1. الالتفاف (Convolution)، وهو الأساس الذي تقوم عليه التصفية في المجال المكاني، يكافئ الضرب في مجال التردد، والعكس صحيح.

2. النبضة (Impulse) ذات الشدة A في المجال المكاني تقابل قيمة ثابتة مقدارها A في مجال التردد، والعكس صحيح.

وكما أوضحنا في الفصل الرابع، يمكن التعبير عن دالة ما (مثل صورة) تستوفي بعض الشروط البسيطة على أنها مجموع لموجات جيبية (Sinusoids) ذات ترددات وسعات مختلفة.

وبالتالي، فإن مظهر الصورة يعتمد على ترددات مكوناتها الجيبية؛ فإذا غيرنا ترددات تلك المكونات، فسوف يتغير مظهر الصورة.

وتكمن قوة هذا المفهوم في إمكانية ربط نطاقات ترددية معينة بخصائص محددة في الصورة. فعلى سبيل المثال، تتميز مناطق الصورة التي تتغير شدتها ببطء (مثل الجدران في صورة لغرفة) بموجات جيبية ذات ترددات منخفضة.

وبالمثل، تتميز الحواف (Edges) وغيرها من الانتقالات الحادة في شدة الإضاءة بترددات عالية. ولذلك، فإن تقليل المكونات ذات الترددات العالية في الصورة يؤدي عادةً إلى تغييبها (Blur).

تهتم التصفية الخطية (Linear Filtering) بإيجاد طرق مناسبة لتعديل المحتوى الترددي للصورة. وفي المجال المكاني، نقوم بذلك باستخدام تصفية الالتفاف (Convolution Filtering). أما في مجال التردد، فنقوم بذلك باستخدام مرشحات ضربية (Multiplicative Filters).

وتُعد الطريقة الأخيرة أكثر سهولة من الناحية الحاسوبية، وهذا أحد الأسباب التي تجعل من الصعب جداً فهم التصفية المكانية فهماً حقيقياً دون امتلاك قدر ولو بسيط من المعرفة بـ مجال التردد.

وسيساعد مثال على توضيح هذه الأفكار.

للتبسيط، لنفترض وجود دالة أحادية البعد (1-D)، مثل خط مسح لشدة الإضاءة عبر صورة، وأننا نريد إزالة جميع تردداتها التي تتجاوز قيمة قطع معينة u_0 ، مع تمرير جميع الترددات التي تقل عن هذه القيمة.

يوضح الشكل 3.32(a) دالة مرشح في مجال التردد تحقق هذا الغرض.

(يُستخدم مصطلح دالة نقل المرشح (Filter Transfer Function) للدلالة على دوال المرشح في مجال التردد، وهذا يماثل استخدامنا لمصطلح نواة المرشح (Filter Kernel) في المجال المكاني).

وبشكل مناسب، تُسمى الدالة الموضحة في الشكل 3.32(a) دالة نقل مرشح تمرير منخفض (Lowpass Filter Transfer Function).

وفي الواقع، فإنها تمثل دالة مرشح تمرير منخفض مثالية (Ideal Lowpass Filter)؛ لأنها تزيل جميع الترددات التي تتجاوز u_0 ، بينما تمرر جميع الترددات التي تقل عن هذه القيمة.

+جميع مرشحات مجال التردد التي نهتم بها متماثلة حول نقطة الأصل وتشمل كلاً من الترددات الموجبة والسالبة، كما سنوضح في القسم (4.3 انظر الشكل (4.8).

وفي الوقت الحالي، ولتبسيط هذا الشرح المختصر، نعرض فقط الجانب الأيمن (الترددات الموجبة) من مرشحات أحادية البعد.

ملاحظة: انظر الشرح المتعلق بالمعادلة (3-33) فيما يخص النبضات (Impulses).

وكما فعلنا سابقاً مع المرشحات المكانية، فعندما يكون المعنى واضحاً، نستخدم مصطلح المرشح (Filter) بالتبادل مع مصطلح دالة نقل المرشح (Filter Transfer Function) عند العمل في مجال التردد.

يكون الانتقال في المرشح بين الترددات المنخفضة والترددات العالية لحظياً. ومثل هذه الدوال المرشحة لا يمكن تحقيقها باستخدام المكونات الفيزيائية، كما أنها تعاني من مشكلات «الرنين» (Ringing) عند تنفيذها رقمياً. ومع ذلك، فإن المرشحات المثالية مفيدة جداً في توضيح العديد من ظواهر التصفية، كما سنتعلم في الفصل الرابع.

لتطبيق ترشيح تمرير منخفض لإشارة مكانية في مجال التردد، نقوم أولاً بتحويلها إلى مجال التردد من خلال حساب تحويل فورييه الخاص بها، ثم نضرب الناتج في دالة نقل المرشح الموضحة في الشكل 3.32(a)، وذلك لإزالة مكونات التردد التي تزيد قيمها على u_0 .

وللعودة إلى المجال المكاني، نحسب تحويل فورييه العكسي للإشارة التي تمت تصفيتها. وستكون النتيجة دالة مكانية موهمة (Blurred).

وبسبب التناظر أو الازدواجية (Duality) بين المجالين المكاني ومجال التردد، يمكننا الحصول على النتيجة نفسها في المجال المكاني من خلال إجراء التفاف (Convolution) بين نواة المرشح المكافئة في المجال المكاني والدالة المكانية المدخلة.

وتكون نواة المرشح المكاني المكافئة هي تحويل فورييه العكسي لدالة نقل المرشح في مجال التردد.

يوضح الشكل 3.32(b) نواة المرشح المكاني المقابلة لدالة نقل المرشح في مجال التردد الموضحة في الشكل 3.32(a). وتظهر في الشكل بوضوح خصائص الرنين الخاصة بالنواة.

ويتمثل أحد الموضوعات الأساسية في نظرية تصميم المرشحات الرقمية في الحصول على تقريبات دقيقة (وعملية) للقطع الحاد الذي تتميز به مرشحات مجال التردد المثالية، مع تقليل خصائص الرنين الخاصة بها.

نبذة عن كيفية إنشاء نوى المرشحات المكانية

سنتناول في الأقسام التالية من هذا الفصل ثلاثة أساليب أساسية لإنشاء المرشحات المكانية.

الأسلوب الأول: بناء المرشحات اعتماداً على الخصائص الرياضية

يعتمد هذا الأسلوب على صياغة المرشحات استناداً إلى خصائص رياضية.

فعلى سبيل المثال، فإن المرشح الذي يحسب متوسط قيم البكسلات في منطقة مجاورة يؤدي إلى تغبيش الصورة.

ويُعد حساب المتوسط أمراً مشابهاً لعملية التكامل (Integration).

وعلى العكس من ذلك، فإن المرشح الذي يحسب المشتقة المحلية للصورة يؤدي إلى زيادة حدة الصورة (Sharpening).

وسنقدم العديد من الأمثلة على هذا الأسلوب في الأقسام التالية.

الأسلوب الثاني: أخذ عينات من دالة مكانية ثنائية الأبعاد

يعتمد الأسلوب الثاني على أخذ عينات من دالة مكانية ثنائية الأبعاد (2-D Spatial Function) يكون شكلها ذا خاصية مرغوبة.

فعلى سبيل المثال، سنوضح في القسم التالي أن أخذ عينات من دالة غاوسية (Gaussian Function) يمكن استخدامه لإنشاء مرشح متوسط موزون. (Weighted-Average / Lowpass Filter)

وفي بعض الأحيان، يتم إنشاء هذه الدوال المكانية ثنائية الأبعاد باعتبارها تحويل فورييه العكسي لمرشحات ثنائية الأبعاد محددة في مجال التردد.

وسنقدم عدة أمثلة على هذا الأسلوب في هذا الفصل والفصل التالي.

الأسلوب الثالث: تصميم مرشح مكاني باستجابة ترددية محددة

يتمثل الأسلوب الثالث في تصميم مرشح مكاني ذي استجابة ترددية محددة.

ويعتمد هذا الأسلوب على المفاهيم التي نوقشت في القسم السابق، ويندرج ضمن مجال تصميم المرشحات الرقمية (Digital Filter Design).

يتم الحصول على مرشح مكاني أحادي البعد (1-D) ذي الاستجابة المطلوبة، وعادةً ما يتم ذلك باستخدام برامج تصميم المرشحات.

ويمكن تمثيل قيم المرشح أحادي البعد على هيئة متجه v ، وبعد ذلك يمكن الحصول على نواة ثنائية الأبعاد قابلة للفصل (2-D Separable Kernel) باستخدام المعادلة (3-42).

أو يمكن تدوير المرشح أحادي البعد حول مركزه لإنشاء نواة ثنائية الأبعاد تقرب دالة متماثلة دائرياً (Circularly Symmetric Function).

وسنوضح هذه التقنيات في القسم 3.7.

3.5 المرشحات المكانية للتنعيم (تمرير منخفض)

تُستخدم المرشحات المكانية للتنعيم (Smoothing Spatial Filters)، والتي تُسمى أيضاً مرشحات المتوسط (Averaging Filters)، لتقليل الانتقالات الحادة في شدة الإضاءة.

ولأن الضوضاء العشوائية (Random Noise) تتكون عادةً من انتقالات حادة في...

شدة الإضاءة، فإن أحد التطبيقات الواضحة للتنعيم هو تقليل الضوضاء (Noise Reduction) كما يُعد إجراء التنعيم قبل إعادة أخذ عينات الصورة (Image Resampling) لتقليل التمرج (Aliasing)، كما ستم مناقشته في القسم 4.5، تطبيقاً شائعاً أيضاً.

ويُستخدم التنعيم لتقليل التفاصيل غير المهمة في الصورة، حيث تشير كلمة «غير مهمة» إلى مناطق البكسلات التي يكون حجمها صغيراً مقارنةً بحجم نواة المرشح (Filter Kernel).

ومن التطبيقات الأخرى للتنعيم تقليل الخطوط الكاذبة (False Contours) الناتجة عن استخدام عدد غير كافٍ من مستويات شدة الإضاءة في الصورة، كما نوقش في القسم 2.4.

تُستخدم مرشحات التنعيم بالاقتران مع تقنيات أخرى لتحسين الصور، مثل تقنيات معالجة المدرج التكراري (Histogram Processing) التي نوقشت في القسم 3.3، وكذلك القناع غير الحاد (Unsharp Masking) الذي ستم مناقشته لاحقاً في هذا الفصل.

سنبدأ مناقشة مرشحات التنعيم بدراسة مرشحات التنعيم الخطية (Linear Smoothing Filters) بشيء من التفصيل. وسنقدم لاحقاً في هذا القسم مرشحات التنعيم غير الخطية (Nonlinear Smoothing Filters).

كما ناقشنا في القسم 3.4، تتكون التصفية المكانية الخطية (Linear Spatial Filtering) من إجراء التفاف للصورة مع نواة المرشح.

ويؤدي إجراء التفاف نواة تنعيم (Smoothing Kernel) مع صورة إلى تغيّش الصورة (Blurring) ، حيث تتحدد درجة التغيّش من خلال حجم النواة وقيم معاملاتها.

وبالإضافة إلى كون مرشحات التمرير المنخفض مفيدة في عدد لا يحصى من تطبيقات معالجة الصور، فإنها تُعد أساسية، بمعنى أن مرشحات مهمة أخرى، بما في ذلك مرشحات زيادة الحدة (Sharpening / Highpass) ومرشحات تمرير النطاق (Bandpass) ومرشحات رفض النطاق (Bandreject) ، يمكن اشتقاقها من مرشحات التمرير المنخفض، كما سنوضح في القسم 3.7.

سنناقش في هذا القسم مرشحات التمرير المنخفض المعتمدة على النوى الصندوقية (Box Kernels) والنوى الغاوسية (Gaussian Kernels)، وكلاهما قابل للفصل (Separable).

وسيركز معظم النقاش على النوى الغاوسية بسبب خصائصها المفيدة العديدة واتساع نطاق تطبيقاتها. وسنقدم مرشحات تنعيم أخرى في الفصلين الرابع والخامس.

نوى المرشح الصندوقي (BOX FILTER KERNELS)

أبسط نواة لمرشح تمرير منخفض قابلة للفصل هي النواة الصندوقية (Box Kernel) ، حيث تكون جميع معاملاتها متساوية في القيمة (وعادةً ما تكون القيمة 1).

ويأتي اسم «النواة الصندوقية» من كون النواة الثابتة تشبه صندوقًا عند النظر إليها في صورة ثلاثية الأبعاد (3-D).

وقد عرضنا مرشحًا صندوقيًا بحجم 3×3 في الشكل 3.31(a).

ويكون المرشح الصندوقي بحجم $m \times n$ عبارة عن مصفوفة $m \times n$ مكوّنة من قيم جميعها تساوي 1، مع وجود ثابت تطبيع (Normalizing Constant) في المقدمة، وتكون قيمته مساوية لـ مقلوب مجموع قيم المعاملات؛ أي:

$$\frac{1}{mn}$$

عندما تكون جميع المعاملات مساوية لـ 1.

ويُطبّق هذا التطبيع (Normalization) على جميع نوى مرشحات التمرير المنخفض، وله غرضان:

أولاً: يجب أن تساوي القيمة المتوسطة لمنطقة ذات شدة إضاءة ثابتة شدة الإضاءة نفسها في الصورة التي تمت تصفيتها، وهذا هو السلوك الصحيح.

ثانياً: يمنع تطبيع النواة بهذه الطريقة إدخال انحياز (Bias) أثناء عملية التصفية؛ أي إن مجموع قيم البكسلات في الصورة الأصلية والصورة التي تمت تصفيتها سيكون متساويًا (انظر المسألة 3.31).

وبما أن جميع الصفوف والأعمدة في النواة الصندوقية متطابقة، فإن رتبة هذه النوى تساوي 1. وكما ناقشنا سابقاً، فإن ذلك يعني أنها قابلة للفصل (Separable).

المثال 3.11: التصفية بتمرير منخفض باستخدام نواة صندوقية

يوضح الشكل 3.33(a) صورة نمط اختبار بحجم 1024×1024 بكسل.

وتوضح الأشكال 3.33(b)–(d) النتائج التي تم الحصول عليها باستخدام مرشحات صندوقية بحجم $m \times m$ ، حيث:

$$m = 3, 11, 21$$

على التوالي.

عندما تكون $m = 3$ ، نلاحظ وجود **تغيبش عام طفيف** للصورة، مع تأثير خصائص الصورة التي تكون أحجامها مقاربة لحجم النواة بدرجة أكبر بكثير.

وتشمل هذه الخصائص **الخطوط الأكثر نحافة في الصورة** و**بكسلات الموضوعات الموجودة داخل المربعات في الجانب الأيمن من الصورة**.


كما تحتوي الصورة التي تمت تصفيتها على **حد رمادي رفيع**، وهو ناتج عن **إضافة حشو صفري (Zero-Padding)** إلى الصورة قبل إجراء التصفية.

وكما أشرنا سابقاً، يعمل الحشو على **تمديد حدود الصورة** لتجنب العمليات غير المعرفة عندما تقع أجزاء من النواة خارج **حدود الصورة**.

الشكل 3.33

أ) (نمط اختبار بحجم 1024×1024 بكسل).

ب) - (د) نتائج التصفية بمرشح تمرير منخفض باستخدام نوى صندوقية بأحجام 3×3 ، 11×11 ، و 21×21 ، على التوالي.



أثناء إجراء التصفية على الصورة. عند استخدام **الحشو الصفري (Zero Padding)**، تكون النتيجة النهائية لعملية التنعيم عند الحدود أو بالقرب منها عبارة عن **حد رمادي داكن**، وينشأ ذلك من إدخال البكسلات السوداء ضمن عملية حساب المتوسط.

أدى استخدام النواة 11×11 إلى **تغيبش أكثر وضوحاً** في جميع أنحاء الصورة، بما في ذلك ظهور حد داكن أكثر بروزاً.

أما النتيجة باستخدام النواة 21×21 ، فتظهر **تغيبشاً كبيراً لجميع مكونات الصورة**، بما في ذلك فقدان الشكل المميز لبعض المكونات؛ فعلى سبيل المثال، المربع الصغير الموجود في أعلى اليسار والشخصية الصغيرة الموجودة في أسفل اليسار.

وبصحب الحد الداكن الناتج عن **الحشو الصفري** أكثر سمكاً نسبياً مما كان عليه سابقاً.

لقد استخدمنا الحشو الصفري هنا، وسنستخدمه عدة مرات أخرى، حتى تتمكن من التعرف على تأثيراته وفهمها. وفي **المثال 3.14**، سنناقش طريقتين أخريين للحشو تعملان على إزالة **الأثر الاصطناعي للحد الداكن (Dark-Border Artifact)** الذي ينتج عادةً عن استخدام الحشو الصفري.

نوى مرشح التمرير المنخفض الغاوسي

(LOWPASS GAUSSIAN FILTER KERNELS)

نظراً لبساطتها، فإن **المرشحات الصندوقية (Box Filters)** مناسبة لإجراء التجارب السريعة، وغالباً ما تعطي نتائج تنعيم مقبولة من الناحية البصرية.

كما أنها مفيدة عندما يكون الهدف هو **تقليل تأثير التنعيم على الحواف** (انظر المثال 3.13).

ومع ذلك، فإن للمرشحات الصندوقية بعض القيود التي تجعلها خيارًا غير مناسب في العديد من التطبيقات.

فعلى سبيل المثال، غالبًا ما يتم نمذجة العدسة غير المركزة (Defocused Lens) باعتبارها مرشح تمرير منخفض، ولكن المرشحات الصندوقية تمثل تقريبات ضعيفة لخصائص التغبيش التي تحدثها العدسات (انظر المسألة 3.33).

ومن القيود الأخرى أن المرشحات الصندوقية تميل إلى تفضيل التغبيش على طول الاتجاهات المتعامدة.

وفي التطبيقات التي تتضمن صورًا ذات مستوى عالٍ من التفاصيل، ...

أو عندما تحتوي الصور على مكونات هندسية قوية، فإن الاتجاهية التي تتميز بها المرشحات الصندوقية غالبًا ما تؤدي إلى نتائج غير مرغوبة. يوضح المثال 3.13 هذه المشكلة. وهذان مجرد مثالين على التطبيقات التي لا تكون فيها المرشحات الصندوقية مناسبة.

إن النوى المفضلة في تطبيقات مثل تلك المذكورة للتو هي النوى المتماثلة دائريًا (Circularly Symmetric)، والتي تُسمى أيضًا متساوية الخواص (Isotropic)، أي إن استجابتها لا تعتمد على الاتجاه.

وكما اتضح، فإن النوى الغاوسية (Gaussian Kernels) من الشكل:

$$w(s, t) = G(s, t) = Ke^{-\frac{s^2+t^2}{2\sigma^2}} \quad (3-45)$$

هي النوى المتماثلة دائريًا الوحيدة التي تكون أيضًا قابلة للفصل. (Sahoo [1990]) (Separable)

وبالتالي، وبما أن النوى الغاوسية من هذا الشكل قابلة للفصل، فإن المرشحات الغاوسية تتمتع بالمزايا الحسابية نفسها التي تتمتع بها المرشحات الصندوقية، ولكنها تمتلك بالإضافة إلى ذلك مجموعة كبيرة من الخصائص الأخرى التي تجعلها مثالية لمعالجة الصور، كما سنتعلم في المناقشة التالية.

المتغيران s و t في المعادلة (3-45) هما أعداد حقيقية وعادةً ما تكون أعدادًا متقطعة.

وبفرض:

$$r = [s^2 + t^2]^{1/2}$$

يمكننا كتابة المعادلة (3-45) على الصورة:

$$G(r) = Ke^{-\frac{r^2}{2\sigma^2}} \quad (3-46)$$

وهذا الشكل المكافئ يبسط اشتقاق التعبيرات التي ستظهر لاحقًا في هذا القسم.

كما يذكرنا هذا الشكل بأن الدالة متماثلة دائريًا.

يمثل المتغير r المسافة من المركز إلى أي نقطة على الدالة G .

يوضح الشكل 3.34 قيم r -لعدة أحجام من النوى، باستخدام قيم صحيحة للمتغيرين s و t .

ولأننا نستخدم عمومًا أحجامًا فردية للنوى، فإن مراكز هذه النوى تقع عند قيم صحيحة، ومن ثم فإنه من الطبيعي أن تكون جميع قيم r^2 أعدادًا صحيحة أيضًا.


ويمكنك ملاحظة ذلك من خلال تربيع القيم الموضحة في الشكل 3.34.

ينصب اهتمامنا هنا بشكل صارم على الشكل الجرسى للدالة الغاوسية؛ ولذلك، نستغني عن المعامل التقليدي لدالة الكثافة الاحتمالية الغاوسية (Gaussian PDF)، ونستخدم بدلاً منه ثابتًا عامًا K .

وتذكر أن σ يتحكم في مدى انتشار الدالة الغاوسية حول متوسطها.

الشكل 3.34

المسافات من المركز
لأحجام مختلفة من النوى
المربعة.



(للاطلاع على برهان رسمي، انظر. [Padfield 2011])

لاحظ بشكل خاص أن مربع المسافة إلى نقاط الزوايا لنواة بحجم $m \times m$ يُعطى بالعلاقة:

$$r_{\max}^2 = \left(\frac{m-1}{2}\right)^2 + \left(\frac{m-1}{2}\right)^2 = \frac{(m-1)^2}{2} \quad (3-47)$$

تم الحصول على النواة الموضحة في الشكل (b) 3.31 من خلال أخذ عينات من المعادلة (3-45)، مع $K = 1$ و $\sigma = 1$.

يوضح الشكل (a) 3.35 رسمًا منظوريًا لدالة غاوسية، ويوضح أن العينات المستخدمة لإنشاء تلك النواة تم الحصول عليها من خلال تحديد قيم t ، ثم قراءة قيم الدالة عند تلك الإحداثيات. وتمثل هذه القيم معاملات النواة.

ويكتمل تحديد النواة من خلال تطبيعها، وذلك بقسمة معاملاتها على مجموع هذه المعاملات. وأسباب إجراء هذا التطبيع هي نفسها التي تمت مناقشتها فيما يتعلق بالنوى الصندوقية.

وبما أن النوى الغاوسية قابلة للفصل، فيمكننا ببساطة أخذ عينات على طول مقطع عرضي يمر عبر مركز النواة، واستخدام هذه العينات لتكوين المتجه r في المعادلة (3-42)، ومنه نحصل على النواة ثنائية الأبعاد.

تُعد قابلية الفصل واحدة من العديد من الخصائص الأساسية للنوى الغاوسية المتماثلة دائريًا.

فعلى سبيل المثال، نعلم أن قيم الدالة الغاوسية عند مسافة أكبر من 3σ عن المتوسط تكون صغيرة بدرجة كافية بحيث يمكن إهمالها.

وهذا يعني أنه إذا اخترنا حجم النواة الغاوسية ليكون:

$$[6\sigma] \times [6\sigma]$$

(يُستخدم الترميز $[c]$ للدلالة على دالة السقف (Ceiling Function) للعدد c ، أي أصغر عدد صحيح لا يقل عن c)، فإننا نضمن الحصول على نتيجة مطابقة تقريبًا للنتيجة التي كنا سنحصل عليها باستخدام نواة غاوسية كبيرة بشكل اعتباطي.

وبطريقة أخرى، تخبرنا هذه الخاصية بأنه لا توجد فائدة من استخدام نواة غاوسية أكبر من:

$$[6\sigma] \times [6\sigma]$$

في معالجة الصور.

وبما أننا نعمل عادةً باستخدام نوى ذات أبعاد فردية، فإننا نستخدم أصغر عدد صحيح فردي يحقق هذا الشرط؛ فعلى سبيل المثال، نستخدم نواة بحجم 43×43 عندما تكون $\sigma = 7$.

هناك خاصيتان أساسيتان أخريان للدوال الغاوسية، وهما أن حاصل ضرب دالتين غاوسيتين والتفافهما هما أيضًا دالتان غاوسيتان.

يوضح الجدول 3.6 المتوسط والانحراف المعياري لحاصل ضرب والتفاف دالتين غاوسيتين أحاديتي البعد، gof .

وتذكر أنه بسبب قابلية الفصل، نحتاج فقط إلى دالة غاوسية أحادية البعد لتكوين دالة ثنائية الأبعاد متماثلة دائريًا.

أما المتوسط والانحراف المعياري...

ملاحظة: لا تستطيع النوى الغاوسية الصغيرة التقاط الشكل الجرسى المميز للدالة الغاوسية، ولذلك فإنها تتصرف بصورة أقرب إلى النوى الصندوقية.

وكما سنناقش أدناه، فإن الحجم العملي للنوى الغاوسية يكون في حدود:

$$6\sigma \times 6\sigma$$


وكما أوضحنا في القسم 2.6، فإن الرمز $[0]$ يشير إلى دالتي السقف والأرضية (Ceiling and Floor Functions).

أي إن دالة السقف ودالة الأرضية تحولان عددًا حقيقيًا إلى أصغر عدد صحيح أكبر منه أو يساويه، أو أكبر عدد صحيح أصغر منه أو يساويه، على التوالي.

يتم تبسيط براهين النتائج الواردة في الجدول 3.6 من خلال العمل باستخدام تحويل فورييه ومجال التردد، وكلاهما...

الشكل 3.35

(أ) أخذ عينات من دالة غاوسية للحصول على نواة غاوسية متقطعة. القيم الموضحة هي عندما تكون $K = 1$ و $\sigma = 1$.



0.3679	0.6065	0.3679
0.6065	1.0000	0.6065
0.3679	0.6065	0.3679

$$\frac{1}{4.8976} \times$$

الجدول 3.6

المتوسط والانحراف المعياري لحاصل ضرب ($\times$) والتفاف ($*$) لدالتين غاوسيتين أحاديتي البعد gof .

وتتعمم هذه النتائج مباشرةً على حاصل ضرب والتفاف أكثر من دالتين غاوسيتين أحاديتي البعد (انظر المسألة 3.25).

	f	g	$f \times g$	$f \star g$
Mean	m_f	m_g	$m_{f \times g} = \frac{m_f \sigma_g^2 + m_g \sigma_f^2}{\sigma_f^2 + \sigma_g^2}$	$m_{f \star g} = m_f + m_g$
Standard deviation	σ_f	σ_g	$\sigma_{f \times g} = \sqrt{\frac{\sigma_f^2 \sigma_g^2}{\sigma_f^2 + \sigma_g^2}}$	$\sigma_{f \star g} = \sqrt{\sigma_f^2 + \sigma_g^2}$

... تحدد الدالة الغاوسية بشكل كامل، ولذلك فإن المعلومات الواردة في الجدول 3.6 تخبرنا بكل ما نحتاج إلى معرفته عن الدوال الناتجة عن ضرب الدوال الغاوسية والتفافها.

وكما هو موضح في المعادلتين (3-45) و(3-46)، فإن النوى الغاوسية لها متوسط يساوي صفراً، ولذلك ينصب اهتمامنا هنا على الانحرافات المعيارية.

وتكتسب نتيجة الالتفاف أهمية خاصة في مجال التصنيف. فعلى سبيل المثال، ذكرنا عند مناقشة المعادلة (3-43) أن التصنيف تُجرى أحياناً على مراحل متتالية، وأنه يمكن الحصول على النتيجة نفسها من خلال إجراء التصنيف في مرحلة واحدة باستخدام نواة مركبة (Composite Kernel) يتم تكوينها باعتبارها التوافقاً للنوى الفردية.

وإذا كانت هذه النوى غاوسية، فيمكننا استخدام النتيجة الواردة في الجدول 3.6 — والتي، كما أشرنا، تتعمم مباشرةً على أكثر من دالتين — لحساب الانحراف المعياري للنواة المركبة (وبالتالي تحديدها بالكامل) دون الحاجة فعلياً إلى إجراء الالتفاف بين جميع النوى الفردية.

المثال 3.12: التصنيفية بتمرير منخفض باستخدام نواة غاوسية

لمقارنة التصنيفية باستخدام النواة الغاوسية والتصنيفية باستخدام النواة الصندوقية، نعيد تنفيذ المثال 3.11 باستخدام نواة غاوسية.

يجب أن تكون النوى الغاوسية أكبر حجماً من النوى الصندوقية لتحقيق الدرجة نفسها من التغبيش.

ويرجع ذلك إلى أن النواة الصندوقية، في حين أنها تعطي الوزن نفسه لجميع البكسلات، فإن قيم معاملات النواة الغاوسية — وبالتالي تأثيرها — تتناقص كلما زادت المسافة عن مركز النواة.

وكما أوضحنا سابقاً، نستخدم حجماً يساوي أقرب عدد صحيح فردي إلى:

$$[6\sigma] \times [6\sigma]$$

وبالتالي، بالنسبة إلى نواة غاوسية بحجم 21×21 ، وهو حجم النواة التي استخدمناها لإنشاء الشكل 3.33(d)، نحتاج إلى:

$$\sigma = 3.5$$

يوضح الشكل 3.36(b) نتيجة تطبيق التصنيفية بتمرير منخفض على نمط الاختبار باستخدام هذه النواة.

وبمقارنة هذه النتيجة مع الشكل 3.33(d)، نلاحظ أن النواة الغاوسية أدت إلى تغبيش أقل بكثير.

ومن خلال إجراء بعض التجارب البسيطة، يتضح أننا نحتاج إلى:

$$\sigma = 7$$

للحصول على نتائج مماثلة.

وهذا يعني استخدام نواة غاوسية بحجم:

$$43 \times 43$$

ويوضح الشكل 3.36(c) نتائج تصنيفية نمط الاختبار باستخدام هذه النواة.

ویمقارنتها مع الشكل (d) 3.33، نلاحظ أن النتائج متقاربة جداً بالفعل.

ذكرنا سابقاً أنه لا توجد فائدة تُذكر من استخدام نواة غاوسية أكبر من:

$$[6\sigma] \times [6\sigma]$$

ولإثبات ذلك، قمنا بتصفية نمط الاختبار الموضح في الشكل (a) 3.36 باستخدام نواة غاوسية ذات:

$$\sigma = 7$$

مرة أخرى، ولكن هذه المرة بحجم:

$$85 \times 85$$

الشكل (a) 3.37 هو نفسه الشكل (c) 3.36، والذي قمنا بإنشائه باستخدام أصغر نواة فردية تحقق شرط:

$$[6\sigma] \times [6\sigma]$$

أي نواة بحجم 43×43 عندما تكون $\sigma = 7$.

أما الشكل (b) 3.37 فيوضح نتيجة استخدام النواة 85×85 ، وهي ضعف حجم النواة الأخرى.


وكما يمكنك ملاحظة ذلك، لا توجد إضافة ملحوظة يمكن تمييزها...

الشكل 3.36

(أ) نمط اختبار بحجم 1024×1024 بكسل.

(ب) نتيجة تطبيق التصفية بمرشح تمرير منخفض على نمط الاختبار باستخدام نواة غاوسية بحجم 21×21 ، وبانحراف معياري $\sigma = 3.5$.

(ج) نتيجة استخدام نواة بحجم 43×43 ، وبانحراف معياري $\sigma = 7$. وهذه النتيجة قابلة للمقارنة مع الشكل (d) 3.33. تم استخدام $K = 1$ في جميع الحالات.



الشكل 3.36

(أ) نمط اختبار بحجم 1024×1024 بكسل.

(ب) نتيجة تطبيق التصفية بمرشح تمرير منخفض على نمط الاختبار باستخدام نواة غاوسية بحجم 21×21 ، وبانحراف معياري $\sigma = 3.5$.

(ج) نتيجة استخدام نواة بحجم 43×43 ، وبانحراف معياري $\sigma = 7$. وهذه النتيجة قابلة للمقارنة مع الشكل (d) 3.33.

تم استخدام $K = 1$ في جميع الحالات.

لم يحدث أي **تغيبش إضافي ملحوظ**. وفي الواقع، تشير صورة الفرق في الشكل (c) 3.37 إلى أن الصورتين متطابقتان تقريباً، حيث بلغ أقصى فرق بينهما 0.75، وهو أقل من مستوى واحد من أصل 256 مستوى (لأن هذه الصور ذات 8 بت).

المثال 3.13: مقارنة خصائص التنعيم باستخدام المرشحات الغاوسية والصندوقية

أظهرت النتائج في المثالين 3.11 و 3.12 وجود فرق بصري طفيف في درجة التغيبش.

وعلى الرغم من ذلك، توجد بعض الاختلافات الدقيقة التي لا تظهر للوهلة الأولى.

فعلى سبيل المثال، قارن الحرف الكبير «a» في الشكلين (d) 3.33 و (c) 3.36؛ إذ إن الحرف في الشكل الأخير يبدو أكثر نعومة حول حوافه.

يوضح الشكل 3.38 هذا النوع من الاختلاف في السلوك بين النوى الصندوقية والنوى الغاوسية بصورة أكثر وضوحاً.


كانت صورة المستطيل...



الشكل 3.37

(أ) نتيجة تصفية الشكل (a) 3.36 باستخدام نواة غاوسية بحجم 43×43 ، وبانحراف معياري $\sigma = 7$.

(ب) نتيجة استخدام نواة بحجم 85×85 ، مع استخدام القيمة نفسها للانحراف المعياري $\sigma = 7$.



الشكل 3.38

(أ) صورة لمستطيل أبيض على خلفية سوداء، ومنحنى شدة إضاءة أفقي على طول خط المسح الموضح بخط منقط.

(ب) نتيجة تنعيم هذه الصورة باستخدام نواة صندوقية بحجم 71×71 ، مع منحنى شدة الإضاءة المقابل.

(ج) نتيجة تنعيم الصورة باستخدام نواة غاوسية بحجم 151×151 ، مع $K = 1$ و $\sigma = 25$. لاحظ نعومة منحنى شدة الإضاءة في (ج) مقارنةً بـ (ب).

يبلغ حجم الصورة 1024×1024 بكسل، بينما يبلغ حجم المستطيل 768×128 بكسل.

تم تنعيم المستطيل باستخدام **نواة صندوقية** و**نواة غاوسية**، بالأحجام والمعلومات الموضحة في الشكل. وقد تم اختيار هذه المعلومات للحصول على مستطيلات مموهة ذات عرض وارتفاع متقاربين تقريباً، وذلك من أجل إظهار تأثيرات المرشحين على أساس قابل للمقارنة.

وكما توضح **منحنيات شدة الإضاءة (Intensity Profiles)** ، أنتج المرشح الصندوقي **تنعيمًا خطيًا**، حيث يأخذ الانتقال من اللون الأسود إلى اللون الأبيض (أي عند الحافة) شكل **منحدر (Ramp)**.

وتتمثل الخصائص المهمة هنا في وجود **انتقالات حادة** عند بداية المنحدر ونهايته.

ونستخدم هذا النوع من المرشحات عندما نرغب في الحصول على **تنعيم أقل للحواف**.

وعلى العكس، أعطى المرشح الغاوسي نتائج أكثر **نعومة بشكل ملحوظ عند مناطق انتقال الحواف**.

ونستخدم هذا النوع من المرشحات عندما يكون المطلوب الحصول على **تنعيم متجانس بشكل عام**.

كما توضح النتائج في الأمثلة **3.11 و 3.12 و 3.13**، فإن استخدام **الحشو الصفري (Zero Padding)** للصورة يؤدي إلى ظهور **حدود داكنة** في النتيجة التي تمت تصفيتها، ويعتمد سمك هذه الحدود على **حجم ونوع نواة المرشح المستخدمة**.

وفي وقت سابق، عند مناقشة **الارتباط والالتفاف (Correlation and Convolution)** ، أشرنا إلى طريقتين أخريين لحشو الصورة:

- **الحشو بالانعكاس (Mirror Padding)** ، ويُسمى أيضًا **الحشو المتماثل (Symmetric Padding)** ، حيث يتم الحصول على القيم الواقعة خارج حدود الصورة من خلال **عكس الصورة مرآتيًا عبر حدودها**.
- **حشو التكرار (Replicate Padding)** ، حيث يتم تعيين القيم الواقعة خارج حدود الصورة لتكون مساوية لقيمة **أقرب بكسل على حدود الصورة**.

ويكون النوع الأخير من الحشو مفيدًا عندما تكون المناطق القريبة من حدود الصورة **ثابتة**.

وعلى العكس، يكون **الحشو بالانعكاس** أكثر ملاءمة عندما تحتوي المناطق القريبة من حدود الصورة على **تفاصيل**.

وبعبارة أخرى، تحاول هاتان الطريقتان من الحشو «**تمديد**» **خصائص الصورة إلى ما بعد حدودها**.

يوضح الشكل **3.39** طرق الحشو هذه، كما يوضح تأثيرات **التنعيم الأكثر شدة**.

توضح الأشكال من **(a) 3.39 إلى (c) 3.39** نتائج تصفية الشكل **(a) 3.36** باستخدام نواة غاوسية مكونة من 187×187 عنصرًا، مع $K = 1$ و $\sigma = 31$ ، وذلك باستخدام **الحشو الصفري، والحشو بالانعكاس، وحشو التكرار**، على التوالي.

وتكون الاختلافات بين **حدود النتيجة الناتجة عن الصورة ذات الحشو الصفري** والنتائج الناتجة باستخدام الطريقتين الأخريين واضحة...



a b c

وتشير النتائج أيضاً إلى أن الحشو بالانعكاس (Mirror Padding) وحشو التكرار (Replicate Padding) يعطيان نتائج أكثر جاذبية من الناحية البصرية، وذلك من خلال إزالة الحدود الداكنة الناتجة عن الحشو الصفري (Zero Padding).

المثال 3.14: أداء التنعيم كدالة في حجم النواة وحجم الصورة

تعتمد كمية التغبيش النسبية التي تنتجها نواة تنعيم ذات حجم معين بشكل مباشر على حجم الصورة.

ولتوضيح ذلك، يوضح الشكل (a) 3.40 نمط الاختبار نفسه الذي استُخدم سابقاً، ولكن بحجم 4096×4096 بكسل، أي أكبر بأربع مرات في كل بُعد مقارنةً بالحجم السابق.

يوضح الشكل (b) 3.40 نتيجة تصفية هذه الصورة باستخدام النواة الغاوسية نفسها وطريقة الحشو نفسها المستخدمة في الشكل (b) 3.39.

وبالمقارنة، تُظهر الصورة السابقة تغبيشاً أقل بكثير عند استخدام مرشح بالحجم نفسه.

وفي الواقع، يبدو الشكل (b) 3.40 أشبه بـ...



الشكل 3.40

(أ) نمط اختبار بحجم 4096×4096 بكسل.

(ب) نتيجة تصفية نمط الاختبار باستخدام النواة الغاوسية نفسها المستخدمة في الشكل 3.39.

... الصورة في الشكل (d) 3.36، التي تمت تصفيتها باستخدام نواة غاوسية بحجم 43×43 .

وللحصول على نتائج قابلة للمقارنة مع الشكل (b) 3.39، يتعين علينا زيادة حجم النواة والانحراف المعياري للنواة الغاوسية بمقدار أربعة أضعاف، وهو العامل نفسه الذي زادت به أبعاد الصورة.

وينتج عن ذلك نواة بحجم فردي:

$$745 \times 745$$

مع:

$$K = 1, \sigma = 124$$

يوضح الشكل (c) 3.40 نتيجة استخدام هذه النواة مع الحشو بالانعكاس (Mirror Padding)

وهذه النتيجة مشابهة جدًا للشكل (b) 3.39

وقد يبدو هذا الأمر، بعد معرفته، ملاحظة بسيطة أو بديهية، ولكن من المدهش مدى تكرار أن يؤدي عدم فهم العلاقة بين حجم النواة وحجم الأجسام الموجودة في الصورة إلى أداء غير فعال لخوارزميات التصفية المكانية.

المثال 3.15: استخدام التصفية بتمرير منخفض وعتبة الشدة لاستخراج المناطق

الشكل (a) 3.41 عبارة عن صورة من تلسكوب هابل بحجم 2758×2566 بكسل، لمجموعة Hickson Compact Group (انظر تعليق الشكل)، وقد تمت إعادة تحجيم قيم شدتها إلى النطاق:

$$[0, 1]$$

هدفنا هو توضيح استخدام التصفية بتمرير منخفض بالاقتران مع تحديد عتبة الشدة (Intensity Thresholding) للتخلص من التفاصيل غير المهمة في هذه الصورة.

وفي هذا السياق، تشير كلمة «غير مهمة» إلى مناطق البكسلات التي يكون حجمها صغيرًا مقارنةً بحجم النواة.

الشكل (b) 3.41 هو نتيجة تصفية الصورة الأصلية باستخدام نواة غاوسية بحجم:

$$151 \times 151$$

أي ما يقارب 6% من عرض الصورة، وبانحراف معياري:

$$\sigma = 25$$

وقد اخترنا قيم هذه المعلمات من أجل إنشاء شكل غاوسي أكثر حدة وانتقائية مقارنةً بالشكل الغاوسي الذي استخدمناه في الأمثلة السابقة.

تُظهر الصورة التي تمت تصفيتها أربع مناطق يغلب عليها السطوع.

ونرغب في استخراج هذه المناطق فقط من الصورة.

الشكل (c) 3.41 هو نتيجة تطبيق تحديد العتبة على الصورة التي تمت تصفيتها باستخدام عتبة:

$$T = 0.4$$

(سنناقش اختيار العتبة في الفصل العاشر).

وكما يوضح الشكل، نجحت هذه الطريقة في استخراج المناطق الأربع محل الاهتمام بشكل فعال، والتخلص من التفاصيل التي اعتُبرت غير مهمة في هذا التطبيق.

المثال 3.16: تصحيح التظليل باستخدام التصفية بتمرير منخفض

يُعد عدم انتظام الإضاءة أحد الأسباب الرئيسية لتظليل الصورة.


وتُعد عملية تصحيح التظليل (Shading Correction)، والتي تُسمى أيضًا تصحيح المجال المسطح (Flat-Field Correction)، مهمة لأن التظليل يُعد سببًا شائعًا في:

- إجراء قياسات غير صحيحة.

• انخفاض أداء خوارزميات تحليل الصور الآلية.

• صعوبة تفسير الصور.

...



a b c

الشكل 3.41

أ (صورة من تلسكوب هابل بحجم 2758×2566 بكسل لمجموعة هيكسون المدمجة (Hickson Compact Group))

ب (نتيجة تطبيق التصفية بمرشح تمرير منخفض باستخدام نواة غاوسية).

ج (نتيجة تطبيق تحديد العتبة (Thresholding) على الصورة التي تمت تصفيتها، مع تحجيم قيم الشدة إلى النطاق $[0, 1]$).

تحتوي مجموعة هيكسون المدمجة على مجرات قزمة اجتمعت معاً، مما أدى إلى نشوء آلاف العناقيد النجمية الجديدة.

المصدر: الصورة الأصلية مقدمة من وكالة ناسا (NASA)



a b c

الشكل 3.42

أ (صورة متأثرة بالتظليل بواسطة نمط تظليل موجّه في اتجاه -45°).

ب (تقدير نمط التظليل الذي تم الحصول عليه باستخدام التصفية بمرشح تمرير منخفض).

بواسطة البشر. وقد قدمنا تصحيح التظليل (Shading Correction) في المثال 2.7، حيث قمنا بتصحيح صورة مظلمة من خلال قسمتها على نمط التظليل. وفي ذلك المثال، كان نمط التظليل معطًى مسبقاً.

لكن في كثير من الأحيان، لا يكون الأمر كذلك في التطبيقات العملية، ونواجه الحاجة إلى تقدير نمط التظليل مباشرةً من العينات المتاحة للصور المظلمة.

تُعد التصفية بمرشح تمرير منخفض (Lowpass Filtering) طريقة بسيطة وفعالة لتقدير أنماط التظليل.

لنفترض صورة رقعة شطرنج (Checkerboard) بحجم 2048×2048 بكسل، كما في الشكل 3.42(a)، حيث يبلغ حجم المربعات الداخلية 128×128 بكسل.

الشكل 3.42(b) هو نتيجة تطبيق التصفية بمرشح تمرير منخفض على الصورة باستخدام نواة غاوسية بحجم 512×512 ، أي أربعة أضعاف حجم المربعات، مع:

$$K = 1, \sigma = 128$$

حيث إن σ يساوي حجم المربعات.

وتكون هذه النواة كبيرة بما يكفي لإزالة المربعات عن طريق التغبيش (Blur-out) ؛ إذ إن استخدام نواة بحجم يعادل ثلاثة أضعاف حجم المربعات لا يكون كافياً لتغبيشها بدرجة مناسبة.

وتُعد هذه النتيجة تقريباً جيداً لنمط التظليل الظاهر في الشكل 3.42(a).

وأخيراً، يمثل الشكل 3.42(c) نتيجة قسمة الصورة (أ) على الصورة (ب).

وعلى الرغم من أن النتيجة ليست مسطحة تماماً، فإنها تمثل بالتأكيد تحسناً مقارنةً بالصورة المظلمة.

في مناقشة النوى القابلة للفصل (Separable Kernels) في القسم 3.4، أشرنا إلى أن الميزة الحسابية للنوى القابلة للفصل يمكن أن تكون كبيرة، خاصةً عند استخدام النوى الكبيرة.

وبالاعتماد على المعادلة (3-44)، نجد أن الميزة الحسابية للنواة المستخدمة في هذا المثال — والتي هي بالطبع نواة قابلة للفصل — تبلغ:

$$262:1$$

أي أن استخدام النواة القابلة للفصل يوفر ميزة حسابية بنسبة 262 إلى 1 مقارنةً بنواة غير قابلة للفصل.

وبالنظر إلى زمن الحساب، إذا استغرق الأمر 30 ثانية لمعالجة مجموعة من الصور المشابهة للصورة في الشكل 3.42(b) باستخدام المكونين أحاديي البعد القابلين للفصل للنواة الغاوسية، فإن تحقيق النتيجة نفسها باستخدام نواة تمرير منخفض غير قابلة للفصل كان سيستغرق حوالي 2.2 ساعة.

وينطبق الأمر نفسه إذا استخدمنا النواة الغاوسية ثنائية الأبعاد مباشرةً دون تحليلها إلى مكوناتها القابلة للفصل.

مرشحات إحصاء الترتيب (المرشحات غير الخطية)

(ORDER-STATISTIC (NONLINEAR) FILTERS)

مرشحات إحصاء الترتيب هي مرشحات مكانية غير خطية، تعتمد استجاباتها على ترتيب (تصنيف) البكسلات الموجودة ضمن المنطقة التي يغطيها المرشح.

ويتحقق التنعيم من خلال استبدال قيمة البكسل المركزي بالقيمة التي يتم تحديدها بناءً على نتيجة الترتيب.

وأشهر مرشح في هذه الفئة هو المرشح الوسيط (Median Filter)، والذي، كما يدل اسمه، يستبدل قيمة البكسل المركزي بـ الوسيط لقيم الشدة الموجودة في جوار ذلك البكسل، مع احتساب قيمة البكسل المركزي ضمن هذه القيم.

in computing the median). Median filters provide excellent noise reduction capabilities for certain types of random noise, with considerably less blurring than linear smoothing filters of similar size. Median filters are particularly effective in the presence of *impulse noise* (sometimes called *salt-and-pepper noise*, when it manifests itself as white and black dots superimposed on an image).

The *median*, ξ , of a set of values is such that half the values in the set are less than or equal to ξ and half are greater than or equal to ξ . In order to perform median filtering at a point in an image, we first sort the values of the pixels in the neighborhood, determine their median, and assign that value to the pixel in the filtered image corresponding to the center of the neighborhood. For example, in a 3×3 neighborhood the median is the 5th largest value, in a 5×5 neighborhood it is the 13th largest value, and so on. When several values in a neighborhood are the same, all equal values are grouped. For example, suppose that a 3×3 neighborhood has values (10, 20, 20, 20, 15, 20, 20, 25, 100). These values are sorted as (10, 15, 20, 20, 20, 20, 20, 25, 100), which results in a median of 20. Thus, the principal function of median filters is to force points to be more like their neighbors. Isolated clusters of pixels that are light or dark with respect to their neighbors, and whose area is less than $m^2/2$ (one-half the filter area), are forced by an $m \times m$ median filter to have the value of the median intensity of the pixels in the neighborhood (see Problem 3.36).

The median filter is by far the most useful order-statistic filter in image processing, but is not the only one. The median represents the 50th percentile of a ranked set of numbers, but ranking lends itself to many other possibilities. For example, using the 100th percentile results in the so-called *max filter*, which is useful for finding the brightest points in an image or for eroding dark areas adjacent to light regions. The response of a 3×3 max filter is given by $R = \max\{z_k \mid k = 1, 2, 3, \dots, 9\}$. The 0th percentile filter is the *min filter*, used for the opposite purpose. Median, max, min, and several other nonlinear filters will be considered in more detail in Section 5.3.

EXAMPLE 3.17: Median filtering.

Figure 3.43(a) shows an X-ray image of a circuit board heavily corrupted by salt-and-pepper noise. To illustrate the superiority of median filtering over lowpass filtering in situations such as this, we show in Fig. 3.43(b) the result of filtering the noisy image with a Gaussian lowpass filter, and in Fig. 3.43(c) the result of using a median filter. The lowpass filter blurred the image and its noise reduction performance was poor. The superiority in all respects of median over lowpass filtering in this case is evident.

3.6 SHARPENING (HIGHPASS) SPATIAL FILTERS

Sharpening highlights transitions in intensity. Uses of image sharpening range from electronic printing and medical imaging to industrial inspection and autonomous guidance in military systems. In Section 3.5, we saw that image blurring could be accomplished in the spatial domain by pixel averaging (smoothing) in a neighborhood. Because averaging is analogous to integration, it is logical to conclude that sharpening can be accomplished by spatial differentiation. In fact, this is the case, and the following discussion deals with various ways of defining and implementing operators for sharpening by digital differentiation. The strength of the response of

الفصل 3: تحويلات الشدة والترشيح المكاني

3.6 مرشحات الشد (المرشحات المكانية عالية التمرير)

يقدم مرشح الوسيط (Median Filter) قدرات ممتازة في تقليل الضوضاء لبعض أنواع الضوضاء العشوائية، مع حدوث طمس أقل بكثير من مرشحات التنعيم الخطية ذات الحجم المماثل. وتكون مرشحات الوسيط فعالة بشكل خاص في وجود ضوضاء النبضات (Impulse Noise)، والتي تُسمى أحياناً ضوضاء الملح والفلفل (Salt-and-Pepper Noise)، عندما تظهر على شكل نقاط بيضاء وسوداء متراكبة على الصورة.

الوسيط، ويرمز له بـ $\tilde{z}$ ، لمجموعة من القيم هو القيمة التي يكون نصف القيم في المجموعة أقل من أو يساوي $\tilde{z}$ ، والنصف الآخر أكبر من أو يساوي $\tilde{z}$. ولإجراء ترشيح الوسيط عند نقطة في الصورة، نقوم أولاً بفرز قيم البكسلات الموجودة في الجوار، ثم نحدد وسيطها، ونسند تلك القيمة إلى البكسل الموجود في مركز الجوار في الصورة الناتجة عن الترشيح.

على سبيل المثال، في جوار بحجم 3×3 يكون الوسيط هو القيمة الخامسة بعد الترتيب، وفي جوار بحجم 5×5 يكون الوسيط هو القيمة الثالثة عشرة، وهكذا.

عندما تكون عدة قيم متساوية في الجوار، فإن جميع القيم المتساوية تُجمع معاً. على سبيل المثال، افترض أن جواراً بحجم 3×3 يحتوي على القيم:

(10, 20, 20, 20, 15, 20, 20, 25, 100)

بعد ترتيب هذه القيم تصبح:

(10, 15, 20, 20, 20, 20, 20, 25, 100)

وبالتالي فإن الوسيط هو 20.

إذن، فإن المبدأ الأساسي لمرشح الوسيط هو إجبار النقاط ذات القيم الشاذة على أن تصبح أكثر تشابهاً مع جيرانها. كما أن التجمعات المعزولة من البكسلات التي تكون فاتحة أو داكنة مقارنةً بجيرانها، والتي تكون مساحتها أقل من $m^2 / 2$ أي نصف مساحة المرشح، يتم إجبارها بواسطة مرشح وسيط بحجم $m \times m$ على أخذ قيمة وسيط شدة البكسلات الموجودة في الجوار (انظر

المسألة 3.36).

يُعد مرشح الوسيط، بفارق كبير، أكثر المرشحات الإحصائية المرتبة فائدةً في معالجة الصور، ولكنه ليس المرشح الوحيد. فالوسيط يمثل النسبة المئوية الخمسين (50th percentile) لمجموعة مرتبة من الأعداد، ولكن ترتيب الرتب يتيح لنا استخدام احتمالات أخرى أيضاً.

فعلى سبيل المثال، يؤدي استخدام النسبة المئوية المئة (100th percentile) إلى ما يسمى مرشح القيمة العظمى (Max Filter)، وهو مفيد للعثور على أكثر النقاط سطوعاً في الصورة أو لتوسيع المناطق الداكنة المجاورة للمناطق المضيئة.

وتكون استجابة مرشح القيمة العظمى بحجم 3×3 :

$$R = \max \{ z_k \mid k = 1, 2, 3, \dots, 9 \}$$

أما النسبة المئوية الصفرية (0th percentile) فتؤدي إلى مرشح القيمة الصغرى (Min Filter)، ويُستخدم للغرض المعاكس.

سيتم تناول مرشحات الوسيط والقيمة العظمى والقيمة الصغرى وغيرها من المرشحات غير

الخطية بمزيد من التفصيل في القسم 5.3.

مثال 3.17: ترشيح الوسيط (Median Filtering)

يوضح الشكل 3.43(a) صورة أشعة سينية للوحة دائرة إلكترونية متضررة بشدة بسبب ضوضاء

الملح والفلل.

لتوضيح تفوق ترشيح الوسيط على الترشيح منخفض التمرير في مثل هذه الحالات، نعرض في الشكل (b) 3.43 نتيجة ترشيح الصورة المشوشة باستخدام مرشح غاوسي منخفض التمرير (Gaussian Lowpass Filter)، وفي الشكل (c) 3.43 نتيجة استخدام مرشح الوسيط (Median Filter).

كان مرشح التمرير المنخفض يؤدي إلى طمس الصورة، كما أن أدائه في تقليل الضوضاء كان ضعيفاً. ومن الواضح تفوق مرشح الوسيط على مرشح التمرير المنخفض في جميع الجوانب في هذه الحالة.

3.6 الشد (المرشحات المكانية عالية التمرير)

يعمل الشد (Sharpening) على إبراز الانتقالات في شدة الإضاءة. وتتراوح تطبيقات شد الصور من الطباعة الإلكترونية والتصوير الطبي إلى الفحص الصناعي وأنظمة التوجيه الذاتي في الأنظمة العسكرية.

في القسم 3.5، رأينا أن طمس الصورة (Image Blurring) يمكن تحقيقه في المجال المكاني عن طريق حساب متوسط قيم البكسلات في منطقة الجوار، أي باستخدام التنعيم (Smoothing). وبما أن حساب المتوسط يشبه عملية التكامل (Integration)، فمن المنطقي أن نستنتج أن الشد يمكن تحقيقه باستخدام التفاضل (Differentiation) المكاني. وفي الواقع، هذا هو الحال، والمناقشة التالية تتناول طرقاً مختلفة لتعريف وتنفيذ المؤثرات المستخدمة في شد الصور باستخدام التفاضل الرقمي. وتعتمد قوة استجابة...




FIGURE 3.43 (a) X-ray image of a circuit board, corrupted by salt-and-pepper noise. (b) Noise reduction using a 19×19 Gaussian lowpass filter kernel with $\sigma = 3$. (c) Noise reduction using a 7×7 median filter. (Original image courtesy of Mr. Joseph E. Pascente, Lixi, Inc.)

a derivative operator is proportional to the magnitude of the intensity discontinuity at the point at which the operator is applied. Thus, image differentiation enhances edges and other discontinuities (such as noise) and de-emphasizes areas with slowly varying intensities. As noted in Section 3.5, smoothing is often referred to as lowpass filtering, a term borrowed from frequency domain processing. In a similar manner, sharpening is often referred to as *highpass* filtering. In this case, high frequencies (which are responsible for fine details) are passed, while low frequencies are attenuated or rejected.

FOUNDATION

In the two sections that follow, we will consider in some detail sharpening filters that are based on first- and second-order derivatives, respectively. Before proceeding with that discussion, however, we stop to look at some of the fundamental properties of these derivatives in a digital context. To simplify the explanation, we focus attention initially on one-dimensional derivatives. In particular, we are interested in the behavior of these derivatives in areas of constant intensity, at the onset and end of discontinuities (*step* and *ramp discontinuities*), and along *intensity ramps*. As you will see in Chapter 10, these types of discontinuities can be used to model noise points, lines, and edges in an image.

Derivatives of a digital function are defined in terms of differences. There are various ways to define these differences. However, we require that any definition we use for a *first derivative*:

1. Must be zero in areas of constant intensity.
2. Must be nonzero at the onset of an intensity step or ramp.
3. Must be nonzero along intensity ramps.

Similarly, any definition of a *second derivative*

الفصل 3: تحويلات الشدة والترشيح المكاني

الشكل 3.43

(a) صورة أشعة سينية للوحة دائرة إلكترونية ملوثة بضوضاء الملح والفلفل.
(b) تقليل الضوضاء باستخدام مرشح غاوسي منخفض التمرير بحجم 19×19 ومعامل انحراف معياري. $\sigma = 3$

(c) تقليل الضوضاء باستخدام مرشح وسيط بحجم 7×7 .

(الصورة الأصلية مقدمة من السيد Joseph E. Pascente ، شركة Lixi, Inc.)
تناسب استجابة مؤثر المشتقة (Derivative Operator) مع مقدار عدم الاستمرارية في شدة الإضاءة عند النقطة التي يتم تطبيق المؤثر عليها.
وبالتالي، فإن اشتقاق الصورة (Image Differentiation) يعمل على تعزيز الحواف وغيرها من حالات عدم الاستمرارية، مثل الضوضاء، ويقلل من أهمية المناطق التي تتغير فيها شدة الإضاءة ببطء.

وكما أشرنا في القسم 3.5، يُشار إلى التنعيم (Smoothing) غالبًا باسم الترشيح منخفض التمرير (Lowpass Filtering)، وهو مصطلح مأخوذ من معالجة الإشارات في مجال التردد.
وبطريقة مماثلة، يُشار إلى الشد (Sharpening) غالبًا باسم الترشيح عالي التمرير (Highpass Filtering).

وفي هذه الحالة، يتم تمرير الترددات العالية، التي تكون مسؤولة عن التفاصيل الدقيقة، بينما يتم توهين أو رفض الترددات المنخفضة.

الأساسيات (FOUNDATION)

في القسمين التاليين، سندرس بالتفصيل مرشحات الشد التي تعتمد على المشتقات من الرتبة الأولى والثانية على التوالي.
ولكن قبل البدء في هذه المناقشة، سنتوقف أولاً للنظر في بعض الخصائص الأساسية لهذه المشتقات في السياق الرقمي.

ولتسهيل الشرح، سنركز في البداية على المشتقات أحادية البعد.
وعلى وجه الخصوص، نحن مهتمون بسلوك هذه المشتقات في المناطق ذات الشدة الثابتة، وعند بداية ونهاية حالات عدم الاستمرارية، مثل:

عدم الاستمرارية على شكل خطوة (Step Discontinuity)

عدم الاستمرارية على شكل منحدر (Ramp Discontinuity)

وكذلك على طول منحدرات الشدة (Intensity Ramps).

وكما سنرى في الفصل 10، يمكن استخدام هذه الأنواع من عدم الاستمرارية لنمذجة:
نقاط الضوضاء

الخطوط

الحواف

في الصورة.

تُعرف مشتقات الدالة الرقمية (Derivatives of a Digital Function) من حيث الفروق (Differences).

وهناك عدة طرق لتعريف هذه الفروق، ولكننا نشترط أن يحقق أي تعريف نستخدمه للمشتقة الأولى الشروط التالية:

1. يجب أن تكون صفراً في المناطق ذات الشدة الثابتة.
 2. يجب أن تكون غير صفرية عند بداية خطوة أو منحدر في الشدة.
 3. يجب أن تكون غير صفرية على طول منحدرات الشدة.
- وبالمثل، فإن أي تعريف لـ المشتقة الثانية (Second Derivative) يجب أن يحقق الشروط التالية:

1. يجب أن تكون صفراً في المناطق ذات الشدة الثابتة.
2. يجب أن تكون غير صفرية عند بداية ونهاية خطوة أو منحدر في الشدة.
3. يجب أن تكون صفراً على طول منحدرات الشدة.

3.6 Sharpening (Highpass) Spatial Filters 177

1. Must be zero in areas of constant intensity.
2. Must be nonzero at the onset and end of an intensity step or ramp.
3. Must be zero along intensity ramps.

We are dealing with digital quantities whose values are finite. Therefore, the maximum possible intensity change also is finite, and the shortest distance over which that change can occur is between adjacent pixels.

A basic definition of the *first-order* derivative of a one-dimensional function $f(x)$ is the difference

$$\frac{\partial f}{\partial x} = f(x+1) - f(x) \quad (3-48)$$

We used a partial derivative here in order to keep the notation consistent when we consider an image function of two variables, $f(x, y)$, at which time we will be dealing with partial derivatives along the two spatial axes. Clearly, $\partial f / \partial x = df / dx$ when there is only one variable in the function; the same is true for the second derivative.

We define the *second-order* derivative of $f(x)$ as the difference

$$\frac{\partial^2 f}{\partial x^2} = f(x+1) + f(x-1) - 2f(x) \quad (3-49)$$

These two definitions satisfy the conditions stated above, as we illustrate in Fig. 3.44, where we also examine the similarities and differences between first- and second-order derivatives of a digital function.

The values denoted by the small squares in Fig. 3.44(a) are the intensity values along a horizontal intensity profile (the dashed line connecting the squares is included to aid visualization). The actual numerical values of the scan line are shown inside the small boxes in 3.44(b). As Fig. 3.44(a) shows, the scan line contains three sections of constant intensity, an intensity ramp, and an intensity step. The circles indicate the onset or end of intensity transitions. The first- and second-order derivatives, computed using the two preceding definitions, are shown below the scan line values in Fig. 3.44(b), and are plotted in Fig. 3.44(c). When computing the first derivative at a location x , we subtract the value of the function at that location from the next point, as indicated in Eq. (3-48), so this is a “look-ahead” operation. Similarly, to compute the second derivative at x , we use the previous and the next points in the computation, as indicated in Eq. (3-49). To avoid a situation in which the previous or next points are outside the range of the scan line, we show derivative computations in Fig. 3.44 from the second through the penultimate points in the sequence.

As we traverse the profile from left to right we encounter first an area of constant intensity and, as Figs. 3.44(b) and (c) show, both derivatives are zero there, so condition (1) is satisfied by both. Next, we encounter an intensity ramp followed by a step, and we note that the first-order derivative is nonzero at the onset of the ramp and the step; similarly, the second derivative is nonzero at the onset and end of both the ramp and the step; therefore, property (2) is satisfied by both derivatives. Finally, we

We will return to Eq. (3-48) in Section 10.2 and show how it follows from a Taylor series expansion. For now, we accept it as a definition.

الشحذ (المرشحات المكانية عالية التمرير)

شروط المشتقة الثانية

يجب أن تكون صفراً في المناطق ذات الشدة الثابتة.

يجب أن تكون غير صفريّة عند بداية ونهاية خطوة أو منحدر في الشدة.

يجب أن تكون صفراً على طول منحدرات الشدة.

نحن نتعامل مع كميات رقمية تكون قيمها محدودة. ولذلك فإن أكبر تغيير ممكن في الشدة يكون محدوداً أيضاً، كما أن أقصر مسافة يمكن أن يحدث خلالها هذا التغير تكون بين بكسلين متجاورين.

المشتقة من الرتبة الأولى

التعريف الأساسي للمشتقة من الرتبة الأولى لدالة أحادية البعد هو الفرق

(3-48):

استخدمنا هنا مشتقة جزئية حتى نحافظ على اتساق الرموز عندما نتعامل مع دالة صورة ذات

متغيرين ، حيث سنتعامل في ذلك الوقت مع المشتقات الجزئية على طول المحورين المكانيين.

وبالتأكيد، فإن:

عندما يكون هناك متغير واحد فقط في الدالة، وينطبق الأمر نفسه على المشتقة الثانية.

المشتقة من الرتبة الثانية

عرّفنا المشتقة من الرتبة الثانية للدالة على أنها الفرق:

(3-49)

هاتان الصيغتان تحققان الشروط المذكورة أعلاه، كما هو موضح في الشكل 3.44، حيث ندرس

أيضاً أوجه التشابه والاختلاف بين مشتقات الرتبة الأولى والثانية للدالة الرقمية.

القيم التي تمثلها المربعات الصغيرة في الشكل (a) 3.44 هي قيم الشدة على طول مقطع شدة أفقي،

وقد تم توصيل المربعات بخط متقطع لتسهيل تصورها.

أما القيم العددية الفعلية لخط المسح، فهي موضحة داخل المربعات الصغيرة في الشكل (b) 3.44.

يوضح الشكل (a) 3.44 أن خط المسح يمر عبر ثلاثة أقسام:

منطقة ذات شدة ثابتة.

منحدر في الشدة. (Intensity Ramp)

خطوة في الشدة. (Intensity Step)

وتشير الدوائر إلى بداية أو نهاية انتقالات الشدة.

أما المشتقتان من الرتبة الأولى والثانية، المحسوبتان باستخدام التعريفين السابقين، فهما موضحتان

أسفل قيم خط المسح في الشكل (b) 3.44، ومرسومتان في الشكل (c) 3.44.

عند حساب المشتقة الأولى عند الموقع ، نطرح قيمة الدالة عند ذلك الموقع من قيمة الدالة عند

النقطة التالية، كما هو موضح في المعادلة (3-48) ولذلك تُسمى هذه العملية عملية "النظر إلى

الأمم. (Look-ahead)"

وبالمثل، لحساب المشتقة الثانية عند ، نستخدم النقطة السابقة والنقطة التالية في عملية الحساب، كما

هو موضح في المعادلة (3-49)

ولتجنب الحالة التي تكون فيها النقطة السابقة أو التالية خارج نطاق خط المسح، نعرض حسابات

المشتقة في الشكل 3.44 بدءاً من النقطة الثانية وحتى النقطة قبل الأخيرة في التسلسل.


تفسير الشكل 3.44

عندما ننتقل عبر مقطع الشدة من اليسار إلى اليمين، نواجه أولاً منطقة ذات شدة ثابتة.

وكما توضح الأشكال (b) 3.44 و (c) 3.44، فإن كلتا المشتقتين تساويان صفراً في هذه المنطقة،

ولذلك يتحقق الشرط (1) لكليهما.
 بعد ذلك نواجه منحدرًا في الشدة يتبعه تغير على شكل خطوة.
 ونلاحظ أن المشتقة الأولى غير صفرية عند بداية المنحدر وعند الخطوة.
 وبالمثل، فإن المشتقة الثانية غير صفرية عند بداية ونهاية كل من المنحدر والخطوة.
 وبالتالي فإن الخاصية (2) تتحقق بواسطة كلتا المشتقتين.
 وفي النهاية، ...

FIGURE 3.44
 (a) A section of a horizontal scan line from an image, showing ramp and step edges, as well as constant segments.
 (b) Values of the scan line and its derivatives.
 (c) Plot of the derivatives, showing a zero crossing. In (a) and (c) points were joined by dashed lines as a visual aid.



see that property (3) is satisfied also by both derivatives because the first derivative is nonzero and the second is zero along the ramp. Note that the sign of the second derivative changes at the onset and end of a step or ramp. In fact, we see in Fig. 3.44(c) that in a step transition a line joining these two values crosses the horizontal axis midway between the two extremes. This *zero crossing* property is quite useful for locating edges, as you will see in Chapter 10.

Edges in digital images often are ramp-like transitions in intensity, in which case the first derivative of the image would result in thick edges because the derivative is nonzero along a ramp. On the other hand, the second derivative would produce a double edge one pixel thick, separated by zeros. From this, we conclude that the second derivative enhances fine detail much better than the first derivative, a property ideally suited for sharpening images. Also, second derivatives require fewer operations to implement than first derivatives, so our initial attention is on the former.

USING THE SECOND DERIVATIVE FOR IMAGE SHARPENING—THE LAPLACIAN

In this section we discuss the implementation of 2-D, second-order derivatives and their use for image sharpening. The approach consists of defining a discrete formulation of the second-order derivative and then constructing a filter kernel based on

We will return to the second derivative in Chapter 10, where we use it extensively for image segmentation.

الشكل 3.44

(a) جزء من خط مسح أفقي لصورة، يوضح حواف على شكل منحدر (Ramp) وخطوة (Step) ، بالإضافة إلى المقاطع ذات الشدة الثابتة.

(b) قيم خط المسح ومشتقاته.

(c) رسم للمشتقات، يوضح عبور الصفر (Zero Crossing) وقد تم توصيل النقاط في (a) و (b) بخطوط متقطعة لتسهيل تصورهما.

القيم الموجودة في الشكل:

قيم خط المسح:

6 ، 6 ، 6 ، 6 ، 6 ، 1 ، 1 ، 1 ، 1 ، 1 ، 1 ، 2 ، 3 ، 4 ، 5 ، 6 ، 6 ، 6 ، 6

المشتقة الأولى:

0 ، 0 ، 0 ، 0 ، 0 ، 5 ، 0 ، 0 ، 0 ، 0 ، 0 ، -1 ، -1 ، -1 ، -1 ، -1 ، 0 ، 0

المشتقة الثانية:

0 ، 0 ، 0 ، 0 ، 0 ، -5 ، 5 ، 0 ، 0 ، 0 ، 1 ، 0 ، 0 ، 0 ، 0 ، 0 ، -1 ، 0 ، 0

نلاحظ أن الخاصية (3) تتحقق أيضًا بواسطة كلتا المشتقتين، لأن المشتقة الأولى غير صفرية والمشتقة الثانية تساوي صفرًا على طول المنحدر.

لاحظ أيضًا أن إشارة المشتقة الثانية تتغير عند بداية ونهاية المنحدر أو الخطوة.

في الواقع، نرى في الشكل (c) 3.44 أنه عند وجود انتقال على شكل خطوة، فإن الخط الذي يصل بين هاتين القيمتين يعبر المحور الأفقي (الصفر) في منتصف المسافة بين الطرفين.

وتُعد خاصية عبور الصفر (Zero Crossing) مفيدة جدًا في تحديد الحواف (Edges) ، كما سنرى في الفصل 10.

الحواف في الصور الرقمية

غالبًا ما تكون الحواف في الصور الرقمية عبارة عن انتقالات شبيهة بالمنحدرات في شدة الإضاءة (Ramp-like transitions).

وفي هذه الحالة، فإن المشتقة الأولى للصورة ستؤدي إلى حواف سميكة، لأن المشتقة تكون غير صفرية على طول المنحدر.

ومن ناحية أخرى، فإن المشتقة الثانية ستنتج حافة مزدوجة (Double Edge) ، تفصل بينهما نقطة عبور الصفر.

ومن هذا نستنتج أن المشتقة الثانية تعزز التفاصيل الدقيقة بصورة أفضل بكثير من المشتقة الأولى، وهي خاصية تجعلها مناسبة بشكل مثالي لشحذ الصور.

وبالإضافة إلى ذلك، فإن المشتقات الثانية تتطلب عددًا أقل من العمليات اللازمة لتنفيذها مقارنةً بالمشتقات الأولى، ولذلك سيكون تركيزنا الأول على المشتقة الثانية.

استخدام المشتقة الثانية لشحذ الصور — مؤثر لابلاسيان

USING THE SECOND DERIVATIVE FOR IMAGE SHARPENING — THE LAPLACIAN

في هذا القسم نناقش تطبيق المشتقات من الرتبة الثانية ثنائية الأبعاد (2-D) واستخدامها في شحذ الصور.

يتكون الأسلوب من:

تعريف صيغة منفصلة للمشتقة الثانية.

إنشاء مرشح (Filter Kernel) اعتمادًا على تلك الصيغة.

وكما هو الحال مع نوى مرشح غاوسي منخفض التمرير التي تناولناها في القسم 3.5، فإننا نهتم هنا بـ النوى متساوية الاتجاه (Isotropic Kernels)، أي النوى التي تكون استجابتها مستقلة عن اتجاه عدم الاستمرارية في الشدة الموجودة في الصورة التي يتم تطبيق المرشح عليها. وقد أوضح Rosenfeld و Kak [1982] أن أبسط مؤثر مشتقة متساوي الاتجاه (Kernel) هو مؤثر لابلاسيان (Laplacian)، والذي يُعرّف للدالة ذات المتغيرين على النحو التالي...

3.6 Sharpening (Highpass) Spatial Filters 179

that formulation. As in the case of Gaussian lowpass kernels in Section 3.5, we are interested here in isotropic kernels, whose response is independent of the direction of intensity discontinuities in the image to which the filter is applied.

It can be shown (Rosenfeld and Kak [1982]) that the simplest isotropic derivative operator (kernel) is the *Laplacian*, which, for a function (image) $f(x, y)$ of two variables, is defined as

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \quad (3-50)$$

Because derivatives of any order are linear operations, the Laplacian is a linear operator. To express this equation in discrete form, we use the definition in Eq. (3-49), keeping in mind that we now have a second variable. In the x -direction, we have

$$\frac{\partial^2 f}{\partial x^2} = f(x+1, y) + f(x-1, y) - 2f(x, y) \quad (3-51)$$

and, similarly, in the y -direction, we have

$$\frac{\partial^2 f}{\partial y^2} = f(x, y+1) + f(x, y-1) - 2f(x, y) \quad (3-52)$$

It follows from the preceding three equations that the discrete Laplacian of two variables is

$$\nabla^2 f(x, y) = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y) \quad (3-53)$$

This equation can be implemented using convolution with the kernel in Fig. 3.45(a); thus, the filtering mechanics for image sharpening are as described in Section 3.5 for lowpass filtering; we are simply using different coefficients here.

The kernel in Fig. 3.45(a) is isotropic for rotations in increments of 90° with respect to the x - and y -axes. The diagonal directions can be incorporated in the definition of the digital Laplacian by adding four more terms to Eq. (3-53). Because each diagonal term would contain a $-2f(x, y)$ term, the total subtracted from the difference terms

0	1	0	1	1	1	0	-1	0	-1	-1	-1
1	-4	1	1	-8	1	-1	4	-1	-1	8	-1
0	1	0	1	1	1	0	-1	0	-1	-1	-1

a b c d

FIGURE 3.45 (a) Laplacian kernel used to implement Eq. (3-53). (b) Kernel used to implement an extension of this equation that includes the diagonal terms. (c) and (d) Two other Laplacian kernels.

3.6 الشدح (المرشحات المكانية عالية التمرير)

كما هو الحال مع نوى مرشح غاوسي منخفض التمرير في القسم 3.5، فإننا نهتم هنا بـ النوى متساوية الاتجاه (Isotropic Kernels)، التي تكون استجابتها مستقلة عن اتجاه عدم الاستمرارية

في شدة الإضاءة في الصورة التي يُطبَّق عليها المرشح. يمكن إظهار أن أبسط مؤثر مشتقة متساوي الاتجاه (Kernel) هو مؤثر لابلاسيان (Laplacian) ، والذي يُعرَّف للدالة (الصورة) ذات المتغيرين كما يلي:

(3-50)

بما أن المشتقات من أي رتبة هي مؤثرات خطية، فإن مؤثر لابلاسيان هو أيضًا مؤثر خطي. وللتعبير عن هذه المعادلة في صورة منفصلة، نستخدم التعريف الموجود في المعادلة (3-49) ، مع الأخذ في الاعتبار أننا أصبح لدينا الآن متغيران.

في اتجاه

(3-51)

وبالمثل، في اتجاه:

(3-52)

ومن المعادلات الثلاث السابقة، نستنتج أن لابلاسيان المنفصل لدالة ذات متغيرين هو:

(3-53)

يمكن تنفيذ هذه المعادلة باستخدام الالتفاف (Convolution) مع النواة الموضحة في

الشكل 3.45(a).

وبالتالي، فإن آلية الترشيح المستخدمة في شحذ الصور هي نفسها التي تم وصفها في القسم 3.5 بالنسبة إلى ترشيح التمير المنخفض، ولكننا نستخدم هنا معاملات مختلفة. نواة الشكل 3.45(a) متساوية الاتجاه بالنسبة إلى الدوران بزيادات مقدارها 90° بالنسبة إلى الاتجاهين.

ويمكن تضمين الاتجاهات القطرية في تعريف لابلاسيان الرقمي عن طريق إضافة أربعة حدود أخرى إلى المعادلة (3-53).

وبما أن كل حد قطري سيحتوي على:

فإن القيمة الكلية المطروحة من حدود الفرق تصبح:

الشكل 3.45

(a)

نواة لابلاسيان المستخدمة لتنفيذ المعادلة (3-53):

(b)

النواة المستخدمة لتنفيذ امتداد لهذه المعادلة، بحيث تتضمن الحدود القطرية:

(c) و (d)

نواتا لابلاسيان أخريان:

و:

توضح الشكل 3.45(b) النواة المستخدمة لتنفيذ هذا التعريف الجديد. وينتج عن هذه النواة تغيرات في الاستجابة بزيادات مقدارها 45°.

كما تُستخدم النواتان الموجودتان في الشكلين (c) و (d) 3.45 لحساب مؤثر لابلاسيان.

وقد تم الحصول عليهما من تعريفات للمشتقات الثانية تكون إشاراتها معكوسة مقارنةً بالتعريفات التي استخدمناها هنا.

وهما تعطيان نتائج مكافئة، ولكن يجب الانتباه إلى اختلاف الإشارة عند دمج صورة تمت معالجتها بمرشح لابلاسيان مع صورة أخرى.

الفكرة المهمة جدًا هنا

لدينا الآن أربع نوى أساسية:

لابلاسيان بدون الأقطار:

ينظر إلى أربعة جيران للبكسل المركزي: أعلى، أسفل، يمين، يسار.
أما:

فيأخذ في الاعتبار الثمانية جيران، أي يضيف الجيران القطريين أيضاً.

والهدف من استخدام لابلاسيان هنا هو إبراز التغيرات الحادة في شدة الإضاءة، وبالتالي إبراز الحواف والتفاصيل الدقيقة في الصورة.

now would be $-8f(x, y)$. Figure 3.45(b) shows the kernel used to implement this new definition. This kernel yields isotropic results in increments of 45° . The kernels in Figs. 3.45(c) and (d) also are used to compute the Laplacian. They are obtained from definitions of the second derivatives that are the negatives of the ones we used here. They yield equivalent results, but the difference in sign must be kept in mind when combining a Laplacian-filtered image with another image.

Because the Laplacian is a derivative operator, it highlights sharp intensity transitions in an image and de-emphasizes regions of slowly varying intensities. This will tend to produce images that have grayish edge lines and other discontinuities, all superimposed on a dark, featureless background. Background features can be “recovered” while still preserving the sharpening effect of the Laplacian by adding the Laplacian image to the original. As noted in the previous paragraph, it is important to keep in mind which definition of the Laplacian is used. If the definition used has a negative center coefficient, then we *subtract* the Laplacian image from the original to obtain a sharpened result. Thus, the basic way in which we use the Laplacian for image sharpening is

$$g(x, y) = f(x, y) + c[\nabla^2 f(x, y)] \quad (3-54)$$

where $f(x, y)$ and $g(x, y)$ are the input and sharpened images, respectively. We let $c = -1$ if the Laplacian kernels in Fig. 3.45(a) or (b) is used, and $c = 1$ if either of the other two kernels is used.

EXAMPLE 3.18: Image sharpening using the Laplacian.

Figure 3.46(a) shows a slightly blurred image of the North Pole of the moon, and Fig. 3.46(b) is the result of filtering this image with the Laplacian kernel in Fig. 3.45(a) directly. Large sections of this image are black because the Laplacian image contains both positive and negative values, and all negative values are clipped at 0 by the display.

Figure 3.46(c) shows the result obtained using Eq. (3-54), with $c = -1$, because we used the kernel in Fig. 3.45(a) to compute the Laplacian. The detail in this image is unmistakably clearer and sharper than in the original image. Adding the Laplacian to the original image restored the overall intensity variations in the image. Adding the Laplacian increased the contrast at the locations of intensity discontinuities. The net result is an image in which small details were enhanced and the background tonality was reasonably preserved. Finally, Fig. 3.46(d) shows the result of repeating the same procedure but using the kernel in Fig. 3.45(b). Here, we note a significant improvement in sharpness over Fig. 3.46(c). This is not unexpected because using the kernel in Fig. 3.45(b) provides additional differentiation (sharpening) in the diagonal directions. Results such as those in Figs. 3.46(c) and (d) have made the Laplacian a tool of choice for sharpening digital images.

Because Laplacian images tend to be dark and featureless, a typical way to scale these images for display is to use Eqs. (2-31) and (2-32). This brings the most negative value to 0 and displays the full range of intensities. Figure 3.47 is the result of processing Fig. 3.46(b) in this manner. The dominant features of the image are edges and sharp intensity discontinuities. The background, previously black, is now gray as a result of scaling. This grayish appearance is typical of Laplacian images that have been scaled properly.

3.6 الشدح (المرشحات المكانية عالية التمرير)

كما ذكرنا، فإن القيمة المطروحة من الحدود التفاضلية تصبح:

يوضح الشكل (b) 3.45 النواة المستخدمة لتنفيذ هذا التعريف. وتؤدي هذه النواة إلى نتائج متساوية

الاتجاه بالنسبة للدوران بزيادات مقدارها 45°.

كما تُستخدم النواتان الموجودتان في الشكلين (c) 3.45 و (d) 3.45 لحساب مؤثر لابلاسيان. وقد تم الحصول عليهما من تعريفات للمشتقات الثانية تكون سالبة التعريفات التي استخدمناها هنا.

وهما تعطيان نتائج مكافئة، ولكن يجب أخذ اختلاف الإشارة في الاعتبار عند دمج صورة تمت معالجتها بمرشح لابلاسيان مع صورة أخرى.

وبما أن لابلاسيان مؤثر مشتقة، فإنه يبرز الانتقالات الحادة في الشدة داخل الصورة، ويقلل من أهمية المناطق التي تتغير فيها الشدة ببطء.

وهذا يؤدي إلى إنتاج صور تحتوي على حواف شديدة الوضوح وغيرها من حالات عدم الاستمرارية، وكلها تكون متراكبة فوق خلفية داكنة تفتقر إلى التفاصيل.

يمكن استعادة تفاصيل الخلفية مع الحفاظ في الوقت نفسه على تأثير الشد الناتج عن لابلاسيان، وذلك عن طريق إضافة صورة لابلاسيان إلى الصورة الأصلية.

وكما أُشير في الفقرة السابقة، من المهم معرفة أي تعريف لمؤثر لابلاسيان نستخدمه.

إذا كان التعريف المستخدم يحتوي على معامل مركزي سالب، فإننا نطرح صورة لابلاسيان من الصورة الأصلية للحصول على النتيجة المشحونة.

وبالتالي، فإن الطريقة الأساسية التي نستخدم بها لابلاسيان لشد الصور هي:

(3-54)

حيث إن:

= الصورة الأصلية (المدخلة).

= الصورة المشحونة.

إذا استخدمنا نواة لابلاسيان الموجودة في الشكل (a) 3.45 أو (b).

إذا استخدمنا إحدى النواتين الموجودتين في الشكل (c) 3.45 أو (d).

مثال: 3.18 شد الصور باستخدام لابلاسيان

يوضح الشكل (a) 3.46 صورة مشوشة قليلاً لـ القطب الشمالي للقمر، ويوضح الشكل (b) 3.46 نتيجة ترشيح هذه الصورة باستخدام نواة لابلاسيان الموجودة في الشكل (a) 3.45.

لاحظ أن أجزاء كبيرة من هذه الصورة تظهر باللون الأسود، لأن صورة لابلاسيان تحتوي على قيم موجبة وسالبة، وجميع القيم السالبة يتم قصها إلى الصفر عند عرض الصورة.

يوضح الشكل (c) 3.46 النتيجة التي تم الحصول عليها باستخدام المعادلة (3-54) ، مع:

وذلك لأننا استخدمنا النواة الموجودة في الشكل (a) 3.45 لحساب لابلاسيان.

إن التفاصيل الموجودة في هذه الصورة أصبحت أكثر وضوحاً وحدةً بشكل ملحوظ مقارنةً بالصورة الأصلية.

وأدت إضافة لابلاسيان إلى الصورة الأصلية إلى استعادة التغيرات العامة في الشدة الموجودة في الصورة.

كما أدت إضافة لابلاسيان إلى زيادة التباين عند مواضع عدم الاستمرارية في الشدة.

والنتيجة النهائية هي صورة تم فيها تعزيز التفاصيل الصغيرة مع الحفاظ بدرجة معقولة على درجة سطوع الخلفية.

وأخيراً، يوضح الشكل (d) 3.46 نتيجة تكرار العملية نفسها، ولكن باستخدام النواة الموجودة في الشكل (b) 3.45.

وهنا نلاحظ تحسناً ملحوظاً في حدة الصورة مقارنةً بالشكل (c) 3.46.

وهذا ليس أمراً مفاجئاً، لأن استخدام النواة الموجودة في الشكل (b) 3.45 يوفر تفضلاً إضافياً

(شحذًا إضافيًا) في الاتجاهات القطرية. وقد جعلت النتائج المشابهة لتلك الموجودة في الشكلين 3.46(c) و 3.46(d) من مؤثر لابلاسيان أداة مهمة لشحذ الصور الرقمية. ملاحظة مهمة عن صور لابلاسيان نظرًا لأن صور لابلاسيان تميل إلى أن تكون داكنة وتفتقر إلى التفاصيل، فإن الطريقة المعتادة لتحجيم هذه الصور للعرض هي استخدام المعادلتين (2-31) و (2-32). وهذا يجعل الصورة أقرب ما يكون إلى عرض النطاق الكامل لقيم الشدة. يوضح الشكل 3.47 نتيجة معالجة الشكل 3.46(b) بهذه الطريقة. وتصبح السمات الأساسية للصورة هي الحواف والانتقالات الحادة في الشدة. أما الخلفية التي كانت سوداء سابقًا، فأصبحت الآن رمادية نتيجة عملية التحجيم. وهذا المظهر الرمادي المائل إلى البياض يُعد من السمات النموذجية لصور لابلاسيان التي تم تحجيمها بصورة صحيحة.

3.6 Sharpening (Highpass) Spatial Filters 181

FIGURE 3.46
(a) Blurred image of the North Pole of the moon.
(b) Laplacian image obtained using the kernel in Fig. 3.45(a).
(c) Image sharpened using Eq. (3-54) with $c = -1$.
(d) Image sharpened using the same procedure, but with the kernel in Fig. 3.45(b).
(Original image courtesy of NASA.)



Observe in Fig. 3.45 that the coefficients of each kernel sum to zero. Convolution-based filtering implements a sum of products, so when a derivative kernel encompasses a constant region in a image, the result of convolution in that location must be zero. Using kernels whose coefficients sum to zero accomplishes this.

In Section 3.5, we normalized smoothing kernels so that the sum of their coefficients would be one. Constant areas in images filtered with these kernels would be constant also in the filtered image. We also found that the sum of the pixels in the original and filtered images were the same, thus preventing a bias from being introduced by filtering (see Problem 3.31). When convolving an image with a kernel

3.6 الشدح (المرشحات المكانية عالية التمرير)

الشكل 3.46

(a)

صورة مشوشة للقطب الشمالي للقمر.

(b)

صورة لابلاسيان تم الحصول عليها باستخدام النواة الموجودة في الشكل 3.45(a).

(c)

صورة تم شدحها باستخدام المعادلة (3-54) ، حيث

(d)

صورة تم شدحها باستخدام الإجراء نفسه، ولكن باستخدام النواة الموجودة في الشكل 3.45(b).
(الصورة الأصلية مقدمة من وكالة ناسا NASA.)

انظري في الشكل 3.45 إلى أن مجموع معاملات كل نواة يساوي صفراً.

إن الترشيح القائم على الالتفاف (Convolution-based filtering) ينفذ عملية جمع للنواتج، لذلك عندما تمر نواة مشتقة فوق منطقة ذات قيمة ثابتة في الصورة، يجب أن تكون نتيجة الالتفاف في ذلك الموقع صفراً.


إن استخدام نوى يكون مجموع معاملاتهما مساوياً للصفر يحقق ذلك.

في القسم 3.5، قمنا بتطبيق نوى التنعيم (Smoothing Kernels) بحيث يكون مجموع معاملات كل منها مساوياً لواحد.

وبالتالي، فإن المناطق ذات القيمة الثابتة في الصور التي تمت تصفيتها باستخدام تلك النوى ستبقى ثابتة أيضاً في الصورة المرشحة.

كما وجدنا أن مجموع قيم البكسلات في الصورة الأصلية والصورة المرشحة كان متساوياً، مما يمنع حدوث انحياز (Bias) ناتج عن عملية الترشيح (انظري المسألة 3.31).
عند إجراء الالتفاف على صورة باستخدام نواة...

FIGURE 3.47
The Laplacian image from Fig. 3.46(b), scaled to the full [0, 255] range of intensity values. Black pixels correspond to the most negative value in the unscaled Laplacian image, grays are intermediate values, and white pixels corresponds to the highest positive value.



whose coefficients sum to zero, it turns out that the pixels of the filtered image will sum to zero also (see Problem 3.32). This implies that images filtered with such kernels will have negative values, and sometimes will require additional processing to obtain suitable visual results. Adding the filtered image to the original, as we did in Eq. (3-54), is an example of such additional processing.

UNSHARP MASKING AND HIGHBOOST FILTERING

Subtracting an unsharp (smoothed) version of an image from the original image is a process that has been used since the 1930s by the printing and publishing industry to sharpen images. This process, called *unsharp masking*, consists of the following steps:

1. Blur the original image.
2. Subtract the blurred image from the original (the resulting difference is called the *mask*.)
3. Add the mask to the original.

Letting $\bar{f}(x, y)$ denote the blurred image, the mask in equation form is given by:

$$g_{\text{mask}}(x, y) = f(x, y) - \bar{f}(x, y) \quad (3-55)$$

Then we add a weighted portion of the mask back to the original image:

$$g(x, y) = f(x, y) + k g_{\text{mask}}(x, y) \quad (3-56)$$

The photographic process of unsharp masking is based on creating a blurred positive and using it along with the original negative to create a sharper image. Our interest is in the digital equivalent of this process.

الفصل الثالث: تحويلات الشدة والترشيح المكاني

الشكل 3.47

صورة لابلاسيان الموجودة في الشكل (b) 3.46، تم تحجيمها إلى المجال الكامل لقيم الشدة. تمثل البكسلات السوداء القيمة الأكثر سلبية في صورة لابلاسيان غير المُحجَّمة، بينما تمثل درجات اللون الرمادي القيم المتوسطة، وتمثل البكسلات البيضاء أعلى قيمة موجبة. ...التي يكون مجموع معاملاتها مساوياً للصفر، يتضح أن بكسلات الصورة المُرشَّحة سيكون مجموعها أيضاً مساوياً للصفر (انظر المسألة 3.32). وهذا يعني أن الصور التي تمت تصفيتها باستخدام مثل هذه النوى سيكون لها قيم سالبة، ولذلك قد تتطلب أحياناً معالجة إضافية للحصول على نتائج بصرية مناسبة. إن إضافة الصورة المُرشَّحة إلى الصورة الأصلية، كما فعلنا في المعادلة (3-54) ، هي مثال على مثل هذه المعالجة الإضافية.

الإخفاء غير الحاد والترشيح عالي التعزيز

(UNSHARP MASKING AND HIGHBOOST FILTERING)

إن طرح نسخة غير حادة (مُنَعَّمة) من الصورة من الصورة الأصلية هو عملية مستخدمة منذ ثلاثينيات القرن العشرين في صناعة الطباعة والنشر من أجل شحذ الصور. وتُسمى هذه العملية الإخفاء غير الحاد (Unsharp Masking) ، وتتكون من الخطوات التالية:

1. تغبيش الصورة الأصلية.

2. طرح الصورة المُغَبَّشة من الصورة الأصلية

ويُسمى الفرق الناتج القناع (Mask)

3. إضافة القناع إلى الصورة الأصلية.

إذا رمزنا إلى الصورة المُغَبَّشة بالرمز:

فإن القناع في صورة معادلة يُعطى كما يلي:

(3-55)


بعد ذلك نضيف جزءاً موزوناً من القناع مرة أخرى إلى الصورة الأصلية:

(3-56)

a
b
c
d

FIGURE 3.48

1-D illustration of the mechanics of unsharp masking. (a) Original signal. (b) Blurred signal with original shown dashed for reference. (c) Unsharp mask. (d) Sharpened signal, obtained by adding (c) to (a).



where we included a weight, k ($k \geq 0$), for generality. When $k = 1$ we have unsharp masking, as defined above. When $k > 1$, the process is referred to as *highboost filtering*. Choosing $k < 1$ reduces the contribution of the unsharp mask.

Figure 3.48 illustrates the mechanics of unsharp masking. Part (a) is a horizontal intensity profile across a vertical ramp edge that transitions from dark to light. Figure 3.48(b) shows the blurred scan line superimposed on the original signal (shown dashed). Figure 3.48(c) is the mask, obtained by subtracting the blurred signal from the original. By comparing this result with the section of Fig. 3.44(c) corresponding to the ramp in Fig. 3.44(a), we note that the unsharp mask in Fig. 3.48(c) is similar to what we would obtain using a second-order derivative. Figure 3.48(d) is the final sharpened result, obtained by adding the mask to the original signal. The points at which a change of slope occurs in the signal are now emphasized (sharpened). Observe that negative values were added to the original. Thus, it is possible for the final result to have negative intensities if the original image has any zero values, or if the value of k is chosen large enough to emphasize the peaks of the mask to a level larger than the minimum value in the original signal. Negative values cause dark halos around edges that can become objectionable if k is too large.

EXAMPLE 3.19: Unsharp masking and highboost filtering.

Figure 3.49(a) shows a slightly blurred image of white text on a dark gray background. Figure 3.49(b) was obtained using a Gaussian smoothing filter of size 31×31 with $\sigma = 5$. As explained in our earlier discussion of Gaussian lowpass kernels, the size of the kernel we used here is the smallest odd integer no less than $6\sigma \times 6\sigma$. Figure 3.49(c) is the unsharp mask, obtained using Eq. (3-55). To obtain the im-

3.6 مرشحات التنعيم المكانية (ترشيح الترددات العالية)

محتوى الرسم البياني والشرح الجانبي:

الإشارة الأصلية Original signal:

الإشارة الضبابية (المنقصة الحدة) Blurred signal:

قناع إزالة التنعيم (قناع الحدة) Unsharp mask:

الإشارة المُحددة (المُقواة الحواف) Sharpened signal:

الشكل (FIGURE 3.48) 3.48

توضيح أحادي البعد (1-D) لميكانيكية حجب التنعيم. (unsharp masking)

(a) الإشارة الأصلية.

(b) الإشارة الضبابية مع إظهار الإشارة الأصلية بخط منقط للمرجعية.

(c) قناع إزالة التنعيم. (Unsharp mask)

(d) الإشارة المُحددة، التي تم الحصول عليها بإضافة (c) إلى (a).

حيث قمنا بتضمين وزن، k ($k \geq 0$)، من أجل التعميم. عندما تكون $k = 1$ يكون لدينا حجب التنعيم (unsharp masking)، كما هو محدد أعلاه. وعندما تكون $k > 1$ ، يُشار إلى العملية باسم الترشيح عالي التعزيز (highboost filtering). واختيار $k < 1$ يقلل من مساهمة قناع التنعيم. يوضح الشكل 3.48 ميكانيكية حجب التنعيم. الجزء (a) عبارة عن مقطع شدة أفقي عبر حافة منحدر رأسية تنتقل من الداكن إلى الفاتح. ويظهر الشكل 3.48(b) خط المسح الضبابي متراكباً على الإشارة الأصلية (الموضحة بخط منقط). والشكل 3.48(c) هو القناع، الذي تم الحصول عليه بطرح الإشارة الضبابية من الأصلية. وبمقارنة هذه النتيجة مع جزء من الشكل 3.44(c) المقابل للمنحدر في الشكل 3.44(a)، نلاحظ أن قناع التنعيم في الشكل 3.48(c) يشبه ما سنحصل عليه باستخدام مشتقة من الرتبة الثانية. والشكل 3.48(d) هو النتيجة النهائية المُحددة، التي تم الحصول عليها بإضافة القناع إلى الإشارة الأصلية. النقاط التي يحدث عندها تغيير في الميل في الإشارة أصبحت الآن مؤكدة (مُحددة).

لاحظ أنه تم إضافة قيم سالبة إلى الأصل. وبالتالي، من الممكن أن تحتوي النتيجة النهائية على شدة سالبة إذا كانت الصورة الأصلية تحتوي على أي قيم صفرية، أو إذا تم اختيار قيمة k كبيرة بدرجة كافية لتعزيز قمم القناع إلى مستوى أكبر من القيمة الأدنى في الصورة الأصلية. تسبب القيم السالبة هالات داكنة (dark halos) حول الحواف والتي يمكن أن تكون غير مرغوب فيها إذا كانت k كبيرة جداً.

مثال 3.19: حجب التنعيم والترشيح عالي التعزيز (Unsharp masking and highboost filtering).

يُظهر الشكل 3.49(a) صورة ضبابية قليلاً لنص أبيض على خلفية رمادية داكنة. تم الحصول على الشكل 3.49(b) باستخدام مرشح تنعيم غاوسي بحجم 31×31 مع $\sigma = 5$. كما تم توضيحه في مناقشتنا السابقة لنوى الترددات المنخفضة الغاوسية، فإن حجم النواة الذي استخدمناه هنا هو أصغر عدد فردي صحيح لا يقل عن 6×6 . الشكل 3.49(c) هو قناع التنعيم، الذي تم الحصول عليه باستخدام المعادلة (3-55) للحصول على الصورة...



FIGURE 3.49 (a) Original image of size 600×259 pixels. (b) Image blurred using a 31×31 Gaussian lowpass filter with $\sigma = 5$. (c) Mask. (d) Result of unsharp masking using Eq. (3-56) with $k = 1$. (e) Result of highboost filtering with $k = 4.5$.

age in Fig. 3.49(d) was used the unsharp masking expression from Eq. (3-56) with $k = 1$. This image is significantly sharper than the original image in Fig. 3.49(a), but we can do better, as we show in the following paragraph.

Figure 3.49(e) shows the result of using Eq. (3-56) with $k = 4.5$. This value is almost at the extreme of what we can use without introducing some serious artifacts in the image. The artifacts are dark, almost black, halos around the border of the characters. This is caused by the lower “blip” in Fig. 3.48(d) becoming negative, as we explained earlier. When scaling the image so that it only has positive values for display, the negative values are either clipped at 0, or scaled so that the most negative values become 0, depending on the scaling method used. In either case, the blips will be the darkest values in the image.

The results in Figs. 3.49(d) and 3.49(e) would be difficult to generate using the traditional film photography explained earlier, and it illustrates the power and versatility of image processing in the context of digital photography.

USING FIRST-ORDER DERIVATIVES FOR IMAGE SHARPENING—THE GRADIENT

We will discuss the gradient in more detail in Section 10.2. Here, we are interested only in using it for image sharpening.

First derivatives in image processing are implemented using the magnitude of the gradient. The gradient of an image f at coordinates (x, y) is defined as the two-dimensional column vector

$$\nabla f = \text{grad}(f) = \begin{bmatrix} g_x \\ g_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} \quad (3-57)$$

الفصل 3 تحويلات الشدة والترشيح المكاني

تسميات الصور وتوضيح الشكل:

a | b | c

d | e

الشكل: (FIGURE 3.49) 3.49

(a) الصورة الأصلية بحجم 259×600 بكسل (b). صورة ضبابية باستخدام مرشح غاوسي للترددات المنخفضة بحجم 31×31 مع $\sigma = 5$ (c). نتيجة حجب التنعيم باستخدام المعادلة (3-56) مع $k = 1$. نتيجة الترشيح عالي التعزيز مع $k = 4.5$ (d). نتيجة حجب النص الأساسي: (e).

...الصورة في الشكل (d) 3.49، تم استخدام تعبير حجب التنعيم من المعادلة (3-56) مع $k = 1$. هذه الصورة أكثر حدة بشكل ملحوظ من الصورة الأصلية في الشكل (a) 3.49، ولكن يمكننا تحقيق نتيجة أفضل، كما نوضح في الفقرة التالية.

يُظهر الشكل (e) 3.49 نتيجة استخدام المعادلة (3-56) مع $k = 4.5$. هذه القيمة تقع تقريباً عند الحد الأقصى لما يمكننا استخدامه دون إدخال عيوب رسومية (artifacts) خطيرة في الصورة. العيوب عبارة عن هالات داكنة، شبه سوداء، حول حدود الأحرف. ينتج هذا عن انخفاض "البروز" (blip) السفلي في الشكل (d) 3.48 ليصبح سالباً، كما شرحنا سابقاً. عند تغيير مقياس الصورة بحيث تحتوي فقط على قيم موجبة للعرض، إما أن يتم قص القيم السالبة عند 0، أو تغيير مقياسها بحيث تصبح أكثر القيم سالبة مساوية لـ 0، اعتماداً على طريقة تغيير المقياس المستخدمة. وفي كلا الحالتين، ستكون التعرجات هي أعمق القيم في الصورة.

سيكون من الصعب إنتاج النتائج الموضحة في الشكلين (d) 3.49 و (e) 3.49 باستخدام التصوير الفوتوغرافي التقليدي الموضح سابقاً، وهو ما يوضح قوة وتعدد استخدامات معالجة الصور في سياق التصوير الرقمي.

استخدام المشتقات من الرتبة الأولى لتحديد/تنعيم الصور — التدرج (USING FIRST-ORDER

DERIVATIVES FOR IMAGE SHARPENING—THE GRADIENT)

ملاحظة جانبية باللون الأزرق: (سنناقش التدرج بمزيد من التفصيل في القسم 10.2 هنا، نحن مهتمون فقط باستخدامه لتحديد/تنعيم الصور)

تُنفذ المشتقات الأولى في معالجة الصور باستخدام مقدار التدرج. يُعرّف التدرج (gradient) لصورة f عند الإحداثيات (x, y) على أنه متجه عمودي ثنائي الأبعاد

This vector has the important geometrical property that it points in the direction of the greatest rate of change of f at location (x, y) .

The *magnitude (length)* of vector ∇f , denoted as $M(x, y)$ (the vector norm notation $\|\nabla f\|$ is also used frequently), where

$$M(x, y) = \|\nabla f\| = \text{mag}(\nabla f) = \sqrt{g_x^2 + g_y^2} \quad (3-58)$$

is the *value* at (x, y) of the *rate of change* in the direction of the gradient vector. Note that $M(x, y)$ is an image of the same size as the original, created when x and y are allowed to vary over all pixel locations in f . It is common practice to refer to this image as the *gradient image* (or simply as the *gradient* when the meaning is clear).

Because the components of the gradient vector are derivatives, they are linear operators. However, the magnitude of this vector is not, because of the squaring and square root operations. On the other hand, the partial derivatives in Eq. (3-57) are not rotation invariant, but the magnitude of the gradient vector is.

In some implementations, it is more suitable computationally to approximate the squares and square root operations by absolute values:

$$M(x, y) \approx |g_x| + |g_y| \quad (3-59)$$

The vertical bars denote absolute values.

This expression still preserves the relative changes in intensity, but the isotropic property is lost in general. However, as in the case of the Laplacian, the isotropic properties of the discrete gradient defined in the following paragraph are preserved only for a limited number of rotational increments that depend on the kernels used to approximate the derivatives. As it turns out, the most popular kernels used to approximate the gradient are isotropic at multiples of 90° . These results are independent of whether we use Eq. (3-58) or (3-59), so nothing of significance is lost in using the latter equation if we choose to do so.

As in the case of the Laplacian, we now define discrete approximations to the preceding equations, and from these formulate the appropriate kernels. In order to simplify the discussion that follows, we will use the notation in Fig. 3.50(a) to denote the intensities of pixels in a 3×3 region. For example, the value of the center point, z_5 , denotes the value of $f(x, y)$ at an arbitrary location, (x, y) ; z_1 denotes the value of $f(x-1, y-1)$; and so on. As indicated in Eq. (3-48), the simplest approximations to a first-order derivative that satisfy the conditions stated at the beginning of this section are $g_x = (z_8 - z_5)$ and $g_y = (z_6 - z_5)$. Two other definitions, proposed by Roberts [1965] in the early development of digital image processing, use cross differences:

$$g_x = (z_9 - z_5) \quad \text{and} \quad g_y = (z_8 - z_6) \quad (3-60)$$

If we use Eqs. (3-58) and (3-60), we compute the gradient image as

$$M(x, y) = [(z_9 - z_5)^2 + (z_8 - z_6)^2]^{1/2} \quad (3-61)$$

3.6 مرشحات التنعيم المكانية (ترشيح الترددات العالية)

النص الأساسي:

يملك هذا المنتج خاصية هندسية مهمة وهي أنه يشير في اتجاه أعلى معدل تغير لـ f عند الموقع (x, y) .

يُرمز لـ مقدار (طول) المنتج ∇f بـ $M(x, y)$ يُستخدم أيضاً تدوين معيار المنتج $\|\nabla f\|$ بشكل متكرر، حيث:

هو قيمة معدل التغير عند (x, y) في اتجاه متجه التدرج. لاحظ أن $M(x, y)$ هي صورة بنفس حجم الصورة الأصلية، تم إنشاؤها عندما نفتح المجال لـ x و y للتغير عبر جميع مواقع البكسلات في f . ومن الشائع الإشارة إلى هذه الصورة باسم صورة التدرج (gradient image) أو اختصاراً التدرج عندما يكون المعنى واضحاً.

ولأن مكونات متجه التدرج عبارة عن مشتقات، فهي مؤثرات خطية. ومع ذلك، فإن مقدار هذا المنتج ليس خطياً، بسبب عمليات التربيع والجذر التربيعي. من ناحية أخرى، فإن المشتقات الجزئية في المعادلة (3-57) ليست صامدة أمام الدوران (not rotation invariant)، ولكن

الفصل 3 تحويلات الشدة والترشيح المكاني

محتوى الشكل والرسم البياني:

a | b | c | d | e

تسميات المصفوفات (النوى) (a): منطقة 3×3 من صورة (b) و (c) مؤثرات روبرتس (Roberts):

(d) و (e) مؤثرات سوبل (Sobel):

الشكل: (FIGURE 3.50) 3.50

(a) منطقة بحجم 3×3 من صورة، حيث تمثل z_5 قيم الشدة.

(c)–(b) مؤثرات التدرج المتقاطع لروبرتس (Roberts cross-gradient operators)

(e)–(d). مؤثرات سوبل (Sobel operators) مجموع معاملات جميع النوى يساوي الصفر، كما هو متوقع من مؤثر المشتقة. النص الأساسي:

إذا استخدمنا المعادلتين (3-59) و (3-60)، فإن: حيث يفهم أن x و y يتغيران عبر أبعاد الصورة بالطريقة الموضحة سابقاً. حدود الفرق المطلوبة في المعادلة (3-60) يمكن تنفيذها باستخدام النواتين الموضحتين في الشكلين (b) و (c). يُشار إلى هذه النوى باسم مؤثرات التدرج المتقاطع لروبرتس (Roberts cross-gradient operators).

كما ذكر سابقاً، نفضل استخدام نوى ذات أحجام فردية لأن لها مركز تماثل مكاني فريد (وصحيح). أصغر نوى نهتم بها تكون بحجم 3×3 . التقديرات التقريبية لـ g_x و g_y باستخدام جوار بحجم 3×3 متمركز عند z_5 هي كما يلي: يمكن تنفيذ هذه المعادلات باستخدام النوى الموضحة في الشكلين (d) و (e). الفرق بين الصفين الثالث والأول لمنطقة الصورة 3×3 يمثل تقريباً المشتقة الجزئية في اتجاه x ، ويُنفذ باستخدام النواة في الشكل (d). 3.50

3.6 Sharpening (Highpass) Spatial Filters 187

The difference between the third and first columns approximates the partial derivative in the y -direction and is implemented using the kernel in Fig. 3.50(e). The partial derivatives at all points in an image are obtained by convolving the image with these kernels. We then obtain the magnitude of the gradient as before. For example, substituting g_x and g_y into Eq. (3-59) yields

$$M(x, y) = \left[g_x^2 + g_y^2 \right]^{1/2} = \left[\left[(z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3) \right]^2 + \left[(z_5 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7) \right]^2 \right]^{1/2} \quad (3-65)$$

This equation indicates that the value of M at any image coordinates (x, y) is given by squaring values of the convolution of the two kernels with image f at those coordinates, summing the two results, and taking the square root.

The kernels in Figs. 3.50(d) and (e) are called the *Sobel operators*. The idea behind using a weight value of 2 in the center coefficient is to achieve some smoothing by giving more importance to the center point (we will discuss this in more detail in Chapter 10). The coefficients in all the kernels in Fig. 3.50 sum to zero, so they would give a response of zero in areas of constant intensity, as expected of a derivative operator. As noted earlier, when an image is convolved with a kernel whose coefficients sum to zero, the elements of the resulting filtered image sum to zero also, so images convolved with the kernels in Fig. 3.50 will have negative values in general.

The computations of g_x and g_y are linear operations and are implemented using convolution, as noted above. The nonlinear aspect of sharpening with the gradient is the computation of $M(x, y)$ involving squaring and square roots, or the use of absolute values, all of which are nonlinear operations. These operations are performed after the linear process (convolution) that yields g_x and g_y .

EXAMPLE 3.20: Using the gradient for edge enhancement.

The gradient is used frequently in industrial inspection, either to aid humans in the detection of defects or, what is more common, as a preprocessing step in automated inspection. We will have more to say about this in Chapter 10. However, it will be instructive now to consider a simple example to illustrate how the gradient can be used to enhance defects and eliminate slowly changing background features.

Figure 3.51(a) is an optical image of a contact lens, illuminated by a lighting arrangement designed to highlight imperfections, such as the two edge defects in the lens boundary seen at 4 and 5 o'clock. Figure 3.51(b) shows the gradient obtained using Eq. (3-65) with the two Sobel kernels in Figs. 3.50(d) and (e). The edge defects are also quite visible in this image, but with the added advantage that constant or slowly varying shades of gray have been eliminated, thus simplifying considerably the computational task required for automated inspection. The gradient can be used also to highlight small specs that may not be readily visible in a gray-scale image (specs like these can be foreign matter, air pockets in a supporting solution, or minuscule imperfections in the lens). The ability to enhance small discontinuities in an otherwise flat gray field is another important feature of the gradient.

3.6 مرشحات التنعيم المكانية (ترشيح الترددات العالية)

النص الأساسي:

الفرق بين العمودين الثالث والأول يمثل تقريباً المشتقة الجزئية في اتجاه y ويُنفذ باستخدام النواة (kernel) الموضحة في الشكل (e) 3.50. يتم الحصول على المشتقات الجزئية عند جميع النقاط في الصورة عن طريق إجراء التجميع/التفاف (convolving) للصورة مع هذه النوى. ثم نحصل على مقدار التدرج كما في السابق. على سبيل المثال، التعويض بـ g_x و g_y في المعادلة

(3-59) يعطي:

تشير هذه المعادلة إلى أن قيمة M عند أي إحداثيات صورة (x, y) تُعطى بتربيع قيم التفاف النواتين مع الصورة f عند تلك الإحداثيات، وجمع النتيجتين، ثم أخذ الجذر التربيعي. تُسمى النوى في الشكلين (d) 3.50 و (e) بـ مؤثرات سوبل (Sobel operators) الفكرة من وراء استخدام قيمة وزن تبلغ 2 في المعامل الأوسط هي تحقيق بعض التنعيم من خلال إعطاء أهمية أكبر للنقطة المركزية (سنناقش هذا بمزيد من التفصيل في الفصل 10). مجموع المعاملات في جميع النوى في الشكل 3.50 يساوي الصفر، لذا فإنها تعطي استجابة صفرية في مناطق الشدة الثابتة، كما هو متوقع من مؤثر المشتقة. وكما ذكر سابقاً، عندما تُلف الصورة مع نواة مجموع معاملاتها صفر، فإن عناصر الصورة المرشحة الناتجة يكون مجموعها صفرأً أيضاً، لذا فإن الصور الملفوفة مع النوى في الشكل 3.50 ستتحصل على قيم سالبة بشكل عام.

حسابات g_x و g_y هي عمليات خطية وتُنفذ باستخدام التجميع (التفاف)، كما هو موضح أعلاه. الجانب غير الخطي في الحدة باستخدام التدرج هو حساب $M(x, y)$ الذي يتضمن التربيع والجذور التربيعية، أو استخدام القيم المطلقة، وتعتبر جميعها عمليات غير خطية. تُنفذ هذه العمليات بعد العملية الخطية (التفاف) التي تنتج g_x و g_y .

مثال: 3.20 استخدام التدرج لتعزيز الحواف (Using the gradient for edge enhancement).


يُستخدم التدرج بشكل متكرر في الفحص الصناعي، إما لمساعدة البشر في اكتشاف العيوب أو، وهو الأكثر شيوعاً، كخطوة معالجة أولية في الفحص الآلي. سيكون لدينا المزيد لنقول عن هذا في الفصل 10. ومع ذلك، سيكون من المفيد الآن النظر في مثال بسيط لتوضيح كيفية استخدام التدرج لتعزيز العيوب والقضاء على ميزات الخلفية بطيئة التغير.

الشكل (a) 3.51 عبارة عن صورة بصرية لعدسة لاصقة، تم إضاءتها بترتيب إضاءة مصمم لتسليط الضوء على العيوب، مثل عيبين في الحافة عند حدود العدسة يظهران عند الساعة 4 و 5. يُظهر الشكل (b) 3.51 التدرج الذي تم الحصول عليه باستخدام المعادلة (3-65) مع نواتي سوبل الموضحتين في الشكلين (d) 3.50 و (e). عيوب الحافة مرئية تماماً في هذه الصورة، ولكن مع الميزة الإضافية المتمثلة في القضاء على درجات الرمادي الثابتة أو بطيئة التغير، مما يسهل بشكل كبير المهمة الحسابية المطلوبة للفحص الآلي. يمكن استخدام التدرج أيضاً لتسليط الضوء على البقع الصغيرة التي قد لا تكون مرئية بسهولة في صورة متدرجة الرمادي (البقع مثل هذه يمكن أن تكون مواد غريبة، أو فقاعات هواء في المحلول الداعم، أو عيوب صغيرة جداً في العدسة). القدرة على تعزيز التغيرات الصغيرة غير المستمرة في مجال رمادي مسطح هي ميزة أخرى مهمة للتدرج.

a b

FIGURE 3.51

(a) Image of a contact lens (note defects on the boundary at 4 and 5 o'clock).
(b) Sobel gradient.
(Original image courtesy of Perceptics Corporation.)



3.7 HIGHPASS, BANDREJECT, AND BANDPASS FILTERS FROM LOW-PASS FILTERS

Spatial and frequency-domain linear filters are classified into four broad categories: lowpass and highpass filters, which we introduced in Sections 3.5 and 3.6, and *bandpass* and *bandreject* filters, which we introduce in this section. We mentioned at the beginning of Section 3.5 that the other three types of filters can be constructed from lowpass filters. In this section we explore methods for doing this. Also, we illustrate the third approach discussed at the end of Section 3.4 for obtaining spatial filter kernels. That is, we use a filter design software package to generate 1-D filter functions. Then, we use these to generate 2-D separable filter functions either via Eq. (3-42), or by rotating the 1-D functions about their centers to generate 2-D kernels. The rotated versions are approximations of circularly symmetric (isotropic) functions.

Figure 3.52(a) shows the transfer function of a 1-D ideal lowpass filter in the frequency domain [this is the same as Fig. 3.32(a)]. We know from earlier discussions in this chapter that lowpass filters attenuate or delete high frequencies, while passing low frequencies. A *highpass filter* behaves in exactly the opposite manner. As Fig. 3.52(b) shows, a highpass filter deletes or attenuates all frequencies below a cut-off value, u_0 , and passes all frequencies above this value. Comparing Figs. 3.52(a) and (b), we see that a highpass filter transfer function is obtained by subtracting a lowpass function from 1. This operation is in the frequency domain. As you know from Section 3.4, a constant in the frequency domain is an impulse in the spatial domain. Thus, we obtain a highpass filter kernel in the spatial domain by subtracting a lowpass filter kernel from a unit impulse with the same center as the kernel. An image filtered with this kernel is the same as an image obtained by subtracting a lowpass-filtered image from the original image. The unsharp mask defined by Eq. (3-55) is precisely this operation. Therefore, Eqs. (3-54) and (3-56) implement equivalent operations (see Problem 3.42).

Figure 3.52(c) shows the transfer function of a bandreject filter. This transfer function can be constructed from the sum of a lowpass and a highpass function with

Recall from the discussion of Eq. (3-33) that a unit impulse is an array of 0's with a single 1.

الفصل 3 تحويلات الشدة والترشيح المكاني

تسمية والشرح الجانبي للشكل:

a | b

الشكل: (FIGURE 3.51) 3.51

(a) صورة لعدسة لاصقة (لاحظ العيوب على الحدود عند الساعة 4 و 5). (b) تدرج سوبل

(Sobel gradient). (الصورة الأصلية بإذن من شركة Perceptics Corporation).

العنوان الرئيسي:

3.7 مرشحات الترددات العالية، وحظر النطاق، وتميرير النطاق من مرشحات الترددات المنخفضة

(3.7 HIGHPASS, BANDREJECT, AND BANDPASS FILTERS FROM LOWPASS FILTERS)

النص الأساسي:

تُصنف المرشحات الخطية في المجالين المكاني والترددية إلى أربع فئات رئيسية: مرشحات

الترددات المنخفضة (lowpass) والترددات العالية (highpass)، والتي قدمناها في


القسمين 3.5 و 3.6، ومرشحات حظر النطاق (bandpass) وتمرير النطاق (bandreject)، والتي نقدمها في هذا القسم. ذكرنا في بداية القسم 3.5 أن الأنواع الثلاثة الأخرى من المرشحات يمكن بناؤها من مرشحات الترددات المنخفضة. في هذا القسم نستكشف الطرق للقيام بذلك. أيضاً، نوضح النهج الثالث الذي تم مناقشته في نهاية القسم 3.4 للحصول على نوى المرشحات المكانية. أي أننا نستخدم حزمة برامج تصميم المرشحات لتوليد دوال مرشح أحادية البعد (1-D) بعد ذلك، نستخدم هذه الدوال لتوليد دوال مرشح ثنائية الأبعاد (2-D) قابلة للفصل إما عبر المعادلة (3-42)، أو تدوير الدوال أحادية البعد حول مراكزها لتوليد نوى ثنائية الأبعاد. النسخ المدورة هي تقريبات لدوال ذات تماثل دائري (متماثلة المناحي). isotropic -

يُظهر الشكل 3.52(a) دالة الانتقال لمرشح الترددات المنخفضة المثالي أحادي البعد (1-D) في مجال التردد [هذا هو نفس الشكل 3.32(a) نعلم من المناقشات السابقة في هذا الفصل أن مرشحات الترددات المنخفضة تضعف أو تحذف الترددات العالية، بينما تمرر الترددات المنخفضة. ويتصرف مرشح الترددات العالية (highpass filter) بالعكس تماماً. كما يُظهر الشكل 3.52(b)، فإن مرشح الترددات العالية يحذف أو يضعف جميع الترددات التي تقض تحت قيمة القطع، u_0 ، ويقرر جميع الترددات التي تزيد عن هذه القيمة. وبمقارنة الشكلين 3.52(a) و (b)، نرى أن دالة انتقال مرشح الترددات العالية يتم الحصول عليها بطرح دالة الترددات المنخفضة من 1. هذه العملية تكون في مجال التردد. وكما تعلم من القسم 3.4، فإن الثابت في مجال التردد هو نبضة (impulse) في المجال المكاني. وبالتالي، نحصل على نواة مرشح الترددات العالية في المجال المكاني بطرح نواة مرشح الترددات المنخفضة من نبضة الوحدة (unit impulse) التي لها نفس مركز النواة. الصورة المرشحة باستخدام هذه النواة هي نفس الصورة التي نتحصل عليها بطرح صورة مرشحة بالترددات المنخفضة من الصورة الأصلية. قناع التنعيم المحدد بالمعادلة (3-55) هو تماماً هذه العملية. لذلك، فإن المعادلتين (3-54) و (3-56) تنفذان عمليات متكافئة (انظر المشكلة 3.42).

(ملاحظة جانبية باللون الأزرق: تذكر من مناقشة المعادلة (3-33) أن نبضة الوحدة هي مصفوفة من الأصفار تحتوي على رقم 1 واحد فقط.) يُظهر الشكل 3.52(c) دالة الانتقال لمرشح حظر النطاق. يمكن بناء دالة الانتقال هذه من مجموع دالة ترددات منخفضة ودالة ترددات عالية مع...

a b
c d

FIGURE 3.52
Transfer functions of ideal 1-D filters in the frequency domain (u denotes frequency).
(a) Lowpass filter.
(b) Highpass filter.
(c) Bandreject filter.
(d) Bandpass filter.
(As before, we show only positive frequencies for simplicity.)



different cut-off frequencies (the highpass function can be constructed from a *different* lowpass function). The bandpass filter transfer function in Fig. 3.52(d) can be obtained by subtracting the bandreject function from 1 (a unit impulse in the spatial domain). Bandreject filters are also referred to as *notch* filters, but the latter tend to be more locally oriented, as we will show in Chapter 4. Table 3.7 summarizes the preceding discussion.

The key point in Fig. 3.52 and Table 3.7 is that all transfer functions shown can be obtained starting with a lowpass filter transfer function. This is important. It is important also to realize that we arrived at this conclusion via simple graphical interpretations in the frequency domain. To arrive at the same conclusion based on convolution in the spatial domain would be a much harder task.

EXAMPLE 3.21: Lowpass, highpass, bandreject, and bandpass filtering.

In this example we illustrate how we can start with a 1-D lowpass filter transfer function generated using a software package, and then use that transfer function to generate spatial filter kernels based on the concepts introduced in this section. We also examine the spatial filtering properties of these kernels.

TABLE 3.7
Summary of the four principal spatial filter types expressed in terms of lowpass filters. The centers of the unit impulse and the filter kernels coincide.

Filter type	Spatial kernel in terms of lowpass kernel, lp
Lowpass	$lp(x, y)$
Highpass	$hp(x, y) = \delta(x, y) - lp(x, y)$
Bandreject	$br(x, y) = lp_1(x, y) + hp_2(x, y)$ $= lp_1(x, y) + [\delta(x, y) - lp_2(x, y)]$
Bandpass	$bp(x, y) = \delta(x, y) - br(x, y)$ $= \delta(x, y) - [lp_1(x, y) + [\delta(x, y) - lp_2(x, y)]]$

3.7 مرشحات الترددات العالية، وحظر النطاق، وتمرير النطاق من مرشحات الترددات المنخفضة

تسميات الشاخص والمحتوى البياني:

a | b
c | d

الشكل: (FIGURE 3.52) 3.52

دوال الانتقال للمرشحات المثالية أحادية البعد (1-D) في مجال التردد (u) يمثل التردد (a). (مرشح الترددات المنخفضة) (b). (Lowpass filter). (c). مرشح الترددات العالية (Highpass filter). (d). مرشح حظر النطاق (Bandreject filter). (مرشح تمرير النطاق) (Bandpass filter). كما في السابق، نعرض الترددات الموجبة فقط للتسهيل.

النص الأساسي:

...ترددات قطع مختلفة (يمكن بناء دالة الترددات العالية من دالة ترددات منخفضة مختلفة). يمكن الحصول على دالة انتقال مرشح تمرير النطاق في الشكل (d) 3.52 بطرح دالة حظر النطاق من 1 (نبضة الوحدة في المجال المكاني). يُشار أيضاً إلى مرشحات حظر النطاق بـ مرشحات الشطب (notch filters)، لكن الأخيرة تميل إلى أن تكون ذات توجه مكاني أكثر، كما سنوضح في الفصل 4. يلخص الجدول 3.7 المناقشة السابقة.

النقطة الأساسية في الشكل 3.52 والجدول 3.7 هي أن جميع دوال الانتقال المعروضة يمكن الحصول عليها بالبداية بدالة انتقال مرشح الترددات المنخفضة. هذا أمر مهم. ومن المهم أيضاً إدراك أننا وصلنا إلى هذا الاستنتاج عبر تفسيرات بيانية بسيطة في مجال التردد. الوصول إلى نفس

الاستنتاج بناءً على التجميع (التفاف) في المجال المكاني سيكون مهمة أصعب بكثير.
مثال: 3.21 ترشيح الترددات المنخفضة، الترددات العالية، حظر النطاق، وتمرير النطاق

(Lowpass, highpass, bandreject, and bandpass filtering).

في هذا المثال نوضح كيف يمكننا البدء بدالة انتقال مرشح الترددات المنخفضة أحادي البعد (1-D) المُولدة باستخدام حزمة برامج، ثم استخدام دالة الانتقال تلك لتوليد نوى مرشحات مكانية بناءً على المفاهيم المحددة في هذا القسم. كما نفحص خواص الترشيح المكاني لهذه النوى.
الجدول: (TABLE 3.7) 3.7 ملخص للأنواع الأربعة الرئيسية للمرشحات المكانية المعبر عنها بدلالة مرشحات الترددات المنخفضة. تتطابق مراكز نبضة الوحدة ونوى [المرشح. نوع](#) المرشح (Filter type) النواة المكانية بدلالة مرشح الترددات المنخفضة

lp (Spatial kernel in terms of lowpass kernel, lp)

Lowpasslp

(x, y)

Highpasshp

(x, y) = \delta(x, y) - lp(x, y)

Bandrejectbr

(x, y) = lp_1(x, y) + hp_2(x, y) = lp_1(x, y) + [\delta(x, y) - lp_2(x, y)]

Bandpassbp

(x, y) = \delta(x, y) - br(x, y) = \delta(x, y) - [lp_1(x, y) + [\delta(x, y) - lp_2(x, y)]]

FIGURE 3.53
A zone plate
image of size
597 × 597 pixels.






Figure 3.53 shows a so-called *zone plate* image that is used frequently for testing the characteristics of filtering approaches. There are various versions of zone plates; the one in Fig. 3.53 was generated using the equation

$$z(x, y) = \frac{1}{2} [1 + \cos(x^2 + y^2)] \quad (3-66)$$

with x and y varying in the range $[-8.2, 8.2]$, in increments of 0.0275. This resulted in an image of size 597×597 pixels. The bordering black region was generated by setting to 0 all pixels with distance greater than 8.2 from the image center. The key characteristic of a zone plate is that its spatial frequency increases as a function of distance from the center, as you can see by noting that the rings get narrower the further they are from the center. This property makes a zone plate an ideal image for illustrating the behavior of the four filter types just discussed.

Figure 3.54(a) shows a 1-D, 128-element spatial lowpass filter function designed using MATLAB [compare with Fig. 3.32(b)]. As discussed earlier, we can use this 1-D function to construct a 2-D, separable lowpass filter kernel based on Eq. (3-42), or we can rotate it about its center to generate a 2-D, isotropic kernel. The kernel in Fig. 3.54(b) was obtained using the latter approach. Figures 3.55(a) and (b) are the results of filtering the image in Fig. 3.53 with the separable and isotropic kernels, respectively. Both filters passed the low frequencies of the zone plate while attenuating the high frequencies significantly. Observe, however, that the separable filter kernel produced a “squarish” (non-radially symmetric) result in the passed frequencies. This is a consequence of filtering the image in perpendicular directions with a separable kernel that is not isotropic. Using the isotropic kernel yielded a result that is uniform in all radial directions. This is as expected, because both the filter and the image are isotropic.

FIGURE 3.54
(a) A 1-D spatial
lowpass filter
function. (b) 2-D
kernel obtained
by rotating the
1-D profile about
its center.



الفصل 3 تحويلات الشدة والترشيح المكاني

تسميات الشاخص والمحتوى البياني:

الشكل: (FIGURE 3.53) 3.53

صورة صفيحة المنطقة (zone plate) بحجم 597×597 بكسل.

النص الأساسي:

يُظهر الشكل 3.53 صورة ما يُسمى بـ صفيحة المنطقة (zone plate) التي تُستخدم بشكل متكرر لاختبار خصائص نهج الترشيح. هناك إصدارات مختلفة من صفحات المنطقة؛ الإصدار الموضح في الشكل 3.53 تم توليده باستخدام المعادلة:

مع تغير x و y في المدى $[-8.2, 8.2]$ ، بزيادات قدرها 0.0275 أدى ذلك إلى صورة بحجم 597×597 بكسل. تم توليد المنطقة السوداء المحيطة عن طريق ضبط جميع البكسلات التي تزيد مسافتها عن 8.2 من مركز الصورة على 0. الخاطئة الرئيسية لصفيحة المنطقة هي أن ترددها المكاني يزداد كدالة للمسافة عن المركز، كما يمكنك أن ترى من خلال ملاحظة أن الحلقات تصبح أضيق كلما ابتعدت عن المركز. هذه الخاصية تجعل صفيحة المنطقة صورة مثالية لتوضيح سلوك أنواع المرشحات الأربعة التي تم مناقشتها للتو.

يُظهر الشكل (a) 3.54 دالة مرشح ترددات منخفضة مكاني أحادي البعد (1-D) يتكون من 128 عنصراً تم تصميمه باستخدام MATLAB قارين مع الشكل (b) 3.32 كما ناقشنا سابقاً، يمكننا استخدام هذه الدالة أحادية البعد لبناء نواة مرشح ترددات منخفضة ثنائي الأبعاد (2-D) قابل للفصل بناءً على المعادلة (3-42) ، أو يمكننا تدويرها حول مركزها لتوليد نواة متماثلة المناحي (isotropic) ثنائية الأبعاد. تم الحصول على النواة في الشكل (b) 3.54 باستخدام النهج الأخير.

يُظهر الشكلان (a) 3.55 و (b) نتائج ترشيح الصورة في الشكل 3.53 باستخدام النوى القابلة للفصل ومتماثلة المناحي، على التوالي. مرر كلا المرشحين الترددات المنخفضة لصفيحة المنطقة بينما أضعف الترددات العالية بشكل ملحوظ. لاحظ، مع ذلك، أن نواة المرشح القابلة للفصل أنتجت نتيجة "مربعة الشكل" (غير متماثلة شعاعياً) في الترددات الممررة. هذا نتيجة لترشيح الصورة في اتجاهات متعامدة مع نواة قابلة للفصل ليست متماثلة المناحي. بينما أدى استخدام النواة متماثلة المناحي إلى نتيجة منتظمة في جميع الاتجاهات الشعاعية. هذا كما هو متوقع، لأن كل من المرشح والصورة متماثلان المناحي.

a | b

الشكل: (FIGURE 3.54) 3.54

(a) دالة مرشح ترددات منخفضة مكاني أحادي البعد (1-D). (b) نواة ثنائية الأبعاد (2-D) تم الحصول عليها بتدوير المقطع أحادي البعد حول مركزه.

a b

FIGURE 3.55
(a) Zone plate image filtered with a separable lowpass kernel.
(b) Image filtered with the isotropic lowpass kernel in Fig. 3.54(b).




Figure 3.56 shows the results of filtering the zone plate with the four filters described in Table 3.7. We used the 2-D lowpass kernel in Fig. 3.54(b) as the basis for the highpass filter, and similar lowpass kernels for the bandreject filter. Figure 3.56(a) is the same as Fig. 3.55(b), which we repeat for convenience. Figure 3.56(b) is the highpass-filtered result. Note how effectively the low frequencies were filtered out. As is true of highpass-filtered images, the black areas were caused by negative values being clipped at 0 by the display. Figure 3.56(c) shows the same image scaled using Eqs. (2-31) and (2-32). Here we see clearly that only high frequencies were passed by the filter. Because the highpass kernel was constructed using the same lowpass kernel that we used to generate Fig. 3.56(a), it is evident by comparing the two results that the highpass filter passed the frequencies that were attenuated by the lowpass filter.

Figure 3.56(d) shows the bandreject-filtered image, in which the attenuation of the mid-band of frequencies is evident. Finally, Fig. 3.56(e) shows the result of bandpass filtering. This image also has negative values, so it is shown scaled in Fig. 3.56(f). Because the bandpass filter was constructed by subtracting the bandreject kernel from a unit impulse, we see that the bandpass filter passed the frequencies that were attenuated by the bandreject filter. We will give additional examples of bandpass and bandreject filtering in Chapter 4.

3.8 COMBINING SPATIAL ENHANCEMENT METHODS

With a few exceptions, such as combining blurring with thresholding (Fig. 3.41), we have focused attention thus far on individual spatial-domain processing approaches. Frequently, a given task will require application of several complementary techniques in order to achieve an acceptable result. In this section, we illustrate how to combine several of the approaches developed thus far in this chapter to address a difficult image enhancement task.

The image in Fig. 3.57(a) is a nuclear whole body bone scan, used to detect diseases such as bone infections and tumors. Our objective is to enhance this image by sharpening it and by bringing out more of the skeletal detail. The narrow dynamic range of the intensity levels and high noise content make this image difficult to enhance. The strategy we will follow is to utilize the Laplacian to highlight fine detail, and the gradient to enhance prominent edges. For reasons that will be explained shortly, a smoothed version of the gradient image will be used to mask the Laplacian

In this context, masking refers to multiplying two images, as in Fig. 2.34. This is not to be confused with the mask used in unsharp masking.

3.8 دمج طرق التعزيز المكاني

تسميات الشاخص والمحتوى البياني:

a | b

الشكل: (FIGURE 3.55) 3.55

(a) صورة صفيحة المنطقة تم ترشيحها باستخدام نواة ترددات منخفضة قابلة للفصل (b). صورة (a) تم ترشيحها باستخدام النواة متماثلة المناحي للترددات المنخفضة الموضحة في الشكل (b). 3.54
النص الأساسي:

يُظهر الشكل 3.56 نتائج ترشيح صفيحة المنطقة باستخدام المرشحات الأربعة الموصوفة في الجدول 3.7. استخدمنا نواة الترددات المنخفضة ثنائية الأبعاد في الشكل (b) 3.54 كأساس لمرشح الترددات العالية، ونوى ترددات منخفضة مماثلة لمرشح حظر النطاق. الشكل (a) 3.56 هو نفس الشكل (b) 3.55، والذي نكرره للتسهيل. الشكل (b) 3.56 هو نتيجة ترشيح الترددات العالية. لاحظ مدى الفعالية التي تم بها ترشيح (حذف) الترددات المنخفضة. وكما هو الحال في الصور المرشحة بالترددات العالية، فإن المناطق السوداء نتجت عن قص القيم السالبة عند 0 بواسطة شاشة العرض. يُظهر الشكل (c) 3.56 نفس الصورة بعد تغيير مقياسها باستخدام المعادلتين (2-31) و (2-32). هنا نرى بوضوح أن الترددات العالية فقط هي التي مرت عبر المرشح. ولأن نواة الترددات العالية تم

بناؤها باستخدام نفس نواة الترددات المنخفضة التي استخدمناها لتوليد الشكل (a) 3.56، فمن الواضح عند مقارنة النتيجة أن مرشح الترددات العالية مرر الترددات التي تم إضعافها بواسطة مرشح الترددات المنخفضة.

يُظهر الشكل (d) 3.56 الصورة المرشحة بحظر النطاق، والتي يظهر فيها إضعاف النطاق المتوسط من الترددات بوضوح. أخيرًا، يُظهر الشكل (e) 3.56 نتيجة ترشيح تمرير النطاق. تحتوي هذه الصورة أيضًا على قيم سالبة، لذا تم عرضها مقاسة في الشكل (f) 3.56 ولأن نواة تمرير النطاق تم بناؤها بطرح نواة حظر النطاق من نبضة الوحدة، نرى أن مرشح تمرير النطاق مرر الترددات التي تم إضعافها بواسطة مرشح حظر النطاق. سنقدم أمثلة إضافية على ترشيح حظر النطاق وتمرير النطاق في الفصل 4.

3.8 دمج طرق التعزيز المكاني (3.8 COMBINING SPATIAL ENHANCEMENT METHODS)

مع وجود استثناءات قليلة، مثل دمج الضبابية مع حد التباين (الشكل (a) 3.41، فقد ركزنا الانتباه حتى الآن على أساليب المعالجة الفردية في المجال المكاني. في كثير من الأحيان، تتطلب مهمة معينة تطبيق عدة تقنيات مكاملة للحصول على نتيجة مقبولة. في هذا القسم، نوضح كيفية دمج العديد من الأساليب التي تم تطويرها حتى الآن في هذا الفصل لمعالجة مهمة تعزيز صورة صعبة. الصورة في الشكل (a) 3.57 هي مسح نووي لعظام الجسم بالكامل، يُستخدم لاكتشاف أمراض مثل التهابات العظام والأورام. هدفنا هو تعزيز هذه الصورة عن طريق زيادة حدتها وإبراز المزيد من التفاصيل الهيكلية. إن النطاق الديناميكي الضيق لمستويات الشدة والمحتوى العالي من الضوضاء يجعلان تعزيز هذه الصورة أمراً صعباً. الاستراتيجية التي سنتبعها هي استخدام مؤثر لابلاس (Laplacian) لتسليط الضوء على التفاصيل الدقيقة، والتدرج (gradient) لتعزيز الحواف البارزة. ولأسباب سيتم شرحها قريباً، سنستخدم نسخة مننعة من صورة التدرج كقناع لمؤثر لابلاس...

(ملاحظة جانبية باللون الأزرق: في هذا السياق، يشير القناع إلى ضرب صورتين ببعضهما، كما في الشكل 2.34. ويجب عدم الخلط بين هذا وبين القناع المستخدم في حجب التنعيم)




FIGURE 3.56 Spatial filtering of the zone plate image. (a) Lowpass result; this is the same as Fig. 3.55(b). (b) Highpass result. (c) Image (b) with intensities scaled. (d) Bandreject result. (e) Bandpass result. (f) Image (e) with intensities scaled.

image. Finally, we will attempt to increase the dynamic range of the intensity levels by using an intensity transformation.

Figure 3.57(b) shows the Laplacian of the original image, obtained using the kernel in Fig. 3.45(d). This image was scaled (for display only) using the same technique as in Fig. 3.47. We can obtain a sharpened image at this point simply by adding Figs. 3.57(a) and (b), according to Eq. (3-54). Just by looking at the noise level in Fig. 3.57(b), we would expect a rather noisy sharpened image if we added Figs. 3.57(a) and (b). This is confirmed by the result in Fig. 3.57(c). One way that comes immediately to mind to reduce the noise is to use a median filter. However, median filtering is an aggressive nonlinear process capable of removing image features. This is unacceptable in medical image processing.

An alternate approach is to use a mask formed from a smoothed version of the gradient of the original image. The approach is based on the properties of first- and

الفصل 3 تحويلات الشدة والترشيح المكاني

تسميات الشاخص والمحتوى البياني:

a | b | c


d | e | f

الشكل: (FIGURE 3.56) 3.56

الترشيح المكاني لصورة صفيحة المنطقة (a). (zone plate) نتيجة الترددات المنخفضة؛ وهي نفس الصورة في الشكل (b). (b) 3.55 نتيجة الترددات العالية (c). الصورة (b) بعد تغيير مقياس شدتها (d). نتيجة حظر النطاق (e). نتيجة تمرير النطاق (f). الصورة (e) بعد تغيير مقياس شدتها. النص الأساسي:

...الصورة. وأخيراً، سنحاول زيادة النطاق الديناميكي لمستويات الشدة باستخدام تحويل الشدة. يُظهر الشكل (b) 3.57 مؤثر لابلاس (Laplacian) للصورة الأصلية، والذي تم الحصول عليه باستخدام النواة في الشكل (d) 3.45 تم تغيير مقياس هذه الصورة (لعرضها فقط) باستخدام نفس التقنية المتبعة في الشكل 3.47. يمكننا الحصول على صورة أكثر حدة عند هذه النقطة ببساطة عن طريق إضافة الشكلين (a) 3.57 و (b)، وفقاً للمعادلة (3-54) ولكن مجرد النظر إلى مستوى الضوضاء في الشكل (b) 3.57، نتوقع صورة مزادة الحدة مليئة بالضوضاء إذا أضفنا الشكلين (a) 3.57 و (b). وهذا ما تؤكد النتيجة في الشكل (c) 3.57 إحدى الطرق التي تخطر بالبال فوراً لتقليل الضوضاء هي استخدام مرشح الوسيط (median filter) ومع ذلك، فإن ترشيح الوسيط هو عملية غير خطية قوية قادرة على إزالة ميزات ومعالم من الصورة، وهذا أمر غير مقبول في معالجة الصور الطبية. النهج البديل هو استخدام قناع مكون من نسخة مُنمّعة من تدرج الصورة الأصلية. يعتمد هذا النهج على خواص المشتقات من الرتبة الأولى و ..

a b
c d
FIGURE 3.57
(a) Image of whole body bone scan.
(b) Laplacian of (a).
(c) Sharpened image obtained by adding (a) and (b).
(d) Sobel gradient of image (a). (Original image courtesy of G.E. Medical Systems.)



3.8 دمج طرق التعزيز المكاني

تسميات الشاخص والمحتوى البياني:

a | b

c | d

الشكل: (FIGURE 3.57) 3.57

(a) صورة مسح عظام الجسم بالكامل (b). مؤثر لابلاس للصورة (c). (a) الصورة المحسنة (المزادة الحدة) التي تم الحصول عليها بإضافة (a) و (d). (b) تدرج سوبل للصورة. (a) الصورة الأصلية بإذن من شركة (G.E. Medical Systems). النص الأساسي:

...المشتقات من الرتبة الثانية التي ناقشناها عند شرح الشكل 3.44. مؤثر لابلاس هو مؤثر مشتقة من الرتبة الثانية وله ميزة مؤكدة تتمثل في كونه متفوقاً في تعزيز التفاصيل الدقيقة. ومع ذلك، فإن المقايضة هي أنه يميل إلى إنتاج نتائج أكثر ضوضاء من التدرج. هذه الضوضاء هي الأشد إزعاجاً في المناطق الناعمة، حيث تميل إلى أن تكون أكثر وضوحاً. يمتلك التدرج استجابة أقوى في المناطق ذات الشدة العالية...

second-order derivatives we discussed when explaining Fig. 3.44. The Laplacian, is a second-order derivative operator and has the definite advantage that it is superior for enhancing fine detail. However, this causes it to produce noisier results than the gradient. This noise is most objectionable in smooth areas, where it tends to be more visible. The gradient has a stronger response in areas of significant intensity transitions (ramps and steps) than does the Laplacian. The response of the gradient to noise and fine detail is lower than the Laplacian's and can be lowered further by smoothing the gradient with a lowpass filter. The idea, then, is to smooth the gradient and multiply it by the Laplacian image. In this context, we may view the smoothed gradient as a mask image. The product will preserve details in the strong areas, while reducing noise in the relatively flat areas. This process can be interpreted roughly as combining the best features of the Laplacian and the gradient. The result is added to the original to obtain a final sharpened image.

Figure 3.57(d) shows the Sobel gradient of the original image, computed using Eq. (3-59). Components g_x and g_y were obtained using the kernels in Figs. 3.50(d) and (e), respectively. As expected, the edges are much more dominant in this image than in the Laplacian image. The smoothed gradient image in Fig. 3.57(e) was obtained by using a box filter of size 5×5 . The fact that Figs. 3.57(d) and (e) are much brighter than Fig. 3.57(b) is further evidence that the gradient of an image with significant edge content has values that are higher in general than in a Laplacian image.

Figure 3.57(f) shows the product of the Laplacian and smoothed gradient image. Note the dominance of the strong edges and the relative lack of visible noise, which is the reason for masking the Laplacian with a smoothed gradient image. Adding the product image to the original resulted in the sharpened image in Fig. 3.57(g). The increase in sharpness of detail in this image over the original is evident in most parts of the image, including the ribs, spinal cord, pelvis, and skull. This type of improvement would not have been possible by using the Laplacian or the gradient alone.

The sharpening procedure just discussed did not affect in an appreciable way the dynamic range of the intensity levels in an image. Thus, the final step in our enhancement task is to increase the dynamic range of the sharpened image. As we discussed in some detail in Sections 3.2 and 3.3, there are several intensity transformation functions that can accomplish this objective. Histogram processing is not a good approach on images whose histograms are characterized by dark and light components, which is the case here. The dark characteristics of the images with which we are dealing lend themselves much better to a power-law transformation. Because we wish to spread the intensity levels, the value of γ in Eq. (3-5) has to be less than 1. After a few trials with this equation, we arrived at the result in Fig. 3.57(h), obtained with $\gamma = 0.5$ and $c = 1$. Comparing this image with Fig. 3.57(g), we note that significant new detail is visible in Fig. 3.57(h). The areas around the wrists, hands, ankles, and feet are good examples of this. The skeletal bone structure also is much more pronounced, including the arm and leg bones. Note the faint definition of the outline of the body, and of body tissue. Bringing out detail of this nature by expanding the dynamic range of the intensity levels also enhanced noise, but Fig. 3.57(h) is a significant visual improvement over the original image.

الفصل 3 تحويلات الشدة والترشيح المكاني

النص الأساسي:

...المشتقات من الرتبة الثانية التي ناقشناها عند شرح الشكل 3.44 مؤثر لابلاس هو مؤثر مشتقة من الرتبة الثانية وله ميزة مؤكدة تتمثل في كونه متفوقاً في تعزيز التفاصيل الدقيقة. ومع ذلك، فإن هذا يتسبب في إنتاجه لنتائج أكثر ضوضاء من التدرج. هذه الضوضاء هي الأشد إزعاجاً في المناطق الناعمة، حيث تميل إلى أن تكون أكثر وضوحاً. يمتلك التدرج استجابة أقوى في المناطق ذات الانتقالات الكبيرة في الشدة (المنحدرات والدرجات) مقارنة بمؤثر لابلاس. استجابة التدرج للضوضاء والتفاصيل الدقيقة أقل من استجابة مؤثر لابلاس، ويمكن تقليلها بدرجة أكبر عن طريق تنعيم التدرج بمرشح ترددات منخفضة. الفكرة إذن هي تنعيم التدرج وضربه في صورة مؤثر لابلاس. في هذا السياق، يمكننا رؤية التدرج المُنعَّم كصورة قناع. سينتج عن ضرب الحفظ على التفاصيل في المناطق القوية، مع تقليل الضوضاء في المناطق المسطحة نسبياً. يمكن تفسير هذه العملية تقريباً على أنها دمج لأفضل ميزات مؤثر لابلاس والتدرج. يتم بعد ذلك إضافة النتيجة إلى الصورة الأصلية للحصول على صورة نهائية محددة/مزادة الحدة.

يُظهر الشكل (d) 3.57 تدرج سوبل للصورة الأصلية، محسوباً باستخدام المعادلة (3-59) تم الحصول على المكونين g_x و g_y باستخدام النوى في الشكلين (d) 3.50 و (e) على التوالي. كما هو متوقع، الحواف أكثر هيمنة بكثير في هذه الصورة مقارنة بصورة مؤثر لابلاس. تم الحصول على صورة التدرج المُنعَّم في الشكل (e) 3.57 باستخدام مرشح الصندوق (box filter) بحجم 5 $\times$ 5. حقيقة أن الشكلين (d) 3.57 و (e) أسطع بكثير من الشكل (b) 3.57 هي دليل إضافي على أن تدرج صورة ذات محتوى حواف كبير يحتوي على قيم أعلى عموماً من صورة مؤثر لابلاس.

يُظهر الشكل (f) 3.57 حاصل ضرب صورة مؤثر لابلاس وصورة التدرج المُنعَّم. لاحظ سيطرة الحواف القوية والغياب النسبي للضوضاء المرئية، وهو السبب في حجب مؤثر لابلاس بتدرج مُنعَّم. أدت إضافة صورة حاصل الضرب إلى الصورة الأصلية إلى الحصول على الصورة المزادة الحدة في الشكل (g) 3.57. إن الزيادة في حدة التفاصيل في هذه الصورة مقارنة بالصورة الأصلية واضحة في معظم أجزاء الصورة، بما في ذلك الأضلاع، العمود الفقري، الحوض، والجمجمة. هذا النوع من التحسين لم يكن ممكناً باستخدام مؤثر لابلاس أو التدرج بمفرده.

إجراء زيادة الحدة الذي تم مناقشته للتو لم يؤثر بطريقة ملحوظة على النطاق الديناميكي لمستويات الشدة في الصورة. وبالتالي، فإن الخطوة الأخيرة في مهمة التحسين لدينا هي زيادة النطاق الديناميكي للصورة المزادة الحدة. كما ناقشنا ببعض التفصيل في القسمين 3.2 و 3.3، هناك العديد

من دوال تحويل الشدة التي يمكنها تحقيق هذا الهدف. معالجة المدرج التكراري (Histogram processing) ليست نهجاً جيداً للصور التي تتميز مدرجاتها التكرارية بمكونات داكنة و فاتحة،

وهو الحال هنا. الخصائص الداكنة للصور التي نتعامل معها تجعلها تتناسب بشكل أفضل مع تحويل قانون القوة (power-law transformation) ولأننا نرغب في توسيع مستويات الشدة،

يجب أن تكون قيمة γ في المعادلة (3-5) أقل من 1. بعد بضع محاولات باستخدام هذه

المعادلة، وصلنا إلى النتيجة في الشكل (h) 3.57، والتي تم الحصول عليها مع γ

0.5. و $c = 1$ بمقارنة هذه الصورة بالشكل (g) 3.57، نلاحظ أن تفاصيل جديدة مهمة أصبحت

مرئية في الشكل (h) 3.57. المناطق المحيطة بـ المعصمين، اليدين، الكاحلين، والقدمين هي أمثلة

جيدة على ذلك. كما أن البنية العظمية للهيكل العظمي أصبحت أكثر وضوحاً بكثير، بما في ذلك

عظام الذراعين والساقين. لاحظ التحديد الخفيف لمحيط الجسم وأنسجة الجسم. أدى إبراز تفاصيل


من هذا النوع عن طريق توسيع النطاق الديناميكي لمستويات الشدة أيضاً إلى تعزيز الضوضاء،

ولكن الشكل (h) يمثل تحسيناً بصرياً كبيراً مقارنة بالصورة الأصلية.

c f
g h

FIGURE 3.57

(Continued)
(e) Sobel image smoothed with a 5×5 box filter.
(f) Mask image formed by the product of (b) and (e).
(g) Sharpened image obtained by the adding images (a) and (f).
(h) Final result obtained by applying a power-law transformation to (g). Compare images (g) and (h) with (a). (Original image courtesy of G.E. Medical Systems.)



3.8 دمج طرق التعزيز المكاني

تسميات الشاخص والمحتوى البياني:

e | f

g | h

الشكل (3.57 متابع): - Continued)

(e) صورة سوبل تم تنعيمها بمرشح صندوق بحجم 5 (f) $\times 5$ صورة القناة المتكونة من حاصل ضرب (b) و (e). الصورة المزادة الحدة التي تم الحصول عليها بإضافة الصورتين (a) و (h). النتيجة النهائية التي تم الحصول عليها بتطبيق تحويل قانون القوة (power-law transformation) على (g). قارن الصورتين (g) و (h) بالصورة (a). الصورة الأصلية بإذن

من شركة G.E. Medical Systems).

196 الفصل 3 تحويلات الشدة والترشيح المكاني

الملخص، المراجع، وقرارات إضافية (Summary, References, and Further Reading) المادة الواردة في هذا الفصل تمثل التقنيات الحالية المستخدمة لتحويلات الشدة والترشيح المكاني. تم اختيار المواضيع لقيمتها كمادة أساسية تعمل كقاعدة في هذا المجال المتطور. على الرغم من أن معظم الأمثلة المستخدمة في هذا الفصل تتعامل مع تحسين الصور، فإن التقنيات...

Summary, References, and Further Reading

The material in this chapter is representative of current techniques used for intensity transformations and spatial filtering. The topics were selected for their value as fundamental material that would serve as a foundation in an evolving field. Although most of the examples used in this chapter deal with image enhancement, the techniques presented are perfectly general, and you will encounter many of them again throughout the remaining chapters in contexts unrelated to enhancement.

The material in Section 3.1 is from Gonzalez [1986]. For additional reading on the material in Section 3.2, see Schowengerdt [2006] and Poyton [1996]. Early references on histogram processing (Section 3.3) are Gonzalez and Fittes [1977], and Woods and Gonzalez [1981]. Stark [2000] gives some interesting generalizations of histogram equalization for adaptive contrast enhancement.

For complementary reading on linear spatial filtering (Sections 3.4–3.7), see Jain [1989], Rosenfeld and Kak [1982], Schowengerdt [2006], Castleman [1996], and Umbaugh [2010]. For an interesting approach for generating Gaussian kernels with integer coefficients see Padfield [2011]. The book by Pitas and Venetsanopoulos [1990] is a good source for additional reading on median and other nonlinear spatial filters.

For details on the software aspects of many of the examples in this chapter, see Gonzalez, Woods, and Eddins [2009].

Problems

Solutions to the problems marked with an asterisk (*) are in the DIP4E Student Support Package (consult the book website: www.ImageProcessingPlace.com).

- 3.1** Give a single intensity transformation function for spreading the intensities of an image so the lowest intensity is 0 and the highest is $L - 1$.
- 3.2** Do the following:
- (a)* Give a continuous function for implementing the contrast stretching transformation in Fig. 3.2(a). In addition to m , your function must include a parameter, E , for controlling the slope of the function as it transitions from low to high intensity values. Your function should be normalized so that its minimum and maximum values are 0 and 1, respectively.
- (b) Sketch a family of transformations as a function of parameter E , for a fixed value $m = L/2$, where L is the number of intensity levels in the image..
- 3.3** Do the following:
- (a)* Propose a set of intensity-slicing transformation functions capable of producing all the individual bit planes of an 8-bit monochrome image. For example, applying to an image a transformation function with the property $T(r) = 0$ if r is 0 or even, and $T(r) = 1$ if r is odd, produces an image of the least significant bit plane (see Fig. 3.13). (Hint: Use an 8-bit truth table to determine the form of each transformation function.)
- (b) How many intensity transformation functions would there be for 16-bit images?
- (c) Is the basic approach in (a) limited to images in which the number of intensity levels is an integer power of 2, or is the method general for any number of integer intensity levels?
- (d) If the method is general, how would it be different from your solution in (a)?
- 3.4** Do the following:
- (a) Propose a method for extracting the bit planes of an image based on converting the value of its pixels to binary.
- (b) Find all the bit planes of the following 4-bit image:
- | | | | |
|---|----|----|----|
| 0 | 1 | 8 | 6 |
| 2 | 2 | 1 | 1 |
| 1 | 15 | 14 | 12 |
| 3 | 6 | 9 | 10 |
- 3.5** In general:
- (a)* What effect would setting to zero the lower-

الفصل 3 تحويلات الشدة والترشيح المكاني

الملخص، المراجع، وقراءات إضافية (Summary, References, and Further Reading) المادة الواردة في هذا الفصل تمثل التقنيات الحالية المستخدمة لتحويلات الشدة والترشيح المكاني. تم اختيار المواضيع لقيمتها كمادة أساسية تعمل كقاعدة في هذا المجال المتطور. على الرغم من أن معظم الأمثلة المستخدمة في هذا الفصل تتعامل مع تحسين الصور، فإن التقنيات المعروضة عامة تماماً، وستصادف العديد منها مرة أخرى خلال الفصول المتبقية في سياقات غير مرتبطة بالتحسين.

المادة في القسم 3.1 هي من Gonzalez [1986] للقراءة الإضافية حول المادة في القسم 3.2، انظر Schowengerdt [2006] و Poyton [1996] المراجع المبكرة حول معالجة المدرج التكراري (القسم 3.3) هي Gonzalez and Fittes [1977] ، و Woods and [1981] Gonzalez. يقدم Stark [2000] بعض التعميمات المثيرة للاهتمام لموازنة المدرج التكراري لتحسين التباين التكيفي.

للقراءة التكميلية حول الترشيح المكاني الخطي (الأقسام 3.4-3.7)، انظر Jain [1989] ، و

Rosenfeld and Kak [1982]، وSchowengerdt [2006]، وCastleman [1996]، وUmbaugh [2010] للحصول على نهج مثير للاهتمام لتوليد نوى غاوسية بمعاملات صحيحة.

انظر Padfield [2011] كتاب Pitas and Venetsanopoulos [1990] هو مصدر جيد

للقراءة الإضافية حول مرشح الوسيط والمرشحات المكانية غير الخطية الأخرى.

للحصول على تفاصيل حول الجوانب البرمجية للعديد من الأمثلة في هذا الفصل، انظر [2009]

Gonzalez, Woods, and Eddins.

المسائل (Problems)

(حلول المسائل المعلمة بنجمة (*)) موجودة في حزمة دعم الطلاب لـ DIP4E راجع موقع

الكتاب. (www.ImageProcessingPlace.com):

3.1 اعط دالة تحويل شدة واحدة لتوسيع شدات صورة بحيث تكون أدنى شدة هي 0 وأعلى شدة

هي. L-1

3.2 قم بما يلي:

(a) * اعط دالة مستمرة لتنفيذ تحويل تمديد التباين الموضح في الشكل. (a) 3.2 بالإضافة إلى m، يجب أن تتضمن دالتك معلماً E للتحكم في ميل الدالة أثناء انتقالها من قيم الشدة المنخفضة إلى العالية. يجب تسوية دالتك (normalization) بحيث تكون قيمتها الدنيا والعليا هما 0 و 1 على التوالي.

(b) ارسم عائلة من التحويلات كدالة للمعلم E، لقيمة ثابتة $m = L/2$ ، حيث L هو عدد مستويات الشدة في الصورة.

3.3 قم بما يلي:

(a) * اقترح مجموعة من دوال تحويل تقسيم الشدة (intensity-slicing) القادرة على إنتاج جميع مستويات البت (bit planes) الفردية لصورة أحادية اللون ذات 8 بت. على سبيل المثال، تطبيق دالة تحويل ذات الخاصية $T(r) = 0$ إذا كانت r تساوي 0 أو زوجية، و $T(r) = 1$ إذا كانت r فردية، ينتج صورة لمستوى البت الأقل أهمية (انظر الشكل). (3.13) تلميح: استخدم جدول حقيقة ذات 8 بت لتحديد شكل كل دالة تحويل.

(b) كم عدد دوال تحويل الشدة التي ستكون موجودة للصور ذات 16 بت؟

(c) هل النهج الأساسي في (a) مقتصر على الصور التي يكون فيها عدد مستويات الشدة قوة صحيحة للعدد 2، أم أن الطريقة عامة لأي عدد من مستويات الشدة الصحيحة؟

(d) إذا كانت الطريقة عامة، فكيف ستختلف عن حلك في (a)؟

3.4 قم بما يلي (a): اقترح طريقة لاستخراج مستويات البت لصورة بناءً على تحويل قيمة البكسلات إلى النظام الثنائي (b). أوجد جميع مستويات البت للصورة ذات 4 بت التالية:


\begin{matrix} 0 & 1 & 8 & 6 \\ 2 & 2 & 1 & 1 \\ 1 & 15 & 14 & 12 \\ 3 & 6 & 9 & 10 \end{matrix}

3.5 بشكل عام:

- order bit planes have on the histogram of an image?
- (b) What would be the effect on the histogram if we set to zero the higher-order bit planes instead?
- 3.6 Explain why the discrete histogram equalization technique does not yield a flat histogram in general.
- 3.7 Suppose that a digital image is subjected to histogram equalization. Show that a second pass of histogram equalization (on the histogram-equalized image) will produce exactly the same result as the first pass.
- 3.8 Assuming continuous values, show by an example that it is possible to have a case in which the transformation function given in Eq. (3-11) satisfies conditions (a) and (b) discussed in Section 3.3, but its inverse may fail condition (a').
- 3.9 Do the following:
- (a) Show that the discrete transformation function given in Eq. (3-15) for histogram equalization satisfies conditions (a) and (b) stated at the beginning of Section 3.3.
- (b)* Show that the inverse discrete transformation in Eq. (3-16) satisfies conditions (a') and (b) in Section 3.3 *only if* none of the intensity levels r_k , $k = 0, 1, 2, \dots, L-1$, are missing in the original image.
- 3.10 Two images, $f(x, y)$ and $g(x, y)$ have unnormalized histograms h_f and h_g . Give the conditions (on the values of the pixels in f and g) under which you can determine the histograms of images formed as follows:
- (a)* $f(x, y) + g(x, y)$
- (b) $f(x, y) - g(x, y)$
- (c) $f(x, y) \times g(x, y)$
- (d) $f(x, y) \div g(x, y)$
- Show how the histograms would be formed in each case. The arithmetic operations are element-wise operations, as defined in Section 2.6.
- 3.11 Assume continuous intensity values, and suppose that the intensity values of an image have the PDF $p_r(r) = 2r/(L-1)^2$ for $0 \leq r \leq L-1$, and $p_r(r) = 0$ for other values of r .

- (a)* Find the transformation function that will map the input intensity values, r , into values, s , of a histogram-equalized image.
- (b)* Find the transformation function that (when applied to the histogram-equalized intensities, s) will produce an image whose intensity PDF is $p_z(z) = 3z^2/(L-1)^3$ for $0 \leq z \leq L-1$ and $p_z(z) = 0$ for other values of z .
- (c) Express the transformation function from (b) directly in terms of r , the intensities of the input image.

3.12 An image with intensities in the range $[0, 1]$ has the PDF, $p_r(r)$, shown in the following figure. It is desired to transform the intensity levels of this image so that they will have the specified $p_z(z)$ shown in the figure. Assume continuous quantities, and find the transformation (expressed in terms of r and z) that will accomplish this.



- 3.13* In Fig. 3.25(b), the transformation function labeled (2) $[G^{-1}(s_k)]$ from Eq. (3-23) is the mirror image of (1) $[G(z_q)]$ in Eq. (3-21) about a line joining the two end points. Does this property always hold for these two transformation functions? Explain.
- 3.14* The local histogram processing method discussed in Section 3.3 requires that a histogram be computed at each neighborhood location. Propose a method for updating the histogram from one neighborhood to the next, rather than computing a new histogram each time.
- 3.15 What is the behavior of Eq. (3-35) when $a = b = 0$? Explain.
- 3.16 You are given a computer chip that is capable of performing linear filtering in real time, but you are not told whether the chip performs correlation or convolution. Give the details of a test you would perform to determine which of the two operations the chip performs.
- 3.17* We mentioned in Section 3.4 that to perform con-

المسائل

3.5: متابعة المسألة

- (a)* ما التأثير الذي سيحدثه ضبط مستويات البت الأقل أهمية على صفر في المدرج التكراري للصورة؟
- (b) ما التأثير على المدرج التكراري إذا قمنا بضبط مستويات البت الأعلى أهمية على صفر بدلاً من ذلك؟
- 3.6 اشرح لماذا تقنية موازنة المدرج التكراري المتقطع لا تؤدي إلى مدرج تكراري مسطح بشكل عام.

3.7 افترض أن صورة رقمية تم إخضاعها لموازنة المدرج التكراري. بين أن ممرًا ثانيًا من موازنة المدرج التكراري (على الصورة موازنة المدرج التكراري بالفعل) سينتج بدقة نفس نتيجة الممر الأول.

3.8 بفرض قيم مستمرة، بين بمثال أنه من الممكن وجود حالة تلبي فيها دالة التحويل المعطاة في المعادلة (3-11) الشرطين (a) و (b) المناقشين في القسم 3.3، ولكن معكوسها قد يفشل في تحقيق الشرط (a').

3.9 قم بما يلي:

(a) بين أن دالة التحويل المتقطعة المعطاة في المعادلة (3-15) لموازنة المدرج التكراري تلي الشرطين (a) و (b) المذكورين في بداية القسم 3.3.

* (b) بين أن التحويل المتقطع المعكوس في المعادلة (3-16) يلبي الشرطين (a') و (b) في القسم 3.3 فقط إذا لم يكن أي من مستويات الشدة r_k حيث $k=0,1,2,\dots,L-1$ مفقوداً في الصورة الأصلية.

3.10 صورتان $f(x,y)$ و $g(x,y)$ تملكان مدرجات تكرارية غير مسواة h_f (unnormalized) و h_g . اعط الشروط على قيم البكسلات في f و g التي يمكنك في ظلها تحديد المدرجات التكرارية للصور المتكونة كالتالي:

(a) $f(x,y) + g(x,y)$

(b) $f(x,y) - g(x,y)$

(c) $f(x,y) \times g(x,y)$

(d) $f(x,y) \div g(x,y)$

وضح كيف ستتكون المدرجات التكرارية في كل حالة. العمليات الحسابية هي عمليات تتم عنصراً بعنصر (element-wise operations)، كما هو محدد في القسم 2.6.

3.11 افترض قيم شدة مستمرة، وافترض أن قيم الشدة لصورة لها دالة كثافة الاحتمال $p_r(r)$ لكل $0 \leq r \leq L-1$ ، و $p_r(r) = 0$ للقيم الأخرى من r .

* (a) أوجد دالة التحويل التي تعين قيم الشدة المدخلة r إلى قيم s لصورة متوازنة المدرج التكراري.

* (b) أوجد دالة التحويل التي (عند تطبيقها على الشدات متوازنة المدرج التكراري s) تنتج

صورة تكون دالة كثافة الاحتمال لشدها هي $p_z(z) = 3z^2 / (L-1)^3$ لكل $0 \leq z \leq L-1$ و $p_z(z) = 0$ للقيم الأخرى من z .

(c) عبر عن دالة التحويل من (b) مباشرة بدلالة r شدات الصورة المدخلة.

3.12 صورة ذات شدات في النطاق $[0,1]$ تملك دالة كثافة الاحتمال $p_r(r)$ الموضحة في الشكل التالي. يُراد تحويل مستويات الشدة لهذه الصورة بحيث تكون لها دالة كثافة الاحتمال المحددة $p_z(z)$ الموضحة في الشكل. افترض كميات مستمرة، وأوجد التحويل) معبراً عنه بدلالة r و z الذي سيققق ذلك.

(المخطط البياني للمسألة 3.12 يُظهر $p_r(r)$ تنحدر خطياً من 2 عند $r=0$ إلى 0 عند $r=1$ ؛ بينما $p_z(z)$ تصعد خطياً من 0 عند $z=0$ إلى 2 عند $z=1$).

* 3.13 في الشكل (b) 3.25، دالة التحويل المحددة بـ $G^{-1}(s_k)$ (2) من المعادلة (3-23) هي صورة مرآة لـ $G(z-q)$ (في المعادلة (3-21)) حول خط يربط نقطتي النهاية. هل تتحقق هذه الخاصية دائماً لدالتي التحويل هاتين؟ اشرح.

* 3.14 طريقة معالجة المدرج التكراري المحلي المناقشة في القسم 3.3 تتطلب حساب مدرج تكراري عند كل موقع جوار. اقترح طريقة لتحديث المدرج التكراري من جوار إلى آخر بدلاً من حساب مدرج تكراري جديد في كل مرة.

3.15 ما هو سلوك المعادلة (3-35) عندما تكون $a = b = 0$ ؟ اشرح.

3.16 قُدِّم لك رقاقة حاسوبية (computer chip) قادرة على إجراء ترشيح خطي في الوقت الفعلي، لكن لم يُذكر لك ما إذا كانت الرقاقة تنفذ عملية التلازم (correlation) أم الالتفاف (convolution). اعط تفاصيل اختبار تجريبه لتحديد أي من العمليتين تنفذها الرقاقة.

3.17* ذكرنا في القسم 3.4 أنه لإجراء الالتفاف...

olution we rotate the kernel by 180° . The rotation is "built" into Eq. (3-35). Figure 3.28 corresponds to correlation. Draw the part of the figure enclosed by the large ellipse, but with w rotated 180° . Expand Eq. (3-35) for a general 3×3 kernel and show that the result of your expansion corresponds to your figure. This shows graphically that convolution and correlation differ by the rotation of the kernel.

3.18 You are given the following kernel and image:

$$w = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \quad f = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

(a)* Give a sketch of the area encircled by the large ellipse in Fig. 3.28 when the kernel is centered at point (2,3) (2nd row, 3rd col) of the image shown above. Show specific values of w and f .

(b)* Compute the convolution $w \star f$ using the *minimum* zero padding needed. Show the details of your computations when the kernel is centered on point (2,3) of f ; and then show the final full convolution result.

(c) Repeat (b), but for correlation, $w \circledast f$.

3.19* Prove the validity of Eqs. (3-36) and (3-37).

3.20 The kernel, w , in Problem 3.18 is separable.

(a)* By inspection, find two kernels, w_1 and w_2 so that $w = w_1 \star w_2$.

(b) Using the image in Problem 3.18, compute $w_1 \star f$ using the *minimum* zero padding (see Fig. 3.30). Show the details of your computation when the kernel is centered at point (2,3) (2nd row, 3rd col) of f and then show the full convolution.

(c) Compute the convolution of w_2 with the result from (b). Show the details of your computation when the kernel is centered at point (3,3) of the result from (b), and then show the full convolution. Compare with the result in Problem 3.18(b).

3.21 Given the following kernel and image:

$$w = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \quad f = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

(a) Give the convolution of the two.

(b) Does your result have a bias?

3.22 Answer the following:

(a)* If $v = [1 \ 2 \ 1]^T$ and $w^T = [2 \ 1 \ 1 \ 3]$, is the kernel formed by vw^T separable?

(b) The following kernel is separable. Find w_1 and w_2 such that $w = w_1 \star w_2$.

$$w = \begin{bmatrix} 1 & 3 & 1 \\ 2 & 6 & 2 \end{bmatrix}$$

3.23 Do the following:

(a)* Show that the Gaussian kernel, $G(s,t)$, in Eq. (3-45) is separable. (Hint: Read the first paragraph in the discussion of separable filter kernels in Section 3.4.)

(b) Because G is separable and circularly symmetric, it can be expressed in the form $G = vv^T$. Assume that the kernel form in Eq. (3-46) is used, and that the function is sampled to yield an $m \times m$ kernel. What is v in this case?

3.24* Show that the product of a column vector with a row vector is equivalent to the 2-D convolution of the two vectors. The vectors do not have to be of the same length. You may use a graphical approach (as in Fig. 3.30) to support the explanation of your proof.

3.25 Given K , 1-D Gaussian kernels, $g_1, g_2, \dots, g_K$, with arbitrary means and standard deviations:

(a)* Determine what the entries in the third column of Table 3.6 would be for the product $g_1 \times g_2 \times \dots \times g_K$.

(b) What would the fourth column look like for the convolution $g_1 \star g_2 \star \dots \star g_K$?

(Hint: It is easier to work with the variance; the standard deviation is just the square root of your result.)

الفصل 3 تحويلات الشدة والترشيح المكاني

متابعة المسألة 3.17*

...الالتفاف، نقوم بتدوير النواة بمقدار 180° هذا التدوير "مبني" في المعادلة (3-35). الشكل 3.28 يتوافق مع التلازم (correlation). ارسم الجزء من الشكل المحاط بالقطع الناقص الكبير، ولكن مع تدوير w بمقدار 180° قم بتوسيع المعادلة (3-35) لنواة عامة بحجم 3×3 وبين أن نتيجة توسيعك تتوافق مع رسمك. يوضح هذا بياناً أن الالتفاف والتلازم يختلفان فقط بتدوير النواة.

3.18 قُدمت لك النواة والصورة التاليتان:

(a)* اعط رسماً تخطيطياً للمنطقة المحاطة بالقطع الناقص الكبير في الشكل 3.28 عندما تكون النواة متمركزة عند النقطة (2,3) (الصف الثاني، العمود الثالث) للصورة الموضحة أعلاه. اعرض قيمة محددة لـ w و f .

(b)* احسب الالتفاف $w \star f$ باستخدام الحد الأدنى من حشو الأصفار (zero padding) المطلوب. اعرض تفاصيل حساباتك عندما تكون النواة متمركزة عند النقطة (2,3) من f ؛ ثم اعرض النتيجة الكاملة للالتفاف.

(c) كرر (b)، ولكن للتلازم $w \circledast f$.

*3.19 أثبت صحة المعادلتين (3-36) و (3-37)

3.20 النواة w في المسألة 3.18 قابلة للفصل (separable).

(a) بالتأمل، أوجد نواتين w_1 و w_2 بحيث تكون $w = w_1 \star w_2$

(b) باستخدام الصورة في المسألة 3.18، احسب $w_1 \star f$ باستخدام الحد الأدنى من حشو الأصفار (انظر الشكل 3.30). اعرض تفاصيل حساباتك عندما تكون النواة متمركزة عند النقطة (2,3) (الصف الثاني، العمود الثالث) من f ثم اعرض الالتفاف الكامل.

(c) احسب الالتفاف لـ w_2 مع النتيجة من (b). اعرض تفاصيل حساباتك عندما تكون النواة متمركزة عند النقطة (3,3) للنتيجة من (b)، ثم اعرض الالتفاف الكامل. قارن مع النتيجة في

المسألة 3.18(b).

3.21 قُدِّمَت لك النواة والصورة التاليتان:

(a) اعطِ الالتفاف لكتيهما.

(b) هل تحتوي نتيجتك على انحياز (bias) ؟

3.22 أجب عما يلي:

(a) إذا كانت $\mathbf{v} = \begin{bmatrix} 1 & 2 & 1 \end{bmatrix}^T$

و $\mathbf{w}^T = \begin{bmatrix} 2 & 1 & 1 & 3 \end{bmatrix}$ ،

هل النواة المتكونة بواسطة $\mathbf{v} \mathbf{w}^T$ قابلة للفصل؟

(b) النواة التالية قابلة للفصل. أوجد w_1 و w_2 بحيث 3.23: $w = w_1 \star w_2$ قم بما يلي:

(a) بين أن النواة الغاوسية $G(s,t)$ في المعادلة (3-45) قابلة للفصل. (تلميح: اقرأ الفقرة الأولى في مناقشة مرشحات النواة القابلة للفصل في القسم 3.4)

(b) لأن G قابلة للفصل ومتماثلة دائرية، يمكن التعبير عنها على الصورة $G = \mathbf{v} \mathbf{v}^T$. افترض استخدام صيغة النواة في المعادلة (3-46)، وأن الدالة تم

أخذ عينات منها لإنتاج نواة بحجم $m \times m$ ما هي $\mathbf{v}$ في هذه الحالة؟
*3.24 بين أن حاصل ضرب متجه عمود في متجه صف مكافئ للالتفاف ثنائي الأبعاد للمتجهين. لا يلزم أن يكون المتجهان بنفس الطول. يمكنك استخدام نهج بياني (كما في الشكل 3.30) لدعم شرح إثباتك.

3.25 قُدِّمَت لك K من النوى الغاوسية أحادية الأبعاد $g_1, g_2, \dots, g_K$ بأوساط حسابية وانحرافات معيارية اختيارية:

(a) حدد ماذا ستكون المدخلات في العمود الثالث من الجدول 3.6 لحاصل الضرب g_1

$\times g_2 \times \dots \times g_K$.

(b) كيف سيبدو العمود الرابع لالتفاف $g_1 \star g_2 \star \dots \star g_K$ ؟
(تلميح: من الأسهل العمل مع التباين (variance) ؛ الانحراف المعياري هو مجرد الجذر التربيعي لنتيجتك)

- 3.26** The two images shown in the following figure are quite different, but their histograms are the same. Suppose that each image is blurred using a 3×3 box kernel.

(a)* Would the histograms of the blurred images still be equal? Explain.



(b) If your answer is no, either sketch the two histograms or give two tables detailing the histogram components.

- 3.27** An image is filtered four times using a Gaussian kernel of size 3×3 with a standard deviation of 1.0. Because of the associative property of convolution, we know that equivalent results can be obtained using a single Gaussian kernel formed by convolving the individual kernels.

(a)* What is the size of the single Gaussian kernel?

(b) What is its standard deviation?

- 3.28** An image is filtered with three Gaussian lowpass kernels of sizes 3×3 , 5×5 , and 7×7 , and standard deviations 1.5, 2, and 4, respectively. A composite filter, w , is formed as the convolution of these three filters.

(a)* Is the resulting filter Gaussian? Explain.

(b) What is its standard deviation?

(c) What is its size?

- 3.29*** Discuss the limiting effect of repeatedly filtering an image with a 3×3 lowpass filter kernel. You may ignore border effects.

- 3.30** In Fig. 3.42(b) the corners of the estimated shading pattern appear darker or lighter than their surrounding areas. Explain the reason for this.

- 3.31*** An image is filtered with a kernel whose coefficients sum to 1. Show that the sum of the pixel values in the original and filtered images is the same.

- 3.32** An image is filtered with a kernel whose coefficients sum to 0. Show that the sum of the pixel values in the filtered image also is 0.

- 3.33** A single point of light can be modeled by a digital image consisting of all 0's, with a 1 in the location of the point of light. If you view a single point of light through a defocused lens, it will appear as a fuzzy blob whose size depends on the amount by which the lens is defocused. We mentioned in Section 3.5 that filtering an image with a box kernel is a poor model for a defocused lens, and that a better approximation is obtained with a Gaussian kernel. Using the single-point-of-light analogy, explain why this is so.

- 3.34** In the original image used to generate the three blurred images shown, the vertical bars are 5 pixels wide, 100 pixels high, and their separation is 20 pixels. The image was blurred using square box kernels of sizes 23, 25, and 45 elements on the side, respectively. The vertical bars on the left, lower part of (a) and (c) are blurred, but a clear separation exists between them.



However, the bars have merged in image (b), despite the fact that the kernel used to generate this image is much smaller than the kernel that produced image (c). Explain the reason for this.

- 3.35** Consider an application such as in Fig. 3.41, in which it is desired to eliminate objects smaller than those enclosed by a square of size $q \times q$ pixels. Suppose that we want to reduce the average

المسائل

3.26 الصورتان الموضحتان في الشكل التالي مختلفان تمامًا، لكن مدرجاتهما التكرارية (histograms) متماثلة. افترض أن كل صورة تم تطبيق ضبابية عليها باستخدام مرشح صندوق (box kernel) بحجم 3×3 .

(a)* هل ستظل المدرجات التكرارية للصور الضبابية متساوية؟ اشرح.
(b) إذا كانت إجابتك بـ "لا"، إما أن ترسم المدرجين التكراريين أو تقدم جدولين يوضحان مكونات المدرج التكراري بالتفصيل.

3.27 تم ترشيح صورة أربع مرات باستخدام نواة غاوسية بحجم 3×3 وانحراف معياري 1.0. بسبب خاصية التجميع (associative property) للالتفاف، نعلم أنه يمكن الحصول على نتائج مكافئة باستخدام نواة غاوسية واحدة متكونة من الالتفاف النوى الفردية.

(a)* ما هو حجم النواة الغاوسية الواحدة؟

(b) ما هو انحرافها المعياري؟

3.28 تم ترشيح صورة بثلاثة مرشحات غاوسية لتمشيط الترددات المنخفضة بأحجام 3×3 و 5×5 و 7×7 ، وانحرافات معيارية 1.5 و 2 و 4 على التوالي. تم تشكيل مرشح مركب w كالتفاف لهذه المرشحات الثلاثة.

(a)* هل المرشح الناتج غاوسي؟ اشرح.

(b) ما هو انحرافه المعياري؟

(c) ما هو حجمه؟

*3.29 ناقش الأثر المحدود (limiting effect) للترشيح المتكرر لصورة باستخدام نواة مرشح

ترددات منخفضة بحجم 3×3 يمكنك إهمال تأثيرات الحدود. (border effects)

3.30 في الشكل (b) 3.42، تظهر أركان نمط الظل المقدر أعمق أو أفتح من المناطق المحيطة بها. اشرح السبب في ذلك.

*3.31 تم ترشيح صورة بنواة مجموع معاملات يساوي 1. بين أن مجموع قيم البكسلات في الصورة الأصلية والصورة المرشحة هو نفسه.

3.32 تم ترشيح صورة بنواة مجموع معاملات يساوي 0. بين أن مجموع قيم البكسلات في الصورة المرشحة هو 0 أيضاً.

3.33 يمكن نمذجة نقطة ضوء واحدة ببدائل صورة رقمية تتكون من أصفار بالكامل، مع وجود 1 في موقع نقطة الضوء. إذا شاهدت نقطة ضوء واحدة عبر عدسة خارج البؤرة (defocused

lens)، فستظهر كبقعة ضبابية يعتمد حجمها على مقدار الخروج عن البؤرة. ذكرنا في

القسم 3.5 أن ترشيح صورة بنواة صندوق هو نموذج ضعيف لعدسة خارج البؤرة، وأن التقريب الأفضل يتم الحصول عليه بنواة غاوسية. باستخدام قياس نقطة الضوء الواحدة، اشرح سبب ذلك.

3.34 في الصورة الأصلية المستخدمة لتوليد الصور الضبابية الثلاث الموضحة، كانت الأشرطة العمودية بعرض 5 بكسلات، وارتفاع 100 بكسل، والمسافة الفاصلة بينها 20 بكسل. تم تطبيق

الضبابية على الصورة باستخدام نوى صندوق مربعة بأحجام 23، 25، و 45 عنصراً في الضلع، على التوالي. الأشرطة العمودية على اليسار في الجزء السفلي من (a) و (c) ضبابية، ولكن يوجد فصل واضح بينها.

(الأشكال الإيضاحية a, b, c للصور الضبابية)

ومع ذلك، اندمجت الأشرطة في الصورة (b)، على الرغم من أن النواة المستخدمة لتوليد هذه الصورة أصغر بكثير من النواة التي أنتجت الصورة (c). اشرح السبب في ذلك.

3.35 افترض تطبيقاً كما في الشكل 3.41، حيث يُراد إزالة الكائنات التي حجمها أصغر من تلك المحاطة بمربع بحجم $q \times q$ بكسل. افترض أننا نريد تقليل متوسط شدة تلك الكائنات إلى

عُشر قيمتها المتوسطة الأصلية. بهذه الطريقة، ستكون شدتها أقرب إلى شدة الخلفية ويمكن إزالتها بواسطة العتبة. (thresholding) اعطِ الحجم (الفردي) لأصغر نواة صندوق تحقق التخفيض المطلوب في متوسط الشدة...

intensity of those objects to one-tenth of their original average value. In this way, their intensity will be closer to the intensity of the background and they can be eliminated by thresholding. Give the (odd) size of the smallest box kernel that will yield the desired reduction in average intensity in only one pass of the kernel over the image.

3.36 With reference to order-statistic filters (see Section 3.5):

(a)* We mentioned that isolated clusters of dark or light (with respect to the background) pixels whose area is less than one-half the area of a median filter are forced to the median value of the neighbors by the filter. Assume a filter of size $n \times n$ (n odd) and explain why this is so.

(b) Consider an image having various sets of pixel clusters. Assume that all points in a cluster are lighter or darker than the background (but not both simultaneously in the same cluster), and that the area of each cluster is less than or equal to $n^2/2$. In terms of n , under what condition would one or more of these clusters cease to be isolated in the sense described in part (a)?

3.37 Do the following:

(a)* Develop a procedure for computing the median of an $n \times n$ neighborhood.

(b) Propose a technique for updating the median as the center of the neighborhood is moved from pixel to pixel.

3.38 In a given application, a smoothing kernel is applied to input images to reduce noise, then a Laplacian kernel is applied to enhance fine details. Would the result be the same if the order of these operations is reversed?

3.39* Show that the Laplacian defined in Eq. (3-50) is isotropic (invariant to rotation). Assume continuous quantities. From Table 2.3, coordinate rotation by an angle θ is given by

$$x' = x \cos \theta - y \sin \theta \text{ and } y' = x \sin \theta + y \cos \theta$$

where (x, y) and (x', y') are the unrotated and rotated coordinates, respectively.

3.40* You saw in Fig. 3.46 that the Laplacian with a -8

in the center yields sharper results than the one with a -4 in the center. Explain the reason why.

3.41* Give a 3×3 kernel for performing unsharp masking in a single pass through an image. Assume that the average image is obtained using a box filter of size 3×3 .

3.42 Show that subtracting the Laplacian from an image gives a result that is proportional to the unsharp mask in Eq. (3-55). Use the definition for the Laplacian given in Eq. (3-53).

3.43 Do the following:

(a)* Show that the magnitude of the gradient given in Eq. (3-58) is an isotropic operation (see the statement of Problem 3.39).

(b) Show that the isotropic property is lost in general if the gradient is computed using Eq. (3-59).

3.44 Are any of the following highpass (sharpening) kernels separable? For those that are, find vectors $\mathbf{v}$ and $\mathbf{w}$ such that $\mathbf{vw}^T$ equals the kernel(s).

(a) The Laplacian kernels in Figs. 3.45(a) and (b).

(b) The Roberts cross-gradient kernels shown in Figs. 3.50(b) and (c).

(c)* The Sobel kernels in Figs. 3.50(d) and (e).

3.45 In a character recognition application, text pages are reduced to binary using a thresholding transformation function of the form in Fig. 3.2(b). This is followed by a procedure that thins the characters until they become strings of binary 1's on a background of 0's. Due to noise, binarization and thinning result in broken strings of characters with gaps ranging from 1 to 3 pixels. One way to "repair" the gaps is to run a smoothing kernel over the binary image to blur it, and thus create bridges of nonzero pixels between gaps.

(a)* Give the (odd) size of the smallest box kernel capable of performing this task.

(b) After bridging the gaps, the image is thresholded to convert it back to binary form. For your answer in (a), what is the minimum value of the threshold required to accomplish this, without causing the segments to break up again?

200 الفصل 3 تحويلات الشدة والترشيح المكاني

3.35: المسألة

...شدة تلك الكائنات إلى عُشر قيمتها المتوسطة الأصلية. بهذه الطريقة، ستكون شدتها أقرب إلى شدة الخلفية ويمكن إزالتها بواسطة العتبة. (thresholding) اعطِ الحجم (الفردى) لأصغر نواة صندوق تحقق التخفيض المطلوب في متوسط الشدة في ممر واحد فقط للنواة عبر الصورة.

3.36 بالرجوع إلى مرشحات الإحصاء الترتيبي (order-statistic filters) انظر القسم: **3.5**

(a)* ذكرنا أن التجمعات المنعزلة من البكسلات الداكنة أو الفاتحة (بالنسبة للخلفية) التي تقل مساحتها عن نصف مساحة مرشح الوسيط تُجبر على أخذ قيمة الوسيط للجيران بواسطة المرشح. افترض مرشحاً بحجم $n \times n$ فردى (واشرح سبب ذلك).

(b) اعتبر صورة تحتوي على مجموعات مختلفة من تجمعات البكسلات. افترض أن جميع النقاط في التجمع أفتح أو أغمق من الخلفية (ولكن ليس كلاهما في نفس التجمع)، وأن مساحة كل تجمع أقل من أو تساوي $n^2/2$ بدلالة n ، تحت أي شرط يتوقف واحد أو أكثر من هذه التجمعات عن كونها منعزلة بالمعنى الموصوف في الجزء (a)؟

3.37 قم بما يلي:

(a)* طور إجراء لحساب الوسيط لجوار بحجم $n \times n$.

(b) اقترح تقنية لتحديث الوسيط أثناء تحرك مركز الجوار من بكسل إلى بكسل.

3.38 في تطبيق معين، يتم تطبيق نواة تنعيم على الصور المدخلة لتقليل الضوضاء، ثم يتم تطبيق

نواة لابلاس لتعزيز التفاصيل الدقيقة. هل ستكون النتيجة هي نفسها إذا تم عكس ترتيب هذه العمليات؟

* [3.39](#) بين أن مؤثر لابلاس المحدد في المعادلة (3-50) هو متمائل المناحي (isotropic) غير متغير بالدوران). افترض كميات مستمرة. من الجدول 2.3، دوران الإحداثيات بزاوية θ يعطى بـ:

$$\begin{aligned} x' &= x \cos \theta - y \sin \theta \\ y' &= x \sin \theta + y \cos \theta \end{aligned}$$

حيث (x, y) و (x', y') هي الإحداثيات غير المدورة والمدورة على التوالي. [3.40](#)* رأيت في الشكل 3.46 أن مؤثر لابلاس مع 8- في المركز يعطي نتائج أكثر حدة من المرشح الذي يحتوي على 4- في المركز. اشرح السبب في ذلك. [3.41](#)* أعط نواة بحجم 3×3 لإجراء حجب زيادة الحدة (unsharp masking) وتنفيذها بممر واحد عبر الصورة. افترض أن الصورة المتوسطة يتم الحصول عليها باستخدام مرشح صندوق بحجم 3×3

[3.42](#) بين أن طرح مؤثر لابلاس من صورة يعطي نتيجة تتناسب مع قناع زيادة الحدة في المعادلة (3-55). استخدم التعريف الخاص بمؤثر لابلاس المعطى في المعادلة (3-53).

[3.43](#) قم بما يلي:

(a)* بين أن مقدار التدرج المعطى في المعادلة (3-58) هو عملية متماثلة المناحي (isotropic) (انظر نص المسألة 3.39).
(b) بين أن خاصية التماثل المنحي تضع بشكل عام إذا تم حساب التدرج باستخدام المعادلة (3-59).

[3.44](#) هل أي من نوى الترددات العالية (زيادة الحدة) التالية قابلة للفصل؟ بالنسبة للنوى القابلة للفصل، أوجد المتجهين $\mathbf{v}$ و $\mathbf{w}$ بحيث $\mathbf{v}^T \mathbf{w} = 0$ (النوى):

(a) نوى لابلاس في الشكلين (a) و (b) 3.45.

(b) نوى رابرتس للتدرج المتقاطع (Roberts cross-gradient) الموضحة في

الشكلين (b) و (c) 3.50.

(c)* نوى سوبل (Sobel) في الشكلين (d) و (e) 3.50.

[3.45](#) في تطبيق التعرف على الرموز/الأحرف، يتم تحويل صفحات النصوص إلى ثنائية باستخدام دالة تحويل العتبة من الشكل الموضح في الشكل (b) 3.2. يتبع ذلك إجراء يقوم بترقيق الأحرف حتى تصبح سلاسل من البكسلات الثنائية بقيمة 1 على خلفية من الأصفار. بسبب الضوضاء، تنتج عن تحويل الثنائية والترقيق سلاسل مكسورة من الأحرف بفجوات تتراوح من 1 إلى 3 بكسلات. إحدى الطرق لـ "إصلاح" الفجوات هي تطبيق نواة تنعيم على الصورة الثنائية لتنعيمها/تغبيشها، وبالتالي إنشاء جسور من بكسلات غير صفرية بين الفجوات.

(a)* أعط الحجم (الفردى) لأصغر نواة صندوق قادرة على تنفيذ هذه المهمة.

(b) بعد تجسير الفجوات، يتم تطبيق العتبة على الصورة لتحويلها مرة أخرى إلى الشكل الثنائي. بالنسبة لإجابتك في (a)، ما هي القيمة الدنيا للعتبة المطلوبة لتحقيق ذلك، دون التسبب في انكسار أجزاء السلاسل مرة أخرى؟

- 3.46** A manufacturing company purchased an imaging system whose function is to either smooth or sharpen images. The results of using the system on the manufacturing floor have been poor, and the plant manager suspects that the system is not smoothing and sharpening images the way it should. You are hired as a consultant to determine if the system is performing these functions properly. How would you determine if the system is working correctly? (*Hint: Study the statements of Problems 3.31 and 3.32*).
- 3.47** A CCD TV camera is used to perform a long-term study by observing the same area 24 hours a day, for 30 days. Digital images are captured and transmitted to a central location every 5 minutes. The illumination of the scene changes from natural day-

light to artificial lighting. At no time is the scene without illumination, so it is always possible to obtain an acceptable image. Because the range of illumination is such that it is always in the linear operating range of the camera, it is decided not to employ any compensating mechanisms on the camera itself. Rather, it is decided to use image processing techniques to post-process, and thus normalize, the images to the equivalent of constant illumination. Propose a method to do this. You are at liberty to use any method you wish, but state clearly all the assumptions you made in arriving at your design.

المسائل

- 3.46** اشترت شركة تصنيع نظام تصوير وظيفته إما تنعيم الصور أو زيادة حداثتها. كانت نتائج استخدام النظام في أرضية التصنيع سيئة، وريتاب مدير المصنع في أن النظام لا يقوم بتنعيم وزيادة حدة الصور بالشكل المطلوب. تم توظيفك كاستشاري لتحديد ما إذا كان النظام يؤدي هذه وظائفه بشكل صحيح. كيف ستحدد ما إذا كان النظام يعمل بشكل صحيح؟ (تلميح: ادرس نص المسألتين **3.31** و **3.32**).
- 3.47** تُستخدم كاميرا تلفزيونية من نوع CCD لإجراء دراسة طويلة الأمد عن طريق مراقبة نفس المنطقة 24 ساعة في اليوم، لمدة 30 يومًا. يتم التقاط الصور الرقمية وإرسالها إلى موقع مركزي كل 5 دقائق. تتغير إضاءة المشهد من ضوء النهار الطبيعي إلى الإضاءة الاصطناعية. لا يوجد وقت يكون فيه المشهد بدون إضاءة، لذلك من الممكن دائمًا الحصول على صورة مقبولة. لأن نطاق الإضاءة هو دائمًا ضمن نطاق التشغيل الخطي للكاميرا، تقرر عدم استخدام أي آليات تعويض على الكاميرا نفسها. بدلاً من ذلك، تقرر استخدام تقنيات معالجة الصور للمعالجة اللاحقة، ومن ثم تسوية (normalize) الصور لما يعادل إضاءة ثابتة. اقترح طريقة القيام بذلك. أنت حر في استخدام أي طريقة ترغب فيها، ولكن اذكر بوضوح جميع الافتراضات التي افترضتها في الوصول إلى تصميمك.